Тренировочные вопросы

1. В рамках анализа геометрии скрытых представлений в пространстве размерности $d = 4096$ независимо сэмплируются два вектора x и y из равномерного распределения внутри единичного шара $B^d = \{z \in \mathbb{R}^d : \|z\|_2 \leq 1\}$.

   К какому конкретному числовому значению с подавляющей вероятностью будет близко евклидово расстояние $\|x - y\|_2$ между ними? Обоснуйте полученный результат в 1–2 предложениях.

2. В задаче сжатия признаков вектор v сэмплируется равномерно из единичной гиперсферы $\mathbb{S}^{d-1}$ в пространстве $\mathbb{R}^d$ при $d = 100$. Пусть $W \subset \mathbb{R}^d$ — фиксированное линейное подпространство размерности $k = 25$, а $P_W v$ — ортогональная проекция вектора v на подпространство W.

   Чему равно точное математическое ожидание квадрата евклидовой нормы этой проекции, $\mathbb{E}\left[\|P_W v\|_2^2\right]$?

3. При исследовании латентных представлений вектор эмбеддинга v выбирается случайно и равномерно на единичной сфере $\mathbb{S}^{d-1}$. Инженер рассматривает проекцию этого вектора сразу на два взаимно ортогональных единичных направления $u_1, u_2 \in \mathbb{S}^{d-1}$ с помощью функции:

   $$g(v) = \langle u_1, v\rangle + \langle u_2, v\rangle$$

   Во сколько раз необходимо увеличить размерность пространства d, чтобы верхняя граница вероятности уклонения $\mathbb{P}(|g(v)| \geq \varepsilon)$, полученная из неравенства Леви на сфере, совпала с аналогичной оценкой для одиночной проекции $f(v) = \langle u_1, v\rangle$ в исходной размерности при том же фиксированном пороге $\varepsilon > 0$?

4. Представьте, что при проектировании слоя эмбеддингов размерности d необходимо сформировать словарь из M единичных векторов признаков так, чтобы взаимная интерференция (проекция) между любыми двумя различными векторами не превышала допустимого уровня шума: $|\langle u_i, u_j\rangle| \leq \varepsilon$.

   Анализ распределения случайных векторов на гиперсфере показывает, что для *одной конкретной пары* вероятность нарушения этого условия экспоненциально мала и оценивается сверху величиной $2\exp\left(-\frac{d\varepsilon^2}{2}\right)$. Однако итоговая теоретическая гарантия существования всей совокупности таких векторов обеспечивает емкость словаря лишь масштаба $M < \exp\left(\frac{d\varepsilon^2}{4}\right)$.

   Объясните, какая вероятностно-комбинаторная причина приводит к переходу от делителя 2 к делителю 4 в показателе экспоненты при переходе от отдельной пары ко всему словарю (ответ сформулируйте в 1–3 предложениях).

5. Инженер оптимизирует RAG-систему и переводит векторное хранилище с модели эмбеддингов размерности $d_1 = 256$ на модель размерности $d_2 = 4096$. Для старой модели эмпирически был установлен порог косинусного сходства $\tau_1 = 0.20$, гарантирующий заданный уровень статистической значимости (z-оценку) при отклонении нулевой гипотезы о семантической несвязанности (случайном шуме).

Какое пороговое значение косинусного сходства τ_2 следует установить для новой модели, чтобы сохранить точно такую же z-оценку для фильтрации случайного шума при условии, что векторные пространства обеих моделей центрированы?

6. Инженер тестирует алгоритм k-NN для поиска похожих векторов в пространстве размерности $d = 1024$ на двух выборках одинакового объема:

   1. Синтетические векторы, координаты которых генерируются независимо из некоторого базового распределения с конечными моментами.
   2. Эмбеддинги текстовых документов, полученные с помощью предобученной языковой модели.

   В первом случае алгоритм демонстрирует полную неустойчивость: даже минимальный численный шум в векторе запроса кардинально меняет состав найденных k ближайших соседей, делая ранжирование бессмысленным. Во втором же случае алгоритм работает стабильно и успешно выделяет релевантные документы.

   Объясните геометрическую причину столь разного поведения алгоритма при одной и той же размерности пространства признаков.

7. Инженер разрабатывает интерпретируемую модификацию модели LLaMA-3-8B ($d = 4096$) и пытается полностью исключить интерференцию признаков в Residual Stream, потребовав строгой попарной ортогональности направлений для всех концептов ($\langle w_i, w_j \rangle = 0$ при $i \neq j$). Чтобы вместить свыше 10^5 необходимых синтаксических и фактологических признаков без расширения размерности d, он предлагает пропорционально увеличить число слоев сети (блоков Attention и MLP).

   Объясните в 1–3 предложениях, почему наращивание глубины архитектуры принципиально не позволит разрешить данный парадокс размерности, и укажите точное максимальное число взаимно неинтерферирующих признаков, которое Residual Stream сможет одновременно переносить между слоями.

8. Нейросеть с размерностью пространства активаций $d = 1024$ представляет признаки в виде квазиортогональных единичных направлений $\{w_i\}_{i=1}^{M}$, где общее число признаков $M = 100\,000$, а дисперсия попарных скалярных произведений различных векторов составляет порядка $1/d$. Вектор активаций формируется как сумма направлений одновременно активных признаков с единичной интенсивностью: $x = \sum_{j \in S} w_j$, где $|S| = k$.

   При обработке данных из некоторого специфического домена среднее число одновременно активных признаков составило $k = 1200$. Объясните (в 1–2 предложениях), почему декодирование отдельного признака $i \in S$ с помощью линейной проекции $\widehat{f}_i = \langle x, w_i \rangle$ в этом домене потерпит неудачу, несмотря на то что число активных признаков все еще пренебрежимо мало относительно их общего запаса ($k \ll M$).

9. В модели со скрытым состоянием размерности $d = 4096$ словарь семантических признаков хранится в режиме суперпозиции с единичными векторами направлений $w_j \in \mathbb{S}^{d-1}$. Для текущего входа вектор истинных признаков разрежен: активно ровно $k = 64$ концепта, причем каждый активный признак имеет единичную силу ($f_j = 1.0$).

Для считывания признака следующий слой вычисляет проекцию $\widehat{f}_i = \langle w_i, x \rangle$ и применяет нелинейную фильтрацию $\widetilde{f}_i = \mathrm{ReLU}(\widehat{f}_i - b)$, где порог отсечения b выбран равным удвоенному стандартному отклонению шума перекрестной интерференции неактивного признака ($2\,\mathrm{std}(\eta_i)$).

Какое числовое значение активации $\widetilde{f}_i$ будет получено на выходе фильтра для активного признака i при условии, что шум интерференции от остальных активных признаков равен своему математическому ожиданию ($\eta_i = \mathbb{E}[\eta_i] = 0$)?

10. Для подавления нежелательного концепта A инженеры определили в скрытом слое размерности d все отдельные нейроны, значения активаций которых положительны ($x_k > 0$) при наличии концепта A, и принудительно занулили их ($x_k = 0$). В результате модель перестала воспроизводить концепт A, однако одновременно потеряла способность корректно обрабатывать семантически независимые от него паттерны (например, синтаксис языка Python или факты об античной истории).

    Опираясь на геометрическое представление активации нейрона как скалярного произведения вектора скрытого состояния на базисный вектор e_k ($x_k = \langle e_k, x \rangle$), объясните в 1–3 предложениях, почему такое вмешательство неизбежно разрушает представление посторонних концептов.

11. В классической архитектуре Sparse Autoencoder (SAE) декодер восстанавливает плотный вектор активаций языковой модели как линейную комбинацию моносемантичных направлений словаря:

$$\widehat{x} = \sum_{i=1}^{D} f_i(x) d_i + b_{\mathrm{dec}},$$

    а обучение проводится минимизацией функционала потерь:

$$\mathcal{L}_{\mathrm{SAE}} = \|x - \widehat{x}\|_2^2 + \lambda \sum_{i=1}^{D} |f_i(x)|$$

    При этом на направления словаря накладывается жесткое геометрическое ограничение единичной длины: $\|d_i\|_2 = 1$.

    Представьте, что инженер при реализации обучения забыл зафиксировать норму векторов d_i, позволив им свободно масштабироваться в процессе оптимизации. К какому вырожденному поведению для значений норм $\|d_i\|_2$ и величин активаций $f_i(x)$ неизбежно приведет градиентный спуск, и почему слагаемое ошибки реконструкции $\|x - \widehat{x}\|_2^2$ не сможет этому воспрепятствовать?