Концентрация меры на сфере, суперпозиция и Sparse Autoencoders в LLM

Введение и постановка проблемы

Современные большие языковые модели (LLM) — такие как GPT-4, Claude 3.5 или LLaMA-3 — демонстрируют впечатляющие способности к рассуждению, фактологическому анализу и генерации кода. Однако их внутреннее устройство долгое время оставалось «черным ящиком». Векторы скрытых состояний (активаций) имеют фиксированную размерность порядка нескольких тысяч чисел, при этом модель способна распознавать, комбинировать и оперировать десятками миллионов различных понятий.

Каким образом в ограниченном пространстве активаций удается упаковать практически неограниченный спектр знаний? Ответ на этот вопрос объединяет классические разделы функционального анализа и теории вероятностей в банаховых пространствах (в частности, феномен **концентрации меры**) с передовыми исследованиями 2023–2024 годов в области интерпретируемости нейронных сетей (**mechanistic interpretability**).

Содержание

1. **Геометрический фундамент:** поведение евклидова пространства при стремлении размерности к бесконечности ($d \to \infty$), свойства единичного шара B^d и единичной гиперсферы $\mathbb{S}^{d-1} \subset \mathbb{R}^d$.
2. **Математический парадокс размерности:** теоремы об упаковке и возникновение экспоненциально большого числа почти ортогональных направлений при ослаблении строгой ортогональности всего на малую величину ε.
3. **Практические следствия для анализа данных:**
   - Статистическое обоснование надежности метрики косинусной близости в векторных базах данных и RAG-системах.
   - Деградация метрических контрастов («проклятие размерности») для алгоритмов поиска ближайших соседей (k-NN) по теореме Бейера.
4. **Применение в Deep Learning:**
   - **Гипотеза суперпозиции (Superposition Hypothesis):** представление моделью $M \gg d$ семантических признаков в d-мерном пространстве.
   - **Полисемантичность нейронов:** почему попытка интерпретировать отдельные нейроны как отдельные понятия математически несостоятельна.
   - **Sparse Autoencoders (SAE):** математика и архитектура разреженных автоэнкодеров (Anthropic, OpenAI), позволяющих факторизовать скрытые слои LLM на миллионы интерпретируемых моносемантичных концептов, а также методы контроля безопасности (*feature steering* и *feature ablation*).

Интуиция высокой размерности: где сосредоточен объем?

Ловушка двумерной и трехмерной интуиции

Человеческая интуиция сформирована пространствами $\mathbb{R}^2$ и $\mathbb{R}^3$. Мы привыкли считать, что объем тела равномерно распределен по его внутренности, а сфера — это лишь оболочка шара. Однако в пространствах высокой размерности $\mathbb{R}^d$ при $d \gg 1$ геометрия евклидовых тел претерпевает радикальные качественные изменения: привычные геометрические тела ведут себя контринтуитивно.

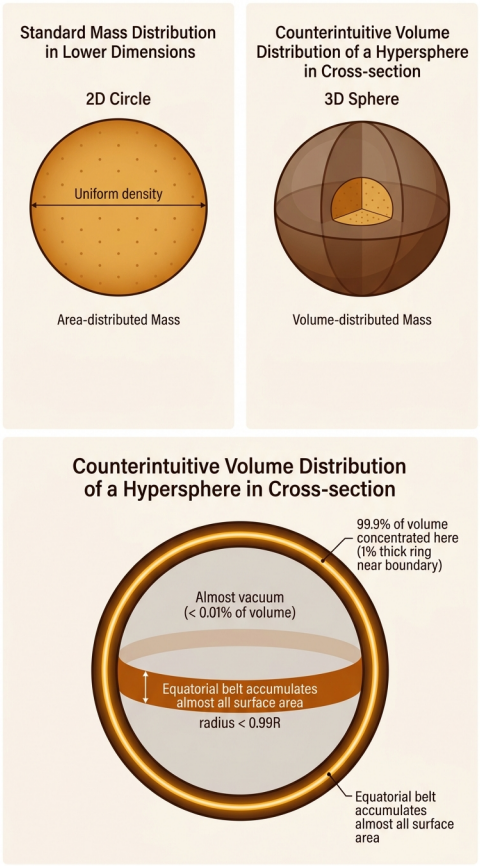


Рис. 1: Ловушка двумерной и трехмерной интуиции

Рассмотрим два базовых объекта:

- **Единичный замкнутый шар:** $B^d = \{x \in \mathbb{R}^d : \|x\|_2 \leq 1\}$;
- **Единичная гиперсфера:** $\mathbb{S}^{d-1} = \partial B^d = \{x \in \mathbb{R}^d : \|x\|_2 = 1\}$.

Объем многомерного шара

Объем d-мерного шара радиуса R задается формулой:

$$V_d(R) = C_d R^d, \quad \text{где } C_d = \frac{\pi^{d/2}}{\Gamma(d/2+1)}$$

Здесь $\Gamma(z) = \int_0^\infty t^{z-1} e^{-t}\, dt$ — гамма-функция Эйлера. Заметим два фундаментальных аспекта:

1. Константа C_d стремительно убывает к нулю при $d \to \infty$ из-за сверхэкспоненциального роста гамма-функции ($\Gamma(n+1) = n! \approx \sqrt{2\pi n}(n/e)^n$ по формуле Стирлинга). Объем единичного шара в $\mathbb{R}^{100}$ практически равен нулю по сравнению с объемом описанного вокруг него куба $[-1, 1]^d$, чей объем равен 2^d.
2. Зависимость объема от радиуса строго масштабируется как R^d.

Феномен тонкой оболочки (Thin Shell)

Исследуем, какая доля объема шара сосредоточена у его границы. Выделим сферический слой (оболочку) толщиной εR непосредственно под внешней поверхностью шара, где $\varepsilon \in (0, 1)$ — сколь угодно малая константа. Внутренняя часть этого шара представляет собой концентрический шар радиуса $(1-\varepsilon)R$.

Вычислим отношение объема внешнего слоя к полному объему шара:

$$\frac{V_d(R) - V_d((1-\varepsilon)R)}{V_d(R)} = \frac{C_d R^d - C_d(1-\varepsilon)^d R^d}{C_d R^d} = 1 - (1-\varepsilon)^d$$

Воспользуемся стандартным аналитическим неравенством $1 - \varepsilon \leq e^{-\varepsilon}$ при $\varepsilon \in (0, 1)$. Тогда:

$$(1-\varepsilon)^d \leq e^{-\varepsilon d} \xrightarrow{d \to \infty} 0$$

Следовательно:

$$\lim_{d \to \infty} \left[1 - (1-\varepsilon)^d\right] = 1$$

Численный пример: Пусть размерность пространства составляет $d = 1000$ (что даже меньше типичной размерности скрытого слоя современных трансформеров), а толщина слоя — всего $\varepsilon = 0.01$ (то есть 1% от радиуса). Доля объема, заключенная в этом тончайшем приповерхностном слое:

$$1 - (1 - 0.01)^{1000} = 1 - (0.99)^{1000} \approx 1 - 4.317 \times 10^{-5} \approx 0.999957 \quad (> 99.995\%)$$

Геометрический вывод: Высокоразмерный шар внутри практически «пуст». Он ведет себя не как твердое однородное тело (например, яблоко или бильярдный шар), а как сверхтонкий мыльный пузырь. Если

сэмплировать точку равномерно из объема шара B^d, с подавляющей вероятностью ее евклидова норма будет лежать в диапазоне $[1 - \mathcal{O}(1/d), 1]$.

Почему в трансформерах нормализация вектора не разрушает информацию.

В современных архитектурах (LLaMA-3, Mistral, Qwen) перед каждым блоком Attention и MLP применяется слой **RMSNorm**:

$$\text{RMSNorm}(x) = \frac{x}{\sqrt{\frac{1}{d}\sum_{i=1}^{d} x_i^2 + \epsilon}} \odot \gamma$$

Для инженера, мыслящего в 2D/3D, деление на норму выглядит как грубое проецирование, «стирающее» информацию об амплитуде вектора.

Однако феномен *тонкой оболочки* доказывает: в пространстве $d = 4096$ длина вектора случайных независимых признаков детерминированно сконцентрирована в тончайшем слое толщиной $\sim 1/\sqrt{d}$. Норма вектора активаций практически константна по своей природе. RMSNorm лишь убирает микроскопический паразитный дрейф масштаба, проецируя вектор на единичную сферу $\mathbb{S}^{d-1}$, где и разворачивается вся содержательная геометрия трансформера. Разница между токенами заключается не в их *длине*, а в их *направлении на гиперсфере*.

Экваториальный пояс гиперсферы

Второй парадокс связан с распределением площади поверхности самой гиперсферы $\mathbb{S}^{d-1}$. Зафиксируем произвольный единичный вектор направления («северный полюс») $p \in \mathbb{S}^{d-1}$.

Площадь сечения сферы гиперплоскостью, ортогональной p на расстоянии x_1 от центра, пропорциональна $(1 - x_1^2)^{(d-1)/2}$. Интегрирование показывает, что подавляющая часть площади поверхности $\mathbb{S}^{d-1}$ сосредоточена в узком поясе вдоль экватора:

$$|x_1| = |\langle x, p \rangle| \leq \frac{c}{\sqrt{d}}$$

Какую бы ось координат или произвольное направление мы ни выбрали в качестве полюса, почти вся поверхность сферы стянута к соответствующему экватору на расстояние порядка $\mathcal{O}(1/\sqrt{d})$.

Скалярное произведение случайных векторов: вывод $\langle u, v \rangle \sim \mathcal{N}(0, 1/d)$

Постановка задачи

Пусть $u, v \sim \text{Unif}(\mathbb{S}^{d-1})$ — два независимых случайных вектора, равномерно распределенных на единичной гиперсфере в $\mathbb{R}^d$. Исследуем распределение их скалярного произведения $\langle u, v \rangle = \cos\theta$.

В силу изотропности (инвариантности относительно вращений группы $SO(d)$) равномерной меры на сфере, распределение $\langle u, v \rangle$ не зависит от конкретной ориентации первого вектора. Зафиксируем вектор u вдоль первой координатной оси:

$$u = (1, 0, 0, \ldots, 0)^T$$

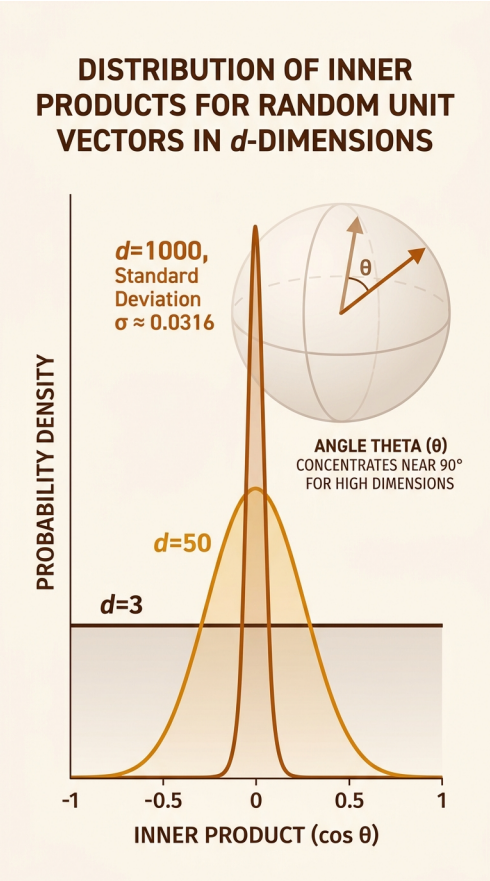


Рис. 2: Распределение скалярного произведения равномерно распределенных единичных векторов на сфере

Тогда скалярное произведение тождественно равно первой координате вектора v:

$$\langle u, v\rangle = u^T v = 1 \cdot v_1 + \sum_{i=2}^{d} 0 \cdot v_i = v_1$$

Генерация равномерного распределения на гиперсфере

Стандартный способ сэмплирования точки $v \sim \text{Unif}(\mathbb{S}^{d-1})$ опирается на сферическую симметрию многомерного нормального распределения.

Пусть $X = (X_1, \dots, X_d)^T \sim \mathcal{N}(0, I_d)$ — вектор, составленный из d независимых стандартных нормальных случайных величин $X_i \sim \mathcal{N}(0,1)$. Плотность вероятности вектора X равна:

$$p_X(x) = \prod_{i=1}^{d} \frac{1}{\sqrt{2\pi}} e^{-x_i^2/2} = \frac{1}{(2\pi)^{d/2}} \exp\left(-\frac{1}{2}\sum_{i=1}^{d} x_i^2\right) = \frac{1}{(2\pi)^{d/2}} \exp\left(-\frac{\|x\|_2^2}{2}\right)$$

Плотность зависит исключительно от евклидовой нормы $\|x\|_2$, что доказывает полную инвариантность распределения относительно любых ортогональных преобразований.

Нормализуем вектор X:

$$v = \frac{X}{\|X\|_2} \sim \text{Unif}(\mathbb{S}^{d-1})$$

Тогда первая координата вектора v (и, соответственно, скалярное произведение) выражается как:

$$v_1 = \frac{X_1}{\sqrt{\sum_{i=1}^{d} X_i^2}} = \frac{X_1}{\sqrt{d \cdot \left(\frac{1}{d}\sum_{i=1}^{d} X_i^2\right)}}$$

Точный расчет моментов при любом конечном d

Вычислим математическое ожидание и дисперсию v_1: 1. **Математическое ожидание:** плотность распределения X_1 симметрична относительно нуля, следовательно, распределение v_1 симметрично относительно нуля:

$$\mathbb{E}[v_1] = \mathbb{E}[\langle u, v\rangle] = 0$$

2. **Дисперсия:** Вектор v лежит на сфере $\mathbb{S}^{d-1}$, поэтому сумма квадратов его компонент строго равна 1:

$$\|v\|_2^2 = \sum_{i=1}^{d} v_i^2 = 1 \implies \mathbb{E}\left[\sum_{i=1}^{d} v_i^2\right] = \sum_{i=1}^{d} \mathbb{E}[v_i^2] = 1$$

В силу симметрии сферы все координаты равноправны: $\mathbb{E}[v_1^2] = \mathbb{E}[v_2^2] = \dots = \mathbb{E}[v_d^2]$. Отсюда:

$$d \cdot \mathbb{E}[v_1^2] = 1 \implies \mathbb{E}[v_1^2] = \frac{1}{d}$$

Поскольку $\mathbb{E}[v_1] = 0$, точная дисперсия для **любой** размерности $d \geq 1$:

$$\text{Var}(\langle u, v\rangle) = \text{Var}(v_1) = \mathbb{E}[v_1^2] - (\mathbb{E}[v_1])^2 = \frac{1}{d}$$

Асимптотическое распределение при $d \to \infty$

Преобразуем выражение для $\sqrt{d} \cdot v_1$:

$$\sqrt{d} \cdot v_1 = \frac{X_1}{\sqrt{\frac{1}{d}\sum_{i=1}^{d} X_i^2}}$$

1. Величины X_i^2 являются независимыми одинаково распределенными случайными величинами с $\mathbb{E}[X_i^2] = 1$ и $\mathrm{Var}(X_i^2) = 2$. По усиленному закону больших чисел (УЗБЧ):

$$\frac{1}{d}\sum_{i=1}^{d} X_i^2 \xrightarrow{a.s.} \mathbb{E}[X_1^2] = 1 \quad \text{при } d \to \infty$$

2. Функция $g(t) = 1/\sqrt{t}$ непрерывна в точке $t = 1$, поэтому по теореме о непрерывном отображении:

$$\frac{1}{\sqrt{\frac{1}{d}\sum_{i=1}^{d} X_i^2}} \xrightarrow{P} 1$$

3. Случайная величина $X_1 \sim \mathcal{N}(0,1)$ не зависит от размерности d. Применяя **теорему Слуцкого** (умножение последовательности, сходящейся по распределению, на последовательность, сходящуюся по вероятности к константе), получаем:

$$\sqrt{d} \cdot \langle u, v \rangle = X_1 \cdot \left(\frac{1}{d}\sum_{i=1}^{d} X_i^2\right)^{-1/2} \xrightarrow{d} X_1 \cdot 1 \sim \mathcal{N}(0,1)$$

Таким образом, при больших d скалярное произведение двух случайных векторов единичной длины распределено практически неотличимо от нормального закона:

$$\langle u, v \rangle \sim \mathcal{N}\left(0,\ \frac{1}{d}\right)$$

Следствие для типичного угла: В размерности $d = 4096$ (размерность эмбеддингов LLaMA-3-8B) стандартное отклонение составляет:

$$\sigma = \frac{1}{\sqrt{4096}} = \frac{1}{64} \approx 0.0156$$

С вероятностью более 99.7% (правило трех сигм) абсолютное значение скалярного произведения не превысит $3 \times 0.0156 = 0.0468$. Угол между двумя случайно выбранными векторами лежит в узком диапазоне:

$$\theta = \arccos(\pm 0.0468) \in [87.3^\circ,\ 92.7^\circ]$$

Случайные векторы в пространствах высокой размерности практически строго ортогональны.

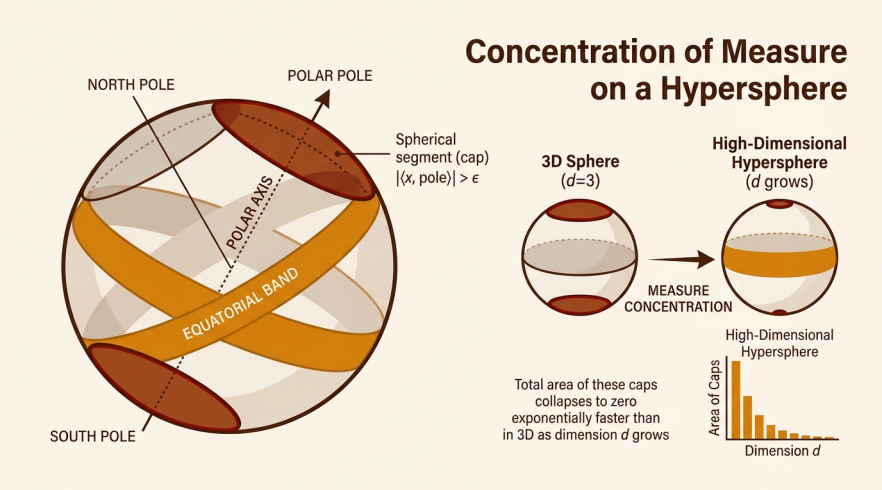


Рис. 3: Иллюстрация 4

Концентрация меры на сфере и экспоненциальные хвосты

Неравенство Леви для гиперсферы

Центральная предельная теорема дает информацию о локальном поведении скалярного произведения около нуля. Однако для теоретических гарантий устойчивости нейросетей критически важны оценки **хвостов распределения** (вероятностей больших уклонений). Фундаментальным аппаратом здесь служит теория концентрации меры, заложенная Пьером Леви и развитая Виталием Мильманом в контексте локальной теории банаховых пространств.

Теорема (Неравенство Леви на сфере): Пусть $\mathbb{S}^{d-1}$ снабжена геодезической метрикой (или евклидовой хордовой метрикой) и нормализованной мерой Хаара σ_{d-1} ($\sigma_{d-1}(\mathbb{S}^{d-1}) = 1$). Пусть $f : \mathbb{S}^{d-1} \to \mathbb{R}$ — произвольная L-липшицева функция, то есть:

$$|f(x) - f(y)| \leq L\|x - y\|_2 \quad \forall x, y \in \mathbb{S}^{d-1}$$

Тогда для любого порога уклонения $\varepsilon > 0$:

$$\mathbb{P}\left(|f(v) - \mathbb{E}[f]| \geq \varepsilon\right) \leq 2\exp\left(-\frac{c\,d\,\varepsilon^2}{L^2}\right)$$

где $c > 0$ — абсолютная константа (в евклидовой метрике часто принимается $c = 1/2$).

Применение к функции скалярного произведения

Рассмотрим функцию ортогонального проектирования на фиксированный вектор $u \in \mathbb{S}^{d-1}$:

$$f(v) = \langle u, v \rangle$$

Проверим свойство Липшица. По неравенству Коши — Буняковского — Шварца:

$$|f(v_a) - f(v_b)| = |\langle u, v_a \rangle - \langle u, v_b \rangle| = |\langle u, v_a - v_b \rangle| \leq \|u\|_2 \cdot \|v_a - v_b\|_2$$

Так как $\|u\|_2 = 1$, константа Липшица тождественно равна $L = 1$.

Математическое ожидание функции равно нулю: $\mathbb{E}[f(v)] = \mathbb{E}[\langle u, v\rangle] = 0$. Подставляя $L = 1$ в неравенство Леви, получаем строгую субгауссовскую оценку хвоста:

$$\mathbb{P}\left(|\langle u, v\rangle| \geq \varepsilon\right) \leq 2\exp\left(-\frac{d\,\varepsilon^2}{2}\right)$$

Сила экспоненциального затухания

Геометрически множество $\{v \in \mathbb{S}^{d-1} : |\langle u, v\rangle| \geq \varepsilon\}$ представляет собой объединение двух сферических сегментов (шапок) вокруг полюсов $+u$ и $-u$. Неравенство показывает, что суммарная площадь этих шапок убывает экспоненциально по размерности d.

Рассчитаем вероятность уклонения на $\varepsilon = 0.1$ при $d = 4096$: 1. Аргумент экспоненты:

$$\frac{d\,\varepsilon^2}{2} = \frac{4096 \times (0.1)^2}{2} = \frac{4096 \times 0.01}{2} = 20.48$$

2. Итоговая вероятность:

$$\mathbb{P}(|\langle u, v\rangle| \geq 0.1) \leq 2e^{-20.48} \approx 2 \times 1.275 \times 10^{-9} \approx 2.55 \times 10^{-9}$$

Вероятность встретить пару векторов, косинус угла между которыми отклонится от нуля хотя бы на 0.1 (что соответствует углу менее $84.26°$ или более $95.74°$), составляет меньше трех миллиардных долей. Случайные векторы в высоких размерностях не просто некоррелированы в среднем — они гарантированно изолированы в узком экваториальном диапазоне.

Парадокс ортогональности: экспоненциальная емкость

Жесткое ограничение линейной алгебры

В классической линейной алгебре максимальное число попарно строго ортогональных векторов в пространстве $\mathbb{R}^d$ жестко ограничено размерностью этого пространства:

$$\langle u_i, u_j\rangle = 0 \quad \forall i \neq j \implies M \leq d$$

Это фундаментальное следствие линейной независимости: ортогональная система ненулевых векторов всегда линейно независима, а максимальное число линейно независимых векторов в $\mathbb{R}^d$ равно размерности базиса d.

Почти ортогональность (ε-ортогональность)

В реальных нейронных сетях и статистических системах строгое равенство нулю не требуется: достаточно, чтобы взаимное влияние признаков не превышало некоторого допустимого уровня шума $\varepsilon > 0$.

Определение: Семейство единичных векторов $\{u_1, \ldots, u_M\} \subset \mathbb{S}^{d-1}$ называется **попарно ε-ортогональным**, если:

$$|\langle u_i, u_j\rangle| \leq \varepsilon \quad \forall\, i \neq j, \quad i, j \in \{1, \ldots, M\}$$

Теорема об упаковке и вероятностный метод

Сколько таких векторов можно разместить в $\mathbb{R}^d$? Оказывается, емкость возрастает от полиномиальной (d) до **экспоненциальной** от размерности!

Теорема: Существует абсолютная константа $c > 0$ такая, что для любого $\varepsilon \in (0, 1)$ в $\mathbb{R}^d$ существует семейство из M попарно ε-ортогональных единичных векторов, удовлетворяющее соотношению:

$$M \geq \exp\left(c\,\varepsilon^2\,d\right)$$

Конструктивное доказательство через вероятностный метод Эрдеша (Union Bound):

1. Сгенерируем M независимых случайных векторов $u_1, u_2, \ldots, u_M$, равномерно распределенных на гиперсфере $\mathbb{S}^{d-1}$.
2. Рассмотрим неблагоприятное событие: «существует хотя бы одна пара (i, j) с $i \neq j$, для которой нарушается условие ε-ортогональности».
3. Число различных неупорядоченных пар равно $\binom{M}{2} = \frac{M(M-1)}{2} < \frac{M^2}{2}$.
4. Применим неравенство объединения (Union Bound) и оценку Леви:

$$\mathbb{P}\left(\exists\, i < j : |\langle u_i, u_j\rangle| > \varepsilon\right) \leq \sum_{1 \leq i < j \leq M} \mathbb{P}\left(|\langle u_i, u_j\rangle| > \varepsilon\right) <$$

$$< \frac{M^2}{2} \cdot 2\exp\left(-\frac{d\varepsilon^2}{2}\right) = M^2 \exp\left(-\frac{d\varepsilon^2}{2}\right)$$

5. Если суммарная вероятность строго меньше 1, то дополнительное событие («все пары удовлетворяют условию $|\langle u_i, u_j\rangle| \leq \varepsilon$») имеет строго положительную вероятность, а значит, такая конфигурация гарантированно существует:

$$M^2 \exp\left(-\frac{d\varepsilon^2}{2}\right) < 1$$

$$M^2 < \exp\left(\frac{d\varepsilon^2}{2}\right) \implies M < \exp\left(\frac{d\varepsilon^2}{4}\right)$$

Практический масштаб эффекта

Пусть $d = 4096$, а порог допустимого шума задан как $\varepsilon = 0.1$. Подставим значения:

$$M = \exp\left(\frac{4096 \times (0.1)^2}{4}\right) = \exp\left(\frac{40.96}{4}\right) = e^{10.24} \approx 28\,001$$

Вывод: Допустив погрешность взаимной интерференции всего в 10% ($\varepsilon = 0.1$), мы получаем возможность упаковать в 4096-мерное пространство не 4096, а **более 28 тысяч** квазинезависимых направлений. Если увеличить допустимую интерференцию до $\varepsilon = 0.15$:

$$M = \exp\left(\frac{4096 \times 0.0225}{4}\right) = e^{23.04} \approx 10^{10}$$

В пространстве размерности 4096 математически помещаются миллиарды направлений, попарные углы между которыми лежат строго в пределах $[81.37^\circ, 98.63^\circ]$. Это фундаментальный мост к пониманию информационной емкости нейронных сетей.

Следствие 1: Почему косинусная близость надежна в LLM?

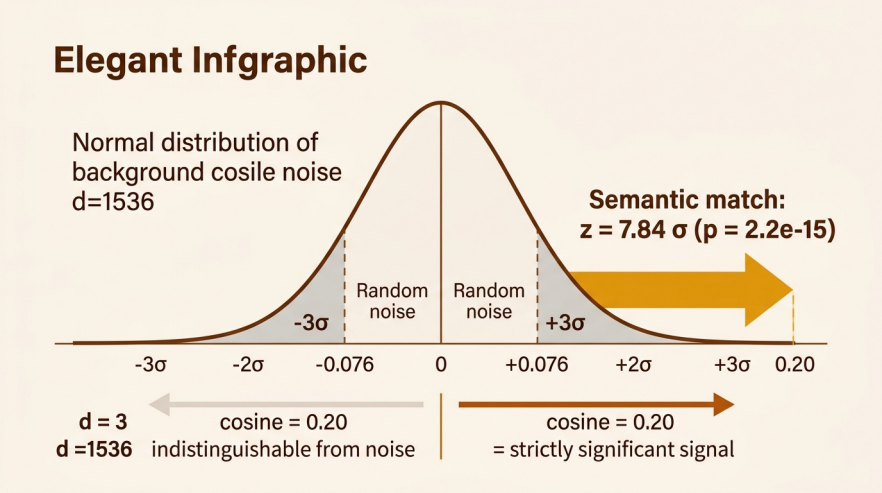


Рис. 4: Распределение косинусной метрики

Косинусная метрика в RAG и семантическом поиске

В информационном поиске, векторных базах данных (Chroma, Pinecone, Qdrant) и конвейерах RAG (Retrieval-Augmented Generation) степень семантической близости текстов оценивается через косинусное сходство их нормализованных векторных эмбеддингов:

$$\cos\theta = \frac{\langle u, v\rangle}{\|u\|_2\|v\|_2} = \langle \tilde{u}, \tilde{v}\rangle$$

где $\tilde{u}, \tilde{v} \in \mathbb{S}^{d-1}$.

Часто у инженеров возникает недоумение: почему при настройке порогов отсечения нерелевантных документов порог косинусного сходства часто устанавливают на уровнях порядка $0.25 - 0.40$? Не является ли значение косинуса 0.20 свидетельством отсутствия связи, ведь в двумерном пространстве $\cos\theta = 0.20$ соответствует углу $\approx 78.5^\circ$, что весьма далеко от параллельности?

Статистическая калибровка гипотезы H_0

Сформулируем строгую нулевую гипотезу H_0: «Два документа семантически не связаны (их векторные представления представляют собой независимый случайный шум на сфере)».

В силу доказанного выше:

$$\cos\theta \mid H_0 \sim \mathcal{N}\left(0,\ \sigma^2\right), \quad \text{где } \sigma = \frac{1}{\sqrt{d}}$$

Рассмотрим популярную эмбеддинг-модель OpenAI `text-embedding-3-small`, для которой размерность пространства составляет $d = 1536$:

$$\sigma = \frac{1}{\sqrt{1536}} \approx 0.025515$$

Вычислим стандартизованную z-оценку для эмпирического значения косинуса $\cos\theta = 0.20$:

$$z = \frac{\cos\theta - \mu_0}{\sigma} = \frac{0.20 - 0}{0.025515} \approx 7.84$$

Вычислим одностороннее p-value для нормального распределения:

$$p = \mathbb{P}(Z \geq 7.84) \approx 2.2 \times 10^{-15}$$

Анализ результата

В физике элементарных частиц критерием открытия новой частицы (например, бозона Хиггса) является порог 5σ ($p \approx 2.87 \times 10^{-7}$). Величина 7.84σ соответствует отклонению, случайное возникновение которого имеет вероятность порядка 10^{-15}.

Таким образом: * В $\mathbb{R}^3$ ($d = 3$): $\sigma = 1/\sqrt{3} \approx 0.577$. Значение $\cos\theta = 0.20$ дает $z = 0.20/0.577 \approx 0.35\sigma$. Это абсолютный шум, не несущий никакой информации. * В $\mathbb{R}^{1536}$: косинус 0.20 — это **колоссальный статистический сигнал**, отвергающий гипотезу некоррелированности на астрономическом уровне достоверности.

Важное инженерное примечание (эффект анизотропии): В реальных языковых моделях векторные представления токенов часто смещены в определенный конус (эффект анизотропии эмбеддингов, при котором средний вектор $\mathbb{E}[v] \neq 0$). Однако после тривиальной процедуры центрирования ($\tilde{v} = v - \bar{v}$) распределение косинусов пар некоррелированных текстов строго ложится на колокол Гаусса с дисперсией $1/d$.

Обратная сторона: «Проклятие размерности» для k-NN

Концентрация евклидовых расстояний

Феномен концентрации меры имеет и обратную, деструктивную сторону, известную в машинном обучении как «проклятие размерности» (Curse of Dimensionality). Он проявляется при попытке использовать методы, опирающиеся на классическое евклидово расстояние $\|X - Y\|_2$ между точками данных.

Пусть $X, Y \in \mathbb{R}^d$ — две независимые случайные точки, координаты которых генерируются независимо из некоторого базового распределения с конечными моментами: $X_i, Y_i \sim P$. Рассмотрим квадрат евклидова расстояния:

$$D^2 = \|X - Y\|_2^2 = \sum_{i=1}^{d} (X_i - Y_i)^2 = \sum_{i=1}^{d} Z_i$$

где $Z_i = (X_i - Y_i)^2$ — независимые одинаково распределенные случайные величины с матожиданием $\mu = \mathbb{E}[Z_1]$ и дисперсией $\sigma^2 = \mathrm{Var}(Z_1)$.

Вычислим математическое ожидание и дисперсию суммарного расстояния:

$$\mathbb{E}[\|X - Y\|_2^2] = \sum_{i=1}^{d} \mathbb{E}[Z_i] = \mu \cdot d = \Theta(d)$$

$$\mathsf{Var}(\|X-Y\|_2^2) = \sum_{i=1}^{d} \mathsf{Var}(Z_i) = \sigma^2 \cdot d = \Theta(d)$$

Вычислим относительный разброс (коэффициент вариации):

$$\mathsf{CV} = \frac{\sqrt{\mathsf{Var}(\|X-Y\|_2^2)}}{\mathbb{E}[\|X-Y\|_2^2]} = \frac{\sigma\sqrt{d}}{\mu d} = \frac{\sigma}{\mu} \cdot \frac{1}{\sqrt{d}} \xrightarrow{d\to\infty} 0$$

По мере роста размерности абсолютная флуктуация расстояния растет как $\sqrt{d}$, однако относительно среднего значения ($\propto d$) разброс исчезающе мал. Квадрат расстояния между **любыми** двумя случайно выбранными точками детерминированно концентрируется вокруг величины μd.

Теорема Бейера (Beyer et al., 1999)

Этот математический факт приводит к полной потере контрастности в метрических пространствах высокой размерности.

Теорема: Пусть $Q \in \mathbb{R}^d$ — фиксированная точка запроса (query), а $X_1, \dots, X_n$ — случайная выборка данных в $\mathbb{R}^d$. Обозначим:

$$\mathsf{dist}_{\mathsf{min}}(Q) = \min_{1\le i\le n} \|X_i - Q\|_2, \quad \mathsf{dist}_{\mathsf{max}}(Q) = \max_{1\le i\le n} \|X_i - Q\|_2$$

Если $\lim_{d\to\infty} \frac{\mathsf{Var}(\|X_1-Q\|_2)}{\mathbb{E}[\|X_1-Q\|_2]} = 0$, то для любого $\varepsilon > 0$:

$$\lim_{d\to\infty} \mathbb{P}\left(\frac{\mathsf{dist}_{\mathsf{max}}(Q) - \mathsf{dist}_{\mathsf{min}}(Q)}{\mathsf{dist}_{\mathsf{min}}(Q)} \le \varepsilon \right) = 1$$

Физический и практический смысл

Относительная разница между расстоянием до *ближайшего соседа* и расстоянием до *самого дальнего объекта выборки* стремится к нулю. Все точки выборки оказываются лежащими на одной и той же гиперсфере относительно точки запроса.

В результате:

1. Алгоритм k ближайших соседей (k-NN) теряет математическую устойчивость: любая малая флуктуация данных или численный шум меняют состав ближайших соседей.
2. Метрические деревья поиска (k-d tree, Ball tree) деградируют до полного перебора $\mathcal{O}(n)$, поскольку гиперсфера запроса пересекает сразу все разбивающие плоскости.

Почему глубокое обучение все же работает? Гипотеза многообразий

Если метрические пространства столь враждебны, почему эмбеддинги трансформеров успешны? Ответ дает **гипотеза многообразий (Manifold Hypothesis)**: данные реального мира (тексты, изображения, аудио) распределены в $\mathbb{R}^d$ не однородно и не изотропно. Они локализованы на низкоразмерных нелинейных подмногообразиях $\mathcal{M} \subset \mathbb{R}^d$ размерности $d_{\text{eff}} \ll d$. Вдоль этих подмногообразий метрика сохраняет высокую контрастность, а окружающее пустое высокоразмерное пространство защищает данные от взаимных наложений.

Проблема емкости в LLM: парадокс размерности

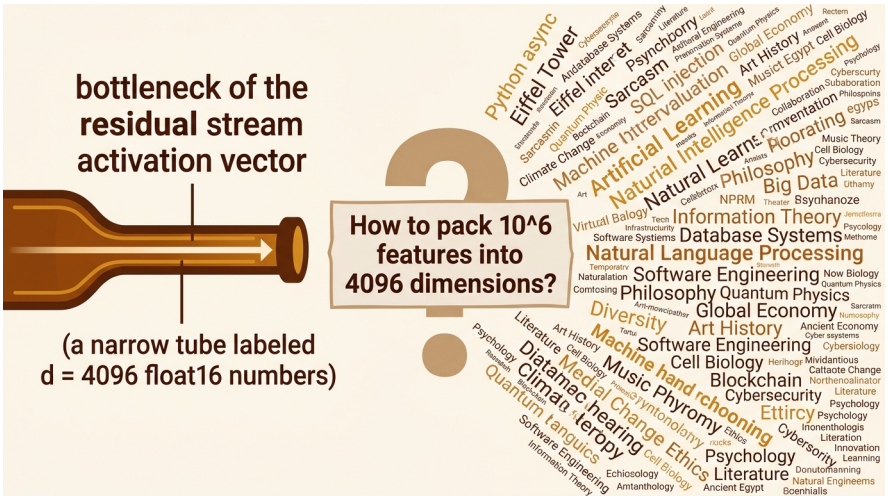


Рис. 5: Проблема емкости в LLM: парадокс размерности

Архитектура Residual Stream

В современных архитектурах трансформеров центральным информационным каналом является **Residual Stream** (остаточный поток). Это вектор активаций $x \in \mathbb{R}^d$, который проходит через все слои сети сквозным образом:

$$x_l = x_{l-1} + \text{Attention}(x_{l-1}) + \text{MLP}(x_{l-1})$$

Слои внимания и полносвязные блоки лишь считывают информацию из этого потока и записывают в него добавки через операцию сложения.

Размерности residual stream в современных открытых и закрытых моделях строго фиксированы:

- **LLaMA-3-8B:** $d = 4096$;
- **LLaMA-3-70B:** $d = 8192$;
- **GPT-4 (OpenAI):** $d \approx 8192 - 12288$.

Информационная нагрузка на модель

Чтобы генерировать связный и осмысленный текст, трансформер должен одновременно удерживать в векторе текущего токена информацию о десятках различных аспектов:

1. **Фактологические знания:** биографии миллионов людей, географические точки, исторические события, даты, химические формулы (потенциально $> 10^7$ сущностей).
2. **Синтаксис и морфология:** часть речи, падеж, род, число, синтаксическая роль токена, глубина вложенности скобок в коде ($> 10^5$ правил).
3. **Контекст и прагматика:** тема диалога, стиль общения (формальный, ироничный), целевая аудитория, язык программирования, текущая системная роль.
4. **Безопасность:** наличие попыток джейлбрейка, токсичности, генерации вредоносного кода.

Крушение наивной гипотезы «Один нейрон = одно понятие»

Ранние гипотезы в нейробиологии и машинном обучении предполагали существование выделенных детекторов — так называемых «нейронов бабушки» (Grandmother Cells), когда отдельная клетка или ней-

рон сети активируется строго на один специфический объект (например, на портрет бабушки или слово «квантовый»).

Если бы эта гипотеза была верна для искусственных нейронных сетей, пространство активаций требовало бы взаимной ортогональности признаков:

$$\langle w_i, w_j \rangle = 0 \quad \forall i \neq j$$

Однако в векторе размерности $d = 4096$ линейная алгебра позволяет сформировать не более **4096** ортогональных координатных осей.

Возникает фундаментальный **парадокс размерности**:

$$\text{Емкость базиса } (4096) \ll \text{Требуемое число концептов } (10^7)$$

Если бы сеть выделяла под каждое понятие отдельный нейрон, она была бы катастрофически ограничена в своей выразительной силе. Каким образом модель разрешает это противоречие?

Гипотеза суперпозиции (Superposition Hypothesis)

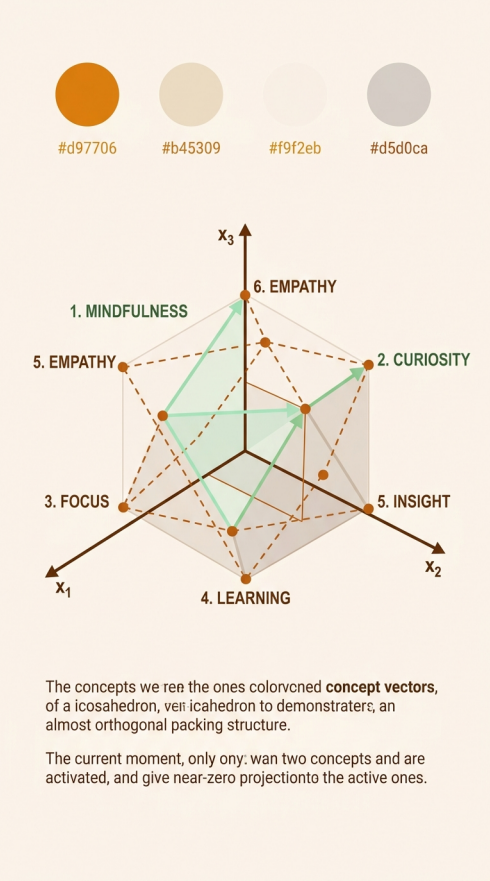


Рис. 6: Иллюстрация 9

Формулировка гипотезы

Фундаментальный ответ на парадокс размерности был предложен исследовательской группой Anthropic в знаковой работе *«Toy Models of Superposition»* (Elhage et al., 2022):

> **Гипотеза суперпозиции:** Нейронные сети представляют значительно больше семантических признаков, чем имеют измерений в пространстве активаций ($M \gg d$), упаковывая их в виде неортогональных, но почти ортогональных направлений. Суперпозиция возможна благодаря тому, что реальный мир разрежен, а геометрия высоких размерностей обладает экспоненциальной емкостью.

Три столпа суперпозиции

Гипотеза опирается на три математических и эмпирических основания:

1. **Линейное представление признаков (Linear Representation Hypothesis):** Признаки в нейросети представлены линейными одномерными подпространствами (направлениями). Для каждого семантического понятия i существует единичный вектор направления $w_i \in \mathbb{S}^{d-1}$. Степень выраженности (наличия) этого признака в контексте задается неотрицательным скаляром $f_i \geq 0$.
2. **Почти ортогональность направлений:** Сеть не раскладывает признаки по базисным осям нейронов. Вместо этого направления $\{w_1, \dots, w_M\}$ образуют переполненную систему векторов на гиперсфере $\mathbb{S}^{d-1}$. Благодаря экспоненциальной емкости почти ортогональной упаковки при $d = 4096$ модель может разместить сотни тысяч направлений так, чтобы их попарные скалярные произведения оставались малыми:
$$\langle w_i, w_j \rangle \approx 0 \quad (\text{с дисперсией } \sim 1/d)$$
3. **Разреженность реального мира (Feature Sparsity):** Это решающий фактор. Хотя модель способна распознавать $M \sim 10^7$ понятий, в любом конкретном предложении или токене одновременно активно лишь крайне малое число признаков:
$$|S| = k \ll d \ll M$$
Пример: если в текущем окне обрабатывается текст о дифференциальных уравнениях, признаки «рецепт пасты болоньезе», «правила хоккея» и «синтаксис CSS» имеют нулевые активации ($f_j = 0$).

Математика суперпозиции: подавление шума интерференции

Математическая модель скрытого состояния

Пусть в модели задан словарь из M семантических признаков с единичными векторами направлений $w_1, \dots, w_M \in \mathbb{S}^{d-1}$. Пусть $f = (f_1, \dots, f_M)^T \in \mathbb{R}^M_{\geq 0}$ — вектор истинных активаций признаков для текущего входа, причем вектор f разрежен: носитель $S = \{j : f_j > 0\}$ имеет мощность $|S| = k \ll d$.

Скрытое состояние сети $x \in \mathbb{R}^d$ формируется как линейная комбинация активных признаков:

$$x = \sum_{j=1}^{M} f_j w_j = \sum_{j \in S} f_j w_j = Wf$$

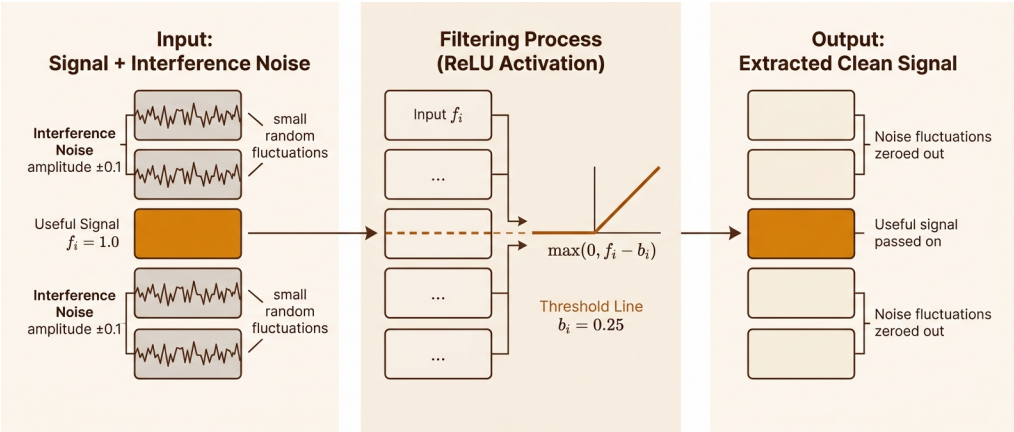


Рис. 7: Иллюстрация 10

где $W = [w_1 \,|\, w_2 \,|\, \ldots \,|\, w_M] \in \mathbb{R}^{d \times M}$ — матрица направлений признаков.

Процесс считывания признака и шум интерференции

Когда следующему слою нейросети требуется извлечь значение конкретного признака i, он выполняет операцию линейной проекции вектора активаций x на соответствующее направление w_i:

$$\hat{f}_i = \langle w_i, x \rangle = w_i^T \left(\sum_{j=1}^{M} f_j w_j \right) = \sum_{j=1}^{M} f_j \langle w_i, w_j \rangle$$

Разобьем эту сумму на целевой сигнал и влияние остальных признаков:

$$\hat{f}_i = f_i \cdot \underbrace{\|w_i\|_2^2}_{=1} + \sum_{j \neq i} f_j \langle w_i, w_j \rangle = f_i + \eta_i$$

Величина $\eta_i = \sum_{j \neq i, j \in S} f_j \langle w_i, w_j \rangle$ называется **шумом перекрестной интерференции (Crosstalk Noise)**.

Статистический расчет шума

Оценим математические характеристики шума интерференции η_i:

1. **Математическое ожидание:** так как направления других признаков изотропно распределены относительно w_i, $\mathbb{E}[\langle w_i, w_j \rangle] = 0$, следовательно:

$$\mathbb{E}[\eta_i] = \sum_{j \neq i, j \in S} f_j \mathbb{E}[\langle w_i, w_j \rangle] = 0$$

2. **Дисперсия:** В предположении некоррелированности направлений разных признаков:

$$\mathrm{Var}(\eta_i) = \sum_{j \in S \setminus \{i\}} f_j^2 \cdot \mathrm{Var}(\langle w_i, w_j \rangle) = \sum_{j \in S \setminus \{i\}} f_j^2 \cdot \frac{1}{d} = \frac{1}{d} \sum_{j \in S \setminus \{i\}} f_j^2$$

Обозначим через $\overline{f^2} = \frac{1}{k}\sum_{j\in S} f_j^2$ средний квадрат активации активных признаков. Тогда:

$$\mathrm{Var}(\eta_i) \approx \frac{k}{d} \cdot \overline{f^2}$$

3. **Амплитуда шума (стандартное отклонение):**

$$\mathrm{std}(\eta_i) = \sqrt{\mathrm{Var}(\eta_i)} \approx \sqrt{\frac{k}{d}} \cdot \mathrm{RMS}(f)$$

где $\mathrm{RMS}(f) = \sqrt{\overline{f^2}}$ — среднеквадратичное значение амплитуды признаков.

Численная оценка и нелинейная фильтрация через ReLU

Пусть размерность модели $d = 4096$, а число одновременно активных концептов в токене равно $k = 50$. Тогда относительный уровень шума интерференции составляет:

$$\sqrt{\frac{k}{d}} = \sqrt{\frac{50}{4096}} = \sqrt{0.0122} \approx 0.11 \implies \approx 11\% \text{ от средней амплитуды}$$

Если признак i **не активен** ($f_i = 0$), проекция $\hat{f}_i$ представляет собой чисто случайную величину с нулевым средним и стандартным отклонением $\approx 0.11 \cdot \mathrm{RMS}(f)$. Если признак i **активен** ($f_i \sim 1.0$), то сигнал f_i существенно превосходит шум интерференции.

Чтобы окончательно устранить шум, модели необходима нелинейная операция с пороговым отсечением:

$$\tilde{f}_i = \mathrm{ReLU}(\hat{f}_i - b_i)$$

Подбирая смещение $b_i \approx \alpha\sqrt{k/d}$, сеть полностью зануляет интерференционный шум неактивных признаков, пропуская только истинные активные сигналы.

Шум интерференции и феномен «Language Bleeding» Пусть модель генерирует текст на **русском языке**. В текущий момент активно подмножество семантических и синтаксических концептов S_{ru}, $|S_{\text{ru}}| = k \approx 60$. Признаки, отвечающие за грамматику **японского языка**, в данном контексте неактивны ($f_{\text{ja}} = 0$).

Однако при считывании проекции на японский признак:

$$\hat{f}_{\text{ja}} = 0 + \sum_{j\in S_{\text{ru}}} f_j \langle w_{\text{ja}}, w_j\rangle = \eta_{\text{cross}}$$

Вектор скрытого состояния генерирует шум перекрестной интерференции с амплитудой $\approx \sqrt{k/d} \approx \sqrt{60/4096} \approx 0.12$.

В норме функция активации $\mathrm{ReLU}(\hat{f}_{\text{ja}} - b)$ отсекает этот шум, поскольку порог смещения установлен на уровне $b \approx 0.25$. Однако, если модель подвергается квантованию до низких битрейтов (например, 2-bit или 3-bit quantization) или температура сэмплинга завышена, пороги фильтрации размываются. Шум преодолевает барьер, и возникает известный в инженерии артефакт **Language Bleeding**: при

ответе на русском языке модель внезапно вставляет китайский иероглиф или завершает предложение японской точкой-кружком вместо стандартной точки. Это прямое проявление неудаленного шума η_i в суперпозиции признаков.

Феномен полисемантичности: почему отдельные нейроны бесполезны

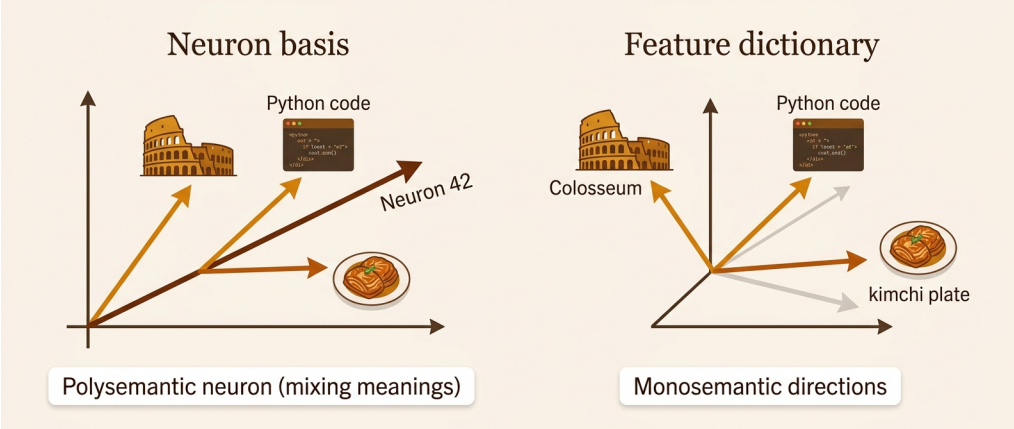


Рис. 8: Иллюстрация 11

Эмпирический тупик интерпретируемости

На протяжении многих лет исследователи пытались понять логику глубоких сетей, изучая условия максимальной активации отдельных нейронов скрытых слоев. Результаты оказались парадоксальными: подавляющее большинство нейронов являются **полисемантичными (polysemantic)**.

Один и тот же нейрон скрытого слоя может сильно активироваться на совершенно несопоставимые паттерны:

- Упоминание имени Юлия Цезаря в историческом контексте;
- Синтаксическая строка кода инициализации класса `def __init__(self):` в Python;
- Описание корейского блюда кимчхи в кулинарном тексте.

Долгое время это приписывалось неэффективности обучения или хаотической природе эмбеддингов. Однако гипотеза суперпозиции доказала: полисемантичность — это неизбежное математическое следствие упаковки признаков.

Геометрическая причина полисемантичности

Нейроны сети — это не семантические единицы, а всего лишь произвольно ориентированные координатные оси стандартного базиса $e_1, e_2, \dots, e_d \in \mathbb{R}^d$.

Пусть истинные моносемантичные концепты имеют направления $w_1, \dots, w_M$, распределенные в пространстве под произвольными углами. Значение активации k-го нейрона x_k — это проекция вектора скрытого состояния x на базисный вектор e_k:

$$x_k = \langle e_k, x \rangle = \left\langle e_k, \sum_{j=1}^{M} f_j w_j \right\rangle = \sum_{j=1}^{M} f_j \langle e_k, w_j \rangle$$

В силу геометрии сферы проекции $\langle e_k, w_j \rangle$ отличны от нуля для огромного числа векторов $\{w_j\}$. Нейрон k активируется на положительную величину всякий раз, когда в тексте появляется **любой** концепт j, для которого проекция $\langle e_k, w_j \rangle > 0$.

Интуитивная аналогия: Представьте спектр видимого света. Если мы спроецируем цветное изображение на две случайные неколлинеарные оси черно-белых датчиков, то ярко-красный и ярко-зеленый сигналы могут дать совершенно одинаковый суммарный отклик на первом сенсоре. Изучать сенсор в отрыве от спектра бесполезно. Необходимо совершить преобразование координат от случайных аппаратных осей к правильному цветовому базису (RGB).

В языковых моделях таким математическим инструментом перехода к истинному моносемантичному базису выступают **разреженные автоэнкодеры (Sparse Autoencoders)**.

Sparse Autoencoders (SAE): архитектура распаковки

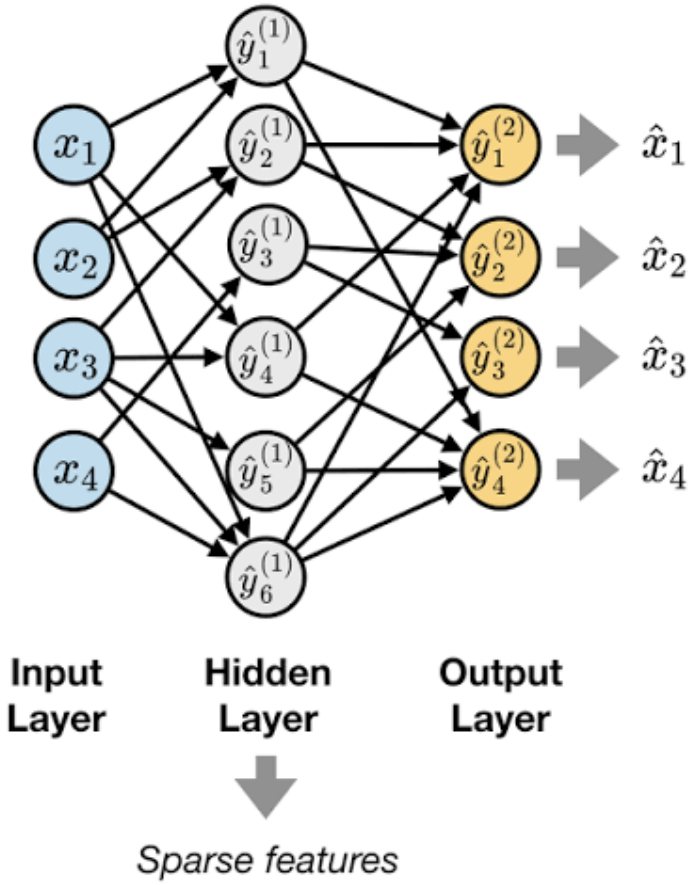


Рис. 9: Sparse Autoencoder Architecture

Постановка задачи

Цель Sparse Autoencoder — обучить без учителя переполненный словарь (overcomplete dictionary) моносемантичных направлений, который берет плотный полисемантичный вектор активаций LLM $x \in$

$\mathbb{R}^d$ и раскладывает его в сверхширокий, но строго разреженный вектор интерпретируемых признаков $f(x) \in \mathbb{R}^D$, где $D \gg d$.

Связь с компрессионным зондированием (Compressed Sensing): Поскольку сам вектор концептов в модели изначально разрежен ($k \ll d$), теория сжатых измерений Донохо — Кандеса — Тао гарантирует, что исходный сверхразмерный разреженный сигнал $f \in \mathbb{R}^D$ может быть точно восстановлен из малого числа линейных проекций $x \in \mathbb{R}^d$.

Математическая архитектура SAE (Bricken et al., Anthropic, 2023)

Архитектура состоит из двух компонентов — энкодера и декодера:

1. **Энкодер (Encoder):** Отображает плотный вектор активаций $x \in \mathbb{R}^d$ в широкое пространство признаков $\mathbb{R}^D$:
$$f(x) = \text{ReLU}\left(W_{\text{enc}}(x - b_{\text{dec}}) + b_{\text{enc}}\right)$$
где:
   - $W_{\text{enc}} \in \mathbb{R}^{D \times d}$ — весовая матрица энкодера;
   - $b_{\text{dec}} \in \mathbb{R}^d$ — геометрическое смещение декодера (Decoder Bias), которое центрирует активации относительно среднего вектора активаций датасета $\mathbb{E}[x]$;
   - $b_{\text{enc}} \in \mathbb{R}^D$ — обучаемый порог отсечения шума энкодера;
   - ReLU — функция, зануляющая все признаки, не преодолевшие порог интерференции.
2. **Декодер (Decoder):** Восстанавливает плотный вектор исходного слоя как линейную комбинацию моносемантичных направлений словаря:
$$\hat{x} = W_{\text{dec}} f(x) + b_{\text{dec}} = \sum_{i=1}^{D} f_i(x) d_i + b_{\text{dec}}$$
где:
   - $W_{\text{dec}} \in \mathbb{R}^{d \times D}$ — матрица направлений словаря;
   - $d_i \in \mathbb{R}^d$ — столбцы матрицы W_{dec}, представляющие собой **единичные нормализованные векторы** ($\|d_i\|_2 = 1$).

Коэффициент расширения (Expansion Factor)

Размерность скрытого пространства признаков D выбирается значительно больше размерности модели:
$$\text{Expansion Factor} = \frac{D}{d} \in \{8\times, 16\times, 32\times, 64\times\}$$
Например, при $d = 4096$ размерность признакового пространства SAE выбирается равной:
$$D = 4096 \times 16 = 65\,536 \quad \text{или} \quad D = 4096 \times 32 = 131\,072$$

SAE обучается автономно: мы «замораживаем» базовую языковую модель, прогоняем через нее терабайты текстовых корпусов, сохраняем векторы активаций выбранного слоя x и обучаем параметры $\{W_{\text{enc}}, b_{\text{enc}}, W_{\text{dec}}, b_{\text{dec}}\}$.

Функция потерь SAE: компромисс реконструкции и разреженности

Классический функционал потерь с ℓ_1-штрафом (Anthropic, 2023)

Обучение автоэнкодера строится на поиске баланса Парето между двумя конфликтующими целями:

1. Максимально точно восстановить исходную активацию x (чтобы признаки не теряли информацию);
2. Сделать вектор активаций $f(x)$ предельно разреженным (чтобы каждый токен активировал лишь малую горсть понятий).

Целевая функция потерь имеет вид:

$$\mathcal{L}_{\text{SAE}} = \underbrace{\|x - \hat{x}\|_2^2}_{\mathcal{L}_{\text{reconstruction}}} + \lambda \underbrace{\|f(x)\|_1}_{\mathcal{L}_{\text{sparsity}}} = \|x - \hat{x}\|_2^2 + \lambda \sum_{i=1}^{D} |f_i(x)|$$

Поскольку после ReLU все компоненты $f_i(x) \geq 0$, норма $\|f(x)\|_1 = \sum f_i(x)$.

Роль слагаемых:

- ℓ_2-ошибка реконструкции $\|x - \hat{x}\|_2^2$ гарантирует полноту информации;
- ℓ_1-норма является выпуклой релаксацией ℓ_0-псевдонормы (числа ненулевых элементов). Она заставляет сеть отключать шумовые проекции и обнулять абсолютное большинство координат $f_i(x)$.
- Коэффициент $\lambda > 0$ регулирует баланс: малые λ дают идеальную реконструкцию, но возвращают полисемантичность; большие λ дают единичные сверхчистые концепты, но теряют важную информацию о контексте.

Фундаментальный дефект ℓ_1-штрафа: эффект усадки (Shrinkage)

Классический ℓ_1-штраф обладает серьезным математическим недостатком. Производная регуляризатора по активации $f_i > 0$ постоянна:

$$\frac{\partial}{\partial f_i}(\lambda f_i) = \lambda$$

Градиент непрерывно «стягивает» значение активации вниз с постоянной силой независимо от того, насколько велик истинный сигнал. Это приводит к **эффекту усадки (shrinkage)**: амплитуда даже сильных и истинно активных концептов систематически занижается на величину $\sim \lambda/2$, что искажает реконструкцию $\hat{x}$ и вынуждает декодер искусственно завышать длину векторов d_i.

Архитектурная революция 2024 года

1. Top-K SAE (Gao et al., OpenAI, июнь 2024) Инженеры OpenAI предложили отказаться от капризного и искажающего амплитуды ℓ_1-штрафа в пользу жесткого нелинейного оператора TopK:

$$f(x) = \text{TopK}\left(W_{\text{enc}}(x - b_{\text{dec}}) + b_{\text{enc}},\ k\right)$$

Оператор $\text{TopK}(\cdot, k)$ оставляет без изменений ровно k наибольших положительных компонент вектора, а остальные $D - k$ элементов принудительно обнуляет.

В функции потерь авторы оставили только **чистую ошибку реконструкции**:

$$\mathcal{L}_{\text{Top-K}} = \|x - \hat{x}\|_2^2$$

Преимущества: Исчезает необходимость в подборе гиперпараметра λ. Разреженность зафиксирована аппаратно (например, $k = 32$ активных признака из словаря в $D = 131\,072$ на каждый токен). Эффект усадки полностью ликвидирован, а качество реконструкции при равной разреженности резко возросло.

2. Gated SAE и JumpReLU SAE (DeepMind / Anthropic, 2024) Альтернативный подход разделяет две задачи: 1. Принятие решения о том, активен ли признак (бинарный вентиль / gate); 2. Оценка истинной амплитуды признака в случае его активности. Использование модифицированных функций с разрывом первого рода (JumpReLU: $H(z-\theta)\cdot z$, где H — функция Хевисайда) позволяет полностью избавиться от штрафования амплитуд сильных сигналов.

Прорыв в интерпретируемости: Golden Gate Claude и GPT-4 (2024)

Эксперимент «Golden Gate Claude» (Anthropic, май 2024)

В мае 2024 года исследователи Anthropic (Templeton et al.) обучили масштабируемый SAE на средних слоях флагманской мультимодальной модели **Claude 3 Sonnet**. Среди миллионов извлеченных признаков был обнаружен изолированный моносемантичный вектор, кодирующий концепцию **моста «Золотые Ворота» в Сан-Франциско**.

Признак активировался не только на прямое упоминание названия моста, но и на: * Фотографии моста под любыми ракурсами и в тумане; * Упоминания связанных архитектурных терминов (опоры висячего моста, цвет International Orange); * Исторические события, связанные со строительством моста инженером Джозефом Страуссом.

Возможности каузального вмешательства (Feature Steering) не ограничены одним языком. В эксперименте над мультиязычной моделью с помощью SAE было выделено моносемантическое направление w_{keigo}, кодирующее концепт «Японская ультравежливая речь».

Исследователи искусственно зафиксировали активацию этого вектора на уровне $f_{\text{keigo}} \leftarrow 8.0$ и подали запросы на разных языках:

1. **Запрос на русском:** *«Где здесь вокзал?»*

- *Вывод модели без вмешательства: «Вокзал находится прямо по улице через 300 метров.»*
- *Вывод с активацией w_{keigo}: «Не соблаговолите ли вы смиренно обратить внимание, что вокзал милостиво расположен прямо по улице. Нижайше прошу простить за беспокойство.»* (Модель перенесла грамматические структуры японского почтительного регистра на русскую морфологию).

2. **Запрос на английском:** *«Close the door.»*

- *Вывод с активацией w_{keigo}: “Would you be so extraordinarily kind as to deign to permit the door to be closed, if it does not cause your honorable self any inconvenience?”*

Этот результат наглядно подтверждает теорию: направления в SAE управляют универсальными семантическими аттракторами. Изменение всего одного коэффициента суперпозиции разворачивает всю мультиязычную траекторию генерации.

Масштабирование на GPT-4 (OpenAI, июнь 2024)

Спустя месяц команда OpenAI (Gao et al.) масштабировала методику Top-K SAE на модель **GPT-4**, выделив **16 миллионов моносемантичных признаков**.

Анализ словаря выявил чистейшие направления сложнейших абстрактных категорий: 1. **Информационная безопасность:** выделены векторы поиска уязвимостей в программном коде (переполнение буфера на стеке, SQL-инъекции, CSRF, эксплойты нулевого дня). 2. **Психологические манипуляции и обман:** найдены направления, активирующиеся, когда модель начинает «льстить» пользователю, поддакивать его ошибочным мнениям (сикофантия / *sycophancy*) или генерировать скрытый манипулятивный контекст. 3. **Высокоуровневые научные абстракции:** специализированные направления для понятий теории струн, квантовой запутанности, статей уголовного кодекса и прецедентного права.

Применение в безопасности: Feature Ablation

Ключевое практическое следствие открытия SAE для индустрии ИИ — переход от «черного ящика» к хирургическому редактированию представлений.

Метод Feature Ablation (хирургическое удаление концепта): Если мы хотим гарантировать, что модель никогда не поможет злоумышленнику создать вредоносное ПО или синтезировать опасные токсины, нам больше не нужно полагаться на ненадежный RLHF (который легко взламывается джейлбрейками). Достаточно найти соответствующие опасные направления w_{danger} и математически спроецировать пространство активаций на их ортогональное дополнение при генерации каждого токена:

$$x_{\text{safe}} = x - \langle x, w_{\text{danger}} \rangle w_{\text{danger}}$$

Модель физически лишается способности удерживать и передавать опасную концепцию на уровне внутреннего представления, что открывает путь к фундаментально верифицируемой безопасности ИИ.

Распространенный способ обхода цензуры (Jailbreak) в моделях вроде GPT-4 — перевод вредоносного запроса на языки с низким объемом защитной разметки (Low-Resource Languages) или сложные иероглифические системы: пользователь запрашивает схему синтеза токсина не на английском, а кодирует запрос редкими китайскими идиомами или использует сложный русский академический жаргон с заменой части терминов. Стандартный классификатор безопасности (Guardrails/RLHF), натренированный преимущественно на английских диалогах, пропускает атаку.

Однако на уровне внутренних слоев модели концепт «Синтез биологического оружия» представлен единым вектором направления $w_{\text{bioweapon}} \in \mathbb{R}^d$, общим для всех языков. Применив **Feature Ablation**, инженеры вычитают проекцию на этот вектор из Residual Stream на каждом шаге инференса:

$$x \leftarrow x - \langle x, w_{\text{bioweapon}} \rangle w_{\text{bioweapon}}$$

Теперь, на каком бы языке ни поступал запрос (на русском, английском, китайском или зашифрованном Base64), модель математически лишена возможности сформировать скрытое состояние, лежащее вдоль оси этого концепта. В ответ модель не выдает шаблонный отказ *«Извините, я не могу…»*, а ведет себя так, словно информация о биологическом оружии полностью стерта из ее памяти, продолжая генерировать нейтральный безопасный контекст.

Заключительное резюме

1. **Геометрия как фундамент:** Поведение современных LLM в своей основе продиктовано геометрией пространств высоких размерностей. Тонкая оболочка шара и концентрация меры на экваторе сферы превращают почти ортогональность из редкого исключения в абсолютное статистическое правило.
2. **Экспоненциальная когнитивная емкость:** Суперпозиция — это естественный и математически оптимальный способ решения парадокса емкости. Трансформеры используют полиномиальные аппаратные затраты (размерность слоев $d \approx 4096$) для оперирования экспоненциальным числом семантических концептов ($M \sim 10^7$), опираясь на естественную разреженность реального мира.
3. **Распаковка черного ящика:** Sparse Autoencoders совершили исторический прорыв в области Mechanistic Interpretability. Разложение активаций на моносемантичные направления позволяет нам читать скрытые слои нейросетей как открытую книгу и дает в руки инженеров точные математические рычаги управления и верификации безопасности искусственного интеллекта.