Тренировочные вопросы

1. При INT4-квантовании активаций в трансформерах возникает проблема: хотя евклидова норма векторов активаций $\|x\|_2$ не является аномально большой, покомпонентная сетка квантования вносит критическую погрешность из-за наличия единичных каналов-выбросов (пространственной анизотропии). В современных методах (QuaRot, SpinQuant) перед квантованием вектор умножается на случайную ортогональную матрицу вращения: $y = xR$.

   Объясните, почему ортогональное преобразование, строго сохраняющее евклидову норму вектора ($\|xR\|_2 = \|x\|_2$), тем не менее нейтрализует негативный эффект каналов-выбросов, и к какому геометрическому распределению в пространстве приводит такая операция?

2. Инженер разрабатывает детектор аномалий для D-мерных латентных векторов, предполагая, что нормальные данные распределены равномерно внутри гипершара радиуса R. Вектор x признается аномальным, если он попадает во внешний сферический слой: $\|x\|_2 > 0.95R$. Однако при переходе к пространствам высокой размерности ($D = 1000$) детектор ошибочно классифицировал как аномалии практически 100% нормальных объектов.

   Объясните геометрическую причину этой ошибки и укажите, какую асимптотическую зависимость от размерности D должна иметь толщина слоя ΔR, чтобы удерживать долю отсекаемых нормальных объектов на фиксированном константном уровне (ответ сформулируйте в виде 1–3 предложений).

3. Инженер исследует поведение линейного нейрона $f(x) = \langle w, x \rangle$ без смещения на случайных нормализованных входных векторах $x \sim \text{Uniform}(\mathbb{S}^{D-1})$ при $D \to \infty$.

   Он замечает, что если зафиксировать вектор весов на единичной сфере ($\|w\| = 1$), то с ростом размерности выход нейрона экспоненциально быстро концентрируется около нуля, превращаясь практически в константу. Однако если масштабировать веса так, чтобы $\|w\| = \sqrt{D}$ (сохраняя дисперсию выхода порядка $O(1)$), выход нейрона перестаёт вырождаться в константу.

   Объясните этот эффект с точки зрения леммы Леви: чему равна константа Липшица L функции $f(x)$ во втором случае и как её подстановка в показатель экспоненты концентрационной оценки объясняет исчезновение эффекта подавления флуктуаций при $D \to \infty$?

4. В задаче приближенного поиска ближайших соседей (ANN) имеется фиксированная база из N векторов $X = \{x_1, \dots, x_N\} \subset \mathbb{R}^D$ и фиксированный вектор-запрос $q \in \mathbb{R}^D$. Для ускорения вычислений пространство сжимается с помощью случайного гауссовского отображения $f(x) = \frac{1}{\sqrt{k}} Ax$. При этом требуется гарантировать сохранение евклидовых расстояний с относительным искажением не более ε и суммарной вероятностью ошибки не более δ **только** между запросом q и каждым вектором базы (то есть для N пар вида (q, x_i)); расстояния между векторами базы друг с другом сохранять не требуется.

   Как изменится теоретическая нижняя граница на размерность k, полученная в доказательстве леммы Джонсона–Линденштрауса через концентрацию хи-квадрат

распределения и неравенство Буля (Union Bound), а именно — числовой коэффициент C_1 при слагаемом $\ln N$ в оценке вида:

$$k \geq \frac{C_1 \ln N + C_2 \ln(1/\delta)}{\varepsilon^2}$$

по сравнению со случаем сохранения всех попарных расстояний в выборке? Укажите новое значение коэффициента C_1 и кратко (в 1–2 предложениях) объясните причину его изменения.

5. В пайплайне понижения размерности эмбеддингов размерности D до целевой размерности $k \ll D$ используется факторизация Fast Johnson-Lindenstrauss Transform ($A = P \cdot H \cdot D$). Разработчик решает сократить задержку и исключает каскад $H \cdot D$, применяя к входным векторам напрямую случайное разреженное прореживание $P \in \mathbb{R}^{k \times D}$.

   К какому критическому эффекту приведет такая упрощенная проекция при обработке стандартного базисного вектора $e_i = (0, \dots, 0, 1, 0, \dots, 0)^T$ и какую именно задачу выполняет опущенный каскад $H \cdot D$ для предотвращения этого эффекта?

6. Для ускорения поиска ближайших соседей среди $N = 10^7$ векторов размерности $D = 1536$ используется каскадная схема: случайная проекция в пространство размерности $k = 128$ для первичного отбора топ-100 кандидатов с последующим точным переранжированием исходных векторов.

   При тестировании на реальных текстовых эмбеддингах этот подход обеспечивает Recall@100 $> 98\%$. Однако при попытке применить точно такую же схему сжатия до $k = 128$ к синтетическим векторам, равномерно распределённым на единичной гиперсфере $\mathbb{S}^{1535}$, полнота отбора кандидатов на первом этапе катастрофически деградирует.

   Объясните геометрическую причину столь разной эффективности проекции до $k = 128$ на этих двух наборах данных.

7. В поисковом сервисе векторные представления документов отображаются в 128-битные сигнатуры SimHash. Для двух нормализованных векторов $u, v \in \mathbb{R}^D$ ($\|u\| = \|v\| = 1$) математическое ожидание расстояния Хэмминга между их сигнатурами равно 32.

   Для построения составного представления вычисляется вектор $w = u + v$. Чему равно математическое ожидание расстояния Хэмминга между сигнатурами векторов u и w?

8. Инженер строит индекс для поиска ближайших соседей по выборке точек в $\mathbb{R}^{50}$ и замечает аномалию: для уменьшения геометрического диаметра ячеек с данными в два раза классическому k-d дереву (с поочередным циклическим разбиением вдоль координатных осей) требуется порядка 50 уровней глубины, тогда как дереву случайных проекций (RP-Tree) для аналогичного сжатия требуется всего 3–4 уровня.

   Объясните с точки зрения геометрии распределения данных и принципа выбора секущих гиперплоскостей в обоих алгоритмах, чем обусловлена такая существенная разница в скорости уменьшения диаметра ячеек.

9. При 4-битном симметричном квантовании вектора активаций языковой модели ($d = 4096$) полезный сигнал лежит в диапазоне $[-1.5, 1.5]$, однако из-за наличия одного изолированного выброса $M = 100$ шаг сетки $\Delta = \frac{\max |x_j|}{7} \approx 14.3$ округляет все информативные координаты в ноль. Для решения этой проблемы перед квантованием вектор активаций умножают на случайную ортогональную матрицу R ($RR^\top = I_d$).

   Несмотря на то, что ортогональное преобразование строго сохраняет евклидову норму вектора ($\|xR\|_2 = \|x\|_2$) и его суммарную энергию, шаг квантования Δ в повернутом пространстве падает более чем в 15 раз, предотвращая потерю информации. Объясните (в 1–3 предложениях) геометрический механизм этого эффекта: почему инвариантность L_2-нормы не препятствует резкому уменьшению шага Δ, и как именно перераспределяется амплитуда компонент вектора?