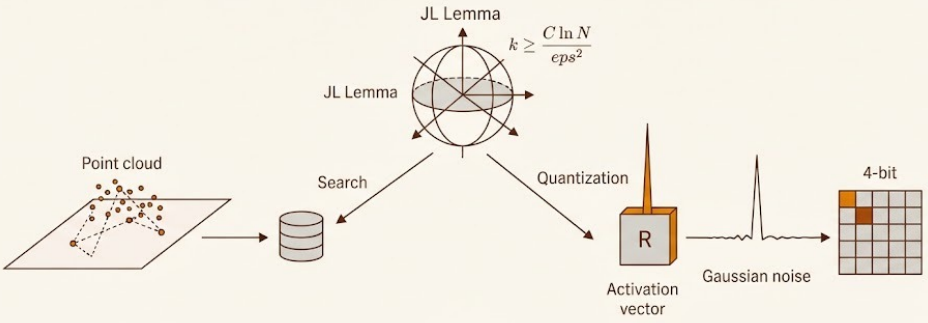
Случайные проекции и геометрия высокой размерности: от JL-леммы до квантования LLM



Содержание

- **Теоретический фундамент:** Лемма Джонсона–Линденштрауса и феномен концентрации меры в пространствах высокой размерности.
- **Масштабируемый поиск (Information Retrieval):** Случайные проекции, SimHash, Locality-Sensitive Hashing (LSH) и эффективный векторный поиск (ANN/RAG).
- **Экстремальное сжатие нейросетей:** Преодоление «проклятия выбросов» (outliers) в LLM через ортогональные вращения.

Проклятие и благословение размерности

Проклятие размерности (Curse of Dimensionality):

- Объем гиперсферы стремится к нулю по сравнению с объемом описанного гиперкуба при $D \to \infty$: $V_{\text{sphere}}(R) = \frac{\pi^{D/2}}{\Gamma(D/2+1)} R^D \ll (2R)^D = V_{\text{cube}}(R)$
- Почти весь объем многомерного шара сосредоточен в тонком приповерхностном слое толщиной $O(1/D)$.
- Расстояния между любыми случайными парами точек становятся одинаковыми: относительный контраст расстояний $\frac{d_{\max} - d_{\min}}{d_{\min}} \to 0$. Поиск ближайших соседей теряет смысл и становится случайным выбором.

Благословение размерности (Blessing of Dimensionality):

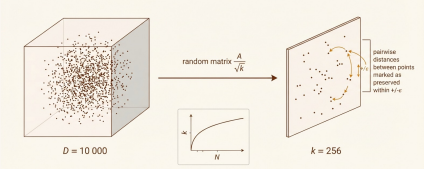
- **Концентрация меры:** гладкие функции от большого числа независимых координат ведут себя почти как константы.
- Любые два случайных вектора в $\mathbb{R}^D$ почти наверняка ортогональны: $\mathbb{E}[\cos\theta] = 0, \quad \text{Var}(\cos\theta) = \frac{1}{D}$
- Данные можно проецировать в пространства существенно меньшей размерности практически без искажения евклидовых расстояний.

Лемма Джонсона–Линденштрауса (JL-лемма)

Теорема (Johnson & Lindenstrauss, 1984): Пусть $\varepsilon \in (0, 1)$ — допустимый уровень погрешности, а $X \subset \mathbb{R}^D$ — произвольное фиксированное множество из N точек. Тогда существует линейное отображение $f : \mathbb{R}^D \to \mathbb{R}^k$ такое, что для всех пар $u, v \in X$ выполняется: $(1-\varepsilon)\|u-v\|^2 \le \|f(u)-f(v)\|^2 \le (1+\varepsilon)\|u-v\|^2$ при условии, что целевая размерность k удовлетворяет оценке: $k \ge \frac{C \ln N}{\varepsilon^2} = O\left(\frac{\log N}{\varepsilon^2}\right)$ *(где константа C не зависит от D и N; для вероятности успеха $1 - 1/N$ достаточно $C \approx 24$).*

Главный концептуальный результат:

- Размерность k **абсолютно не зависит от исходной размерности** D!
- Не важно, лежат ли эмбеддинги в $\mathbb{R}^{1536}$, $\mathbb{R}^{4096}$ или $\mathbb{R}^{10^8}$.
- Объем выборки N входит под знаком логарифма: рост объема данных в 1000 раз требует лишь аддитивной прибавки к k.

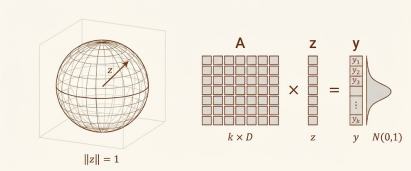


Альтернативная формулировка

Мы докажем более сильный результат - не ”существует”отображение, а то, что почти любое случайное отображение обладает этим свойством. Рассмотрим нормированную случайную матрицу $A \in \mathbb{R}^{k \times D}$: $f(x) = \frac{1}{\sqrt{k}} Ax$ где каждый элемент матрицы генерируется независимо: $A_{ij} \sim \mathcal{N}(0, 1)$.

В силу линейности отображения:

$$f(u) - f(v) = f(u - v) = \frac{1}{\sqrt{k}} A(u - v)$$



Обозначим единичный вектор направления $z = \frac{u-v}{\|u-v\|} \in \mathbb{R}^D$, тогда $\|z\|_2 = 1$. Достаточно показать, что для любого фиксированного единичного вектора z:

$$\mathbb{P}\left(\left|\frac{1}{k}\|Az\|^2 - 1\right| \geq \varepsilon\right) \leq 2e^{-ck\varepsilon^2}$$

т.е. случайная величина $Z = \frac{1}{k}\|Az\|^2$ строго концентрируется около единицы.

Доказательство JL: Шаг 1 — 1D Гауссова устойчивость

- Пусть $y = Az \in \mathbb{R}^k$. Рассмотрим i-ю координату вектора y:

$$y_i = \sum_{j=1}^{D} A_{ij} z_j = a_i^\top z$$

  где $a_i^\top = (A_{i1}, \dots, A_{iD})$ — i-я строка случайной матрицы A.
- Линейная комбинация независимых гауссовских величин сама распределена по Гауссу:

$$\mathbb{E}[y_i] = \sum_{j=1}^{D} z_j \mathbb{E}[A_{ij}] = 0$$

$$\mathrm{Var}(y_i) = \sum_{j=1}^{D} z_j^2 \mathrm{Var}(A_{ij}) = \sum_{j=1}^{D} z_j^2 \cdot 1 = \|z\|_2^2 = 1$$

- Независимо от исходного вектора z и размерности D, каждая компонента y_i является **стандартной нормальной случайной величиной**: $y_i \sim \mathcal{N}(0,1)$ для всех $i = 1, \dots, k$
  Поскольку строки матрицы A независимы, случайные величины $y_1, y_2, \dots, y_k$ взаимно независимы в совокупности.

Доказательство JL: Шаг 2 — Концентрация меры хи-квадрат

- Квадрат длины спроецированного вектора выражается через сумму квадратов: $\|f(z)\|^2 = \frac{1}{k}\|Az\|^2 = \frac{1}{k}\sum_{i=1}^{k} y_i^2 = \frac{1}{k}S_k$ Величина $S_k = \sum_{i=1}^{k} y_i^2$ имеет распределение **хи-квадрат** с k степенями свободы: $S_k \sim \chi^2(k)$.
- **Применение неравенства Чернова (для верхнего хвоста)** $\mathbb{P}(\xi \geq a) \leq \inf_{t>0} e^{-ta}\mathbb{E}[e^{t\xi}]$: $\mathbb{P}\left(\frac{1}{k}S_k \geq 1+\varepsilon\right) \leq \inf\limits_{t>0} \frac{\mathbb{E}[e^{tS_k}]}{e^{tk(1+\varepsilon)}}$
- Для $y_i \sim \mathcal{N}(0,1)$ производящая функция моментов: $\mathbb{E}[e^{ty_i^2}] = (1-2t)^{-1/2}$ при $t < 1/2$. $\mathbb{E}[e^{tS_k}] = \prod_{i=1}^{k}\mathbb{E}[e^{ty_i^2}] = (1-2t)^{-k/2}$ $\mathbb{P}\left(\frac{1}{k}S_k \geq 1+\varepsilon\right) \leq \left[(1-2t)^{-1}e^{-2t(1+\varepsilon)}\right]^{k/2}$
- Оптимум достигается в точке $t = \frac{\varepsilon}{2(1+\varepsilon)} < \frac{1}{2}$: $\mathbb{P}\left(\frac{1}{k}S_k \geq 1+\varepsilon\right) \leq \left[(1+\varepsilon)e^{-\varepsilon}\right]^{k/2} = e^{-\frac{k}{2}(\varepsilon-\ln(1+\varepsilon))} \leq e^{-\frac{k\varepsilon^2}{8}}$ *(поскольку* $\varepsilon - \ln(1+\varepsilon) \geq \frac{\varepsilon^2}{4}$ *при* $\varepsilon \in (0,1)$*).*
- Симметрично оценивая нижний хвост $\mathbb{P}(\frac{1}{k}S_k \leq 1-\varepsilon) \leq e^{-\frac{k\varepsilon^2}{8}}$, по правилу объединения получаем: $\mathbb{P}\left(\left|\frac{1}{k}\|Az\|^2 - 1\right| \geq \varepsilon\right) \leq 2e^{-\frac{k\varepsilon^2}{8}}$

Доказательство JL: Шаг 3 — Union Bound по парам точек

- Для одной фиксированной пары точек (u, v) случайная проекция сохраняет расстояние с высокой вероятностью: $\mathbb{P}(\text{ошибка для фиксированной пары} \geq \varepsilon) \leq 2e^{-\frac{k\varepsilon^2}{8}}$
- **Объединение событий по выборке X (Union Bound):** В множестве из N точек существует ровно $\binom{N}{2} = \frac{N(N-1)}{2} < \frac{N^2}{2}$ пар.

$$\mathbb{P}(\text{хотя бы для одной пары искажение} \geq \varepsilon) \leq \sum_{u \neq v \in X} \mathbb{P}\left(\left|\frac{\|f(u) - f(v)\|^2}{\|u - v\|^2} - 1\right| \geq \varepsilon\right)$$

$$\mathbb{P}(\text{сбой}) \leq \frac{N^2}{2} \cdot 2e^{-\frac{k\varepsilon^2}{8}} = N^2 e^{-\frac{k\varepsilon^2}{8}}$$

- **Финальный выбор размерности k:** Потребуем, чтобы вероятность сбоя не превышала малого $\delta \in (0, 1)$:

$$N^2 e^{-\frac{k\varepsilon^2}{8}} \leq \delta \iff 2\ln N - \frac{k\varepsilon^2}{8} \leq \ln \delta, \implies k \geq \frac{16 \ln N + 8 \ln(1/\delta)}{\varepsilon^2}$$

- **Вывод (Вероятностный метод Эрдёша):** Случайная гауссовская матрица удовлетворяет условию теоремы с вероятностью не менее $1 - \delta$ без какого-либо градиентного обучения!

Варианты проекций: от Гаусса к FJLT

Проблема плотной матрицы Гаусса: Умножение Ax требует $O(k \cdot D)$ операций с плавающей точкой. Для $D = 4096, k = 512$ это более 2 млн операций на каждый одиночный вектор.

1. Разреженные проекции Ачлиоптаса (Achlioptas, 2003): Элементы матрицы A_{ij} выбираются дискретно: $A_{ij} = \sqrt{3} \times \begin{cases} +1, & \text{с вер. } 1/6 \\ 0, & \text{с вер. } 2/3 \\ -1, & \text{с вер. } 1/6 \end{cases}$

Умножение ускоряется в 3 раза, операции умножения заменяются простым сложением и вычитанием! Гарантии JL полностью сохраняются.

2. Fast Johnson-Lindenstrauss Transform (Ailon & Chazelle, 2006): Матрица факторизуется в виде $A = P \cdot H \cdot D$:

- $D \in \mathbb{R}^{D \times D}$ — диагональная матрица со случайными знаками ± 1.
- $H \in \mathbb{R}^{D \times D}$ — нормированная матрица Адамара ($O(D \log D)$ через быстрое преобразование Уолша–Адамара).
- $P \in \mathbb{R}^{k \times D}$ — разреженная случайная матрица прореживания.

Сложность проекции падает с $O(kD)$ до $O(D \log D + k \log^2 N)$! *(Техническое условие: D дополняется нулями до ближайшей степени двойки).*

Применение 1: Векторные БД и ANN-поиск в RAG

Проблема масштабирования векторного поиска:

- В современных RAG-системах базы данных содержат от 10^6 до 10^9 текстовых пассажей.
- Хранение 10^7 векторов OpenAI (`text-embedding-3-small`, $D = 1536$, float32): $10^7 \times 1536 \times 4$ байта ≈ 61.44 ГБ RAM
- Точный поиск k-NN линейным перебором ($O(N \cdot D)$) дает неприемлемую задержку в сотни миллисекунд.

Архитектура двухстадийного ANN-поиска (Approximate Nearest Neighbors):

Стадия 1 (Грубый отбор, Coarse filtering): Проецируем базу и вектор запроса в $k \ll D$ (например, $k = 128$) с помощью JL-проекции: $\tilde{x} = \frac{1}{\sqrt{k}} Ax$ Быстро находим топ-M кандидатов (где $M \approx 100$) в сверхкомпактном пространстве оперативной памяти.

Стадия 2 (Точное переранжирование, Precise Reranking): Для отобранных M кандидатов подгружаем полные векторы и вычисляем точное скалярное произведение в размерности $D = 1536$.

Результат: 10–30-кратное ускорение поиска и резкое снижение нагрузки на шину памяти при сохранении метрики Recall@K $> 98\%$.

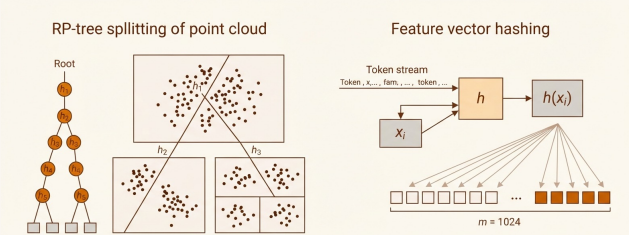
SimHash и угловой Locality-Sensitive Hashing (LSH)

- **Идея LSH:** Спроектировать векторы так, чтобы близкие объекты попадали в один хэш-бин с высокой вероятностью, а далекие — с низкой.
- **Случайные гиперплоскости (Charikar, 2002):** Генерируем случайный вектор нормали $r \sim \mathcal{N}(0, I_D)$. Определим 1-битный хэш: $h_r(x) = \text{sign}(r^\top x) \in \{-1, +1\}$ Геометрически: случайная гиперплоскость, проходящая через ноль, делит пространство пополам.
- **Теорема о вероятности коллизии (Goemans–Williamson / Charikar):** Пусть $\theta(u, v) = \arccos\left(\frac{u^\top v}{\|u\|\|v\|}\right)$ — угол между векторами u и v.
  $\mathbb{P}(h_r(u) \neq h_r(v)) = \frac{\theta(u,v)}{\pi} \implies \mathbb{P}(h_r(u) = h_r(v)) = 1 - \frac{\theta(u,v)}{\pi}$
- **Сборка битового кода SimHash:** Выбираем b независимых нормалей $r_1, \dots, r_b$. Получаем компактный b-битный код: $\text{SimHash}(x) = [\text{sign}(r_1^\top x), \dots, \text{sign}(r_b^\top x)] \in \{0, 1\}^b$
- Косинусная близость строго переводится в **расстояние Хэмминга** на битовых строках!
- Дистанция Хэмминга считается на CPU/GPU за **1 такт** инструкциями `XOR` + `POPCNT` (`__builtin_popcountll`).

Random Projection Trees (RP-Trees)

- Классические k-d деревья делят пространство строго по исходным координатным осям. При $D > 20$ они деградируют до прямого перебора $O(N)$.
- **RP-Tree:** на каждом узле выбирает случайный вектор $r \sim \mathcal{N}(0, I)$, вычисляет одномерную проекцию всех точек $r^\top x$ и рассекает их по медиане:
  $x \in \text{Left}$, если $r^\top x \leq \text{median}$; иначе $x \in \text{Right}$

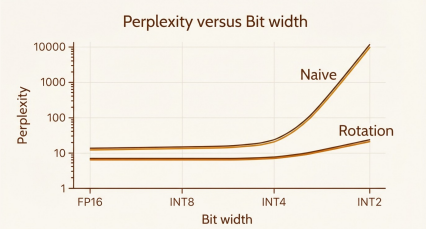
Дерево адаптируется к собственной внутренней размерности данных независимо от величины D.



Применение 2: Проблема экстремального квантования LLM

Проблема памяти при инференсе LLM:

- LLaMA-3-70B в формате FP16 требует **140 ГБ видеопамяти** (минимум две профессиональные карты A100/H100 по 80 ГБ).
- 4-битное квантование (INT4) сжимает модель до **~36–38 ГБ** (запуск на одном потребительском GPU RTX 4090 или рабочей станции с Apple Silicon).
- 2-битное квантование (INT2) позволяет запустить 70B модель на ноутбуке (**~18–19 ГБ**)!



Парадигмы квантования:

- **Weight-Only:** сжаты только веса (4 бита), активации остаются в FP16. Ускорение ограничено: веса перед умножением нужно распаковывать в FP16 на лету.
- **Weight-Activation:** и веса, и активации целочисленные (аппаратное ускорение в 2–4 раза по сравнению с FP16).

Стена квантования (Quantization Cliff): При попытке перевести активации в INT4 в моделях масштаба > 6.7B перплексия (PPL) устремляется в бесконечность — модель теряет адекватность. Почему?

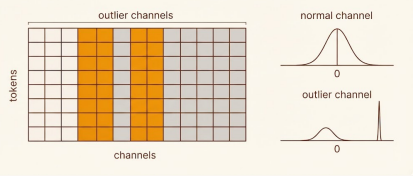
Анатомия выбросов (Outlier Features) в трансформерах

Феномен выбросов (Dettmers et al., 2022, LLM.int8()): При превышении порога в 6.7B параметров во всех трансформерах возникает фазовый переход:

- В $0.01\% - 0.1\%$ скрытых координат вектора активаций значения достигают экстремальных амплитуд $\pm 50 \cdots \pm 150$.
- В остальных 99.9% каналов значения компактно сосредоточены в диапазоне $[-1.5, +1.5]$.
- Разница по амплитуде — **до 100 раз**, по плотности энергии — до **10 000 раз**!

Свойства каналов-выбросов:

- **Координатная привязка:** выбросы жестко локализованы в определенных индексах скрытого состояния (например, всегда строго в 137-м и 2049-м каналах).
- **Критическая важность:** искусственное обнуление этих каналов мгновенно разрушает способность модели связно генерировать текст.
- **Семантическая роль:** эти координаты аккумулируют контекстные регуляторы внимания (attention sinks) и маркеры редких синтаксических паттернов.



Почему выбросы убивают равномерное квантование?

Схема симметричного равномерного квантования (Uniform INT4): Целевой диапазон 4-битных целых чисел со знаком: $[-8, 7]$ (или симметричный $[-7, 7]$). Шаг квантования Δ определяется абсолютным максимумом строки активаций:

$$\Delta = \frac{\max|X|}{2^{b-1}-1} = \frac{X_{\max}}{7}, \quad X_{\text{quant}} = \text{clip}\left(\left\lfloor \frac{X}{\Delta} \right\rceil, -8, 7\right), \quad \hat{X} = X_{\text{quant}} \cdot \Delta$$

Механика ошибки округления: Пусть из-за одного выброса в канале $X_{\max} = 100$. Шаг сетки округления раздувается: $\Delta = \frac{100}{7} \approx 14.28$. При этом 99.9% полезных активаций лежат в границах $[-1.5, +1.5]$!

Все информативные каналы попадут строго в нулевой бин:
$\left\lfloor \frac{1.5}{14.28} \right\rceil = 0, \quad \left\lfloor \frac{-1.5}{14.28} \right\rceil = 0 \implies \hat{X} = 0$

Катастрофический итог: Информация из подавляющего большинства каналов стирается. Дисперсия шума равномерного квантования равна $\sigma^2 = \frac{\Delta^2}{12}$: $\mathbb{E}[(X - \hat{X})^2] \approx \frac{X_{\max}^2}{12 \cdot 7^2}$. Рост $X_{\max}$ в 50 раз увеличивает суммарную дисперсию ошибки квантования слоя в **2500 раз**!

Идея Incoherence Processing: Ортогональная инвариантность

- **Ортогональная инвариантность линейного слоя:**
  Рассмотрим матричное умножение активаций $X \in \mathbb{R}^{n \times d}$ на матрицу весов $W \in \mathbb{R}^{d \times m}$: $Y = XW$ Вставим в середину тождественный оператор $RR^\top = I$, где $R \in \mathbb{R}^{d \times d}$ — ортогональная матрица ($R^{-1} = R^\top$):

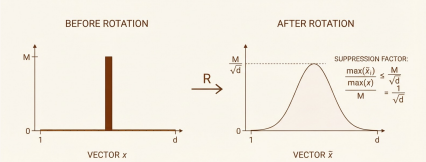
$$Y = X(RR^\top)W = (XR)(R^\top W) = \tilde{X}\tilde{W}$$

  где $\tilde{X} = XR$ — повернутые активации, а $\tilde{W} = R^\top W$ — повернутые веса.

- **Ключевые инженерные следствия:**
  1. **Тождественная эквивалентность:** До процедуры квантования операция не меняет выход Y: ошибка строго равна 0.
  2. **Оффлайн-преобразование весов:** Матрицу $\tilde{W} = R^\top W$ можно вычислить один раз на этапе подготовки модели и упаковать в 4 бита. В рантайме оверхед на веса отсутствует!
  3. **Трансформация активаций:** Векторы активаций X умножаются на R на лету перед подачей в целочисленный вычислительный блок.

Математика подавления выбросов: Концентрация на сфере

- **Модель единичного экстремального выброса:** Пусть строка активаций токена имеет выброс амплитуды M в координате j^*: $x = (0, \dots, 0, M, 0, \dots, 0) \in \mathbb{R}^{1\times d}, \quad \|x\|_2 = M$
- **Поведение при случайном ортогональном вращении** $\tilde{x} = xR$**:** $\tilde{x}_k = \sum_{j=1}^{d} x_j R_{jk} = M \cdot R_{j^*k}$ где строка случайной матрицы Хаара равномерно распределена по единичной сфере $\mathbb{S}^{d-1}$.



- **Концентрация меры на сфере:** Координата случайного единичного вектора в $\mathbb{R}^d$ распределена почти гауссовски: $R_{j^*k} \approx \mathcal{N}(0, 1/d)$. Отсюда каждая компонента повернутого вектора: $\tilde{x}_k \sim \mathcal{N}\left(0, \frac{M^2}{d}\right)$ Энергия выброса M^2, запертая ранее в одном канале, строго поровну «размазалась» по всем d координатам!
- **Оценка максимальной координаты:** $\mathbb{E}[\max_{k=1..d} |\tilde{x}_k|] \leq \frac{M}{\sqrt{d}}\sqrt{2\ln(2d)}$
- Для скрытого слоя трансформера ($d = 4096$): $\sqrt{\frac{2\ln(8192)}{4096}} = \sqrt{\frac{18.02}{4096}} \approx \frac{1}{15.1}$
- **Пиковая амплитуда активации падает более чем в 15 раз!**
- Дисперсия шума квантования Δ^2 падает в $15.1^2 \approx$ **225** раз!

Вычислительная эффективность: Преобразование Уолша–Адамара

Проблема матрицы Хаара: Умножение на случайную плотную матрицу $R \in \mathbb{R}^{d\times d}$ требует $O(d^2)$ операций. Это съедает все преимущества.

Решение: Рандомизированное преобразование Уолша–Адамара (RHT): $R = \frac{1}{\sqrt{d}} H_d \cdot D$ где $D = \mathrm{diag}(\pm 1, \ldots, \pm 1)$ — случайная диагональная знаковая матрица, а H_d — рекурсивная матрица Адамара размера $2^m \times 2^m$: $H_2 = \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}, \quad H_{2^m} = H_2 \otimes H_{2^{m-1}}$

Свойства преобразования Уолша–Адамара:

- **Строгая ортогональность:** $RR^\top = \frac{1}{d}(H_d D)(D H_d^\top) = \frac{1}{d} H_d I H_d = I_d$.
- **Равномерность:** каждый элемент $|(H_d)_{ij}| = 1$. Энергия любого входного импульса делится строго поровну между выходами.

Fast Walsh-Hadamard Transform (FWHT): вычисление требует $O(d \log_2 d)$ **только сложений и вычитаний**, без единого матричного умножения с плавающей точкой!

Для $d = 4096$: $d^2 \approx 1.68 \times 10^7$ операций заменяется на $d \log_2 d = 49\,152$ операции (**ускорение в 340 раз!**).

Практический нюанс: Если размерность скрытого слоя не является степенью 2 (например, SwiGLU MLP intermediate size), используют блочно-диагональные матрицы Адамара ($H_d = \mathrm{diag}(H_{2^a}, H_{2^b})$) либо дополнение вектора нулями (padding).