Случайные проекции и геометрия высокой размерности — от JL-леммы до квантования LLM

---

1. Введение: Случайная геометрия как мост между теорией и инженерными системами

Современное машинное обучение сталкивается с двумя масштабными вычислительными вызовами:

1. **Масштабируемый семантический поиск (Information Retrieval / RAG):** Необходимость быстро находить ближайшие векторы в терабайтных базах dense-эмбеддингов без полного линейного перебора.
2. **Экстремальная оптимизация инференса больших языковых моделей (LLM):** Необходимость сжатия десятков миллиардов параметров трансформеров до разрядности 4 и 2 бита для запуска на доступных GPU без потери генеративной способности.

Удивительным образом обе эти прикладные проблемы решаются с помощью одного и того же математического аппарата — **теории концентрации меры** и **случайных линейных отображений**, восходящих к функциональному анализу 1980-х годов и знаменитой **лемме Джонсона–Линденштрауса (JL-лемме)**.

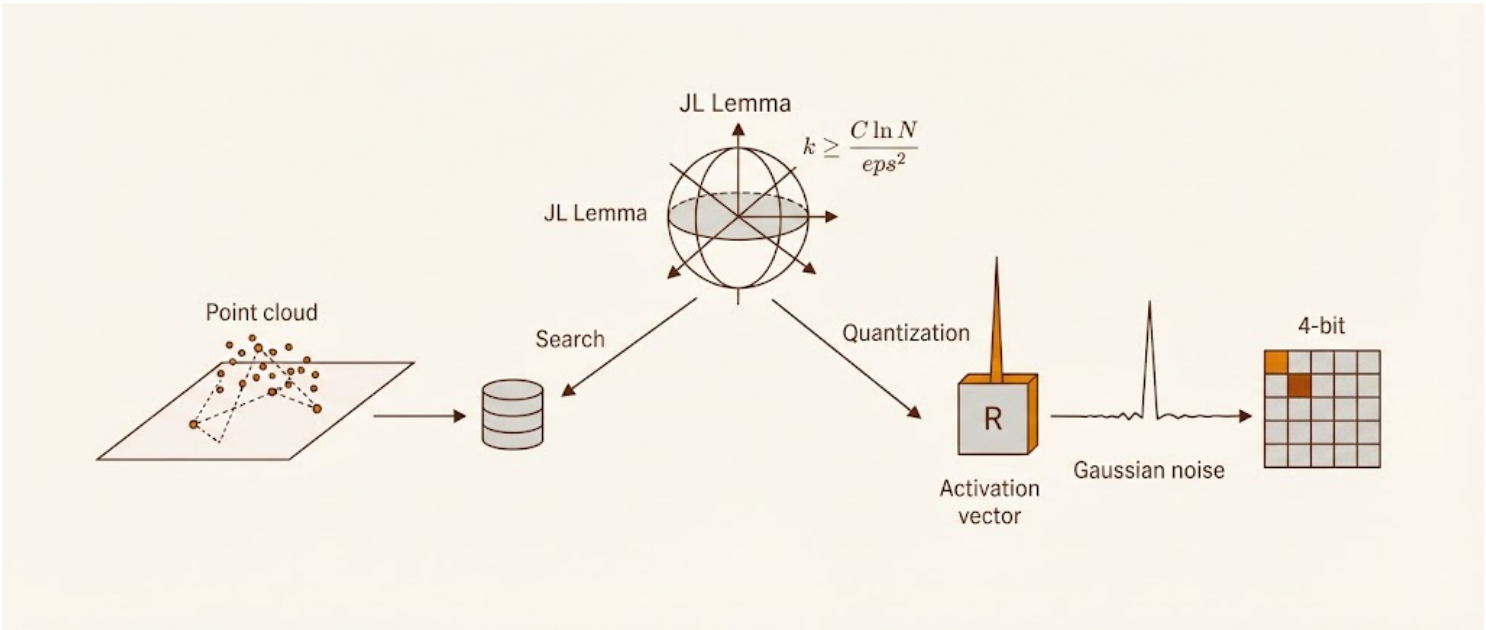


Рис. 1: Случайная геометрия как мост между теорией и инженерными системами

Ключевые сквозные принципы лекции:

- **Теоретический базис:** Феномены неевклидовой геометрии пространств сверхвысокой размерности $\mathbb{R}^D$ ($D \gg 1$) и строгая концентрация случайных величин около своего математического ожидания.

- **Масштабируемый поиск:** Превращение геометрической информации в компактные хэш-коды (Locality-Sensitive Hashing, SimHash) и снижение размерности эмбеддингов для двухстадийного векторного поиска.
- **Сжатие нейросетей:** Применение случайных и псевдослучайных ортогональных вращений (алгоритмы QuaRot, QuIP, SpinQuant) для устранения пространственной анизотропии активаций («проклятия каналов-выбросов»), что открывает путь к аппаратному INT4/INT2 квантованию матричных умножений.
- **Изотропизация данных:** Преобразование скоординированных, вырожденных структур данных в статистически равномерные сферические распределения, с которыми алгоритмы работают предельно эффективно.

---

2. Геометрия высокой размерности: Проклятие и благословение

Геометрическая интуиция исследователя формируется в пространствах $\mathbb{R}^2$ и $\mathbb{R}^3$. Однако поведение геометрических тел в пространствах высокой размерности ($D = 10^2 \dots 10^5$) кардинально меняется из-за распределения объема и расстояний.

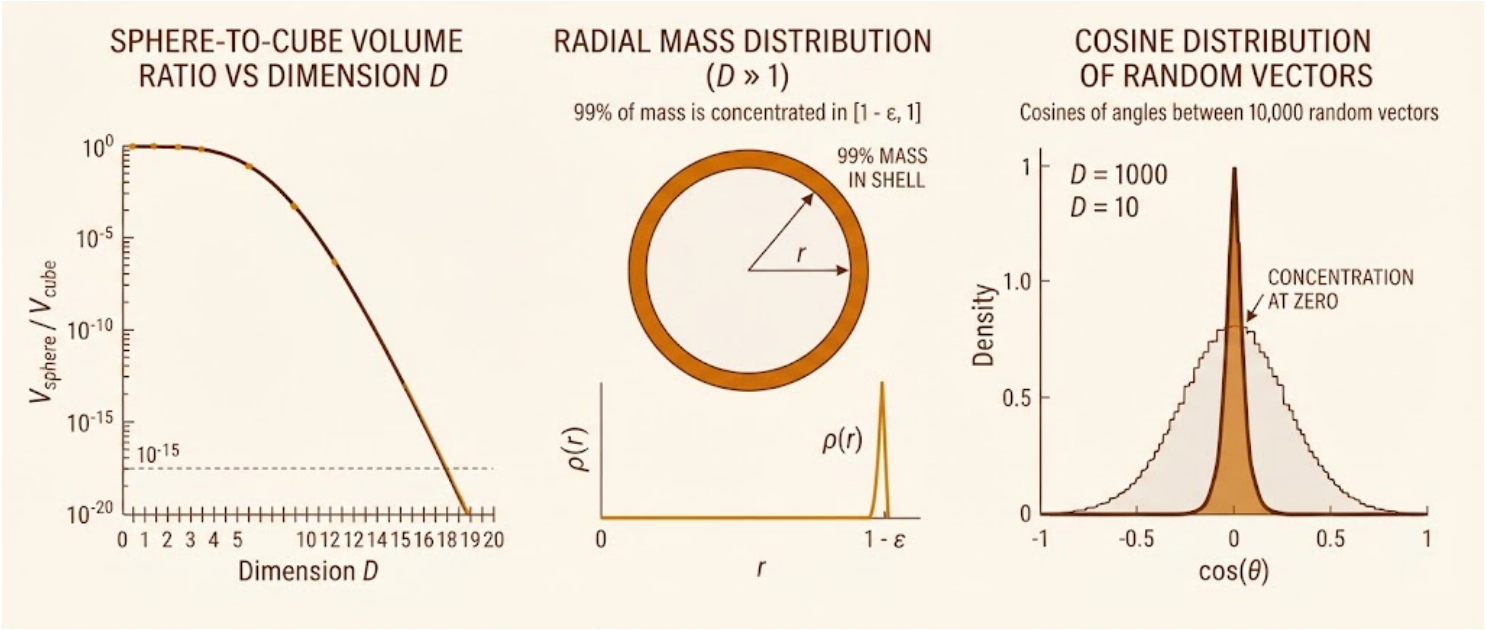


Рис. 2: Особенности распределения точек в многомерном шаре

Проклятие размерности (Curse of Dimensionality)

1. Парадокс объема гиперсферы Рассмотрим евклидову гиперсферу радиуса R в $\mathbb{R}^D$ и описанный вокруг нее гиперкуб со стороной $2R$. Их объемы вычисляются следующим образом:

$$V_{\text{cube}}(R) = (2R)^D = 2^D R^D$$

$$V_{\text{sphere}}(R) = \frac{\pi^{D/2}}{\Gamma\left(\frac{D}{2}+1\right)} R^D$$

где $\Gamma(z)$ — гамма-функция Эйлера ($\Gamma(n) = (n-1)!$).

Отношение объема сферы к объему описанного куба:

$$\frac{V_{\text{sphere}}(R)}{V_{\text{cube}}(R)} = \frac{\pi^{D/2}}{2^D \Gamma\left(\frac{D}{2}+1\right)} \xrightarrow[D\to\infty]{} 0$$

По формуле Стирлинга $\Gamma\left(\frac{D}{2}+1\right) \approx \sqrt{\pi D}\left(\frac{D}{2e}\right)^{D/2}$. Следовательно, знаменатель растет как $(D/2e)^{D/2}$, что несоизмеримо быстрее числителя $(\sqrt{\pi}/2)^D$. При $D \to \infty$ объем гиперсферы составляет исчезающе малую долю объема куба: практически весь объем куба вытесняется в его угловые области.

2. Концентрация объема в тонком приповерхностном слое Рассмотрим объем гиперсферы радиуса $R(1-\delta)$, находящейся внутри сферы радиуса R:

$$\frac{V_{\text{sphere}}(R(1-\delta))}{V_{\text{sphere}}(R)} = \frac{(R(1-\delta))^D}{R^D} = (1-\delta)^D$$

Если положить толщину слоя $\delta = \frac{c}{D}$ для некоторой константы $c > 0$, то по замечательному пределу:

$$\lim_{D\to\infty}\left(1-\frac{c}{D}\right)^D = e^{-c}$$

При $c = 5$ внутренняя часть сферы содержит лишь $e^{-5} \approx 0.0067$ (менее 1%) объема. Таким образом, **более 99% объема шара высокой размерности сосредоточено в исчезающе тонком приповерхностном сферическом слое толщиной** $O(1/D)$.

3. Вырождение метрического контраста Пусть точки генерируются независимо из некоторого распределения. Евклидово расстояние между парой независимых векторов $X, Y \in \mathbb{R}^D$ определяется как:

$$\|X-Y\|_2 = \sqrt{\sum_{i=1}^{D}(X_i - Y_i)^2}$$

В силу закона больших чисел сумма D независимых случайных величин имеет стандартное отклонение порядка $O(\sqrt{D})$, в то время как ее математическое ожидание растет пропорционально $O(D)$. В результате относительный разброс расстояний стремится к нулю:

$$\lim_{D\to\infty}\frac{d_{\text{max}} - d_{\text{min}}}{d_{\text{min}}} = 0$$

В высоких размерностях все точки оказываются практически на одинаковом расстоянии друг от друга. Понятие «ближайшего соседа» в классическом виде вырождается: поиск по евклидовому расстоянию начинает походить на случайный выбор.

Благословение размерности (Blessing of Dimensionality)

Те же самые вероятностные законы, порождающие трудности, дают мощные вычислительные преимущества:

1. Квазиортогональность случайных векторов Пусть $u, v \in \mathbb{R}^D$ — два случайных независимых единичных вектора, равномерно распределенных на сфере $\mathbb{S}^{D-1}$. Косинус угла между ними:

$$\cos\theta = \langle u, v \rangle = \sum_{i=1}^{D} u_i v_i$$

В силу центральной предельной теоремы (ЦПТ) для суммы независимых одинаково распределенных случайных величин с нулевым средним:

$$\mathbb{E}[\cos\theta] = 0, \quad \mathrm{Var}(\cos\theta) = \frac{1}{D}$$

С ростом D дисперсия падает до нуля: $\cos\theta \sim \mathcal{N}\left(0, \frac{1}{D}\right)$. Это означает, что для $D = 10\,000$ стандартное отклонение составляет $\frac{1}{100}$, а угол между **любыми двумя случайно взятыми направлениями лежит в диапазоне** $90^\circ \pm 1.5^\circ$ **с вероятностью** > 0.99. В $\mathbb{R}^D$ помещается экспоненциально много взаимно почти ортогональных направлений.

2. Феномен концентрации меры (Lévy's Lemma) Любая липшицева функция $f : \mathbb{S}^{D-1} \to \mathbb{R}$ с константой Липшица L (то есть $|f(x) - f(y)| \leq L\|x - y\|$) в высокой размерности ведет себя практически как константа на всем многообразии:

$$\mathbb{P}(|f(x) - \mathbb{E}[f]| \geq \varepsilon) \leq 2\exp\left(-\frac{C \cdot D\varepsilon^2}{L^2}\right)$$

Случайные флуктуации макроскопических параметров подавляются экспоненциально по размерности D. Это позволяет сохранять глобальные метрические свойства структур при случайных проекциях.

---

3. Лемма Джонсона–Линденштрауса (JL-лемма)

Лемма Джонсона–Линденштрауса (1984) — фундаментальная теорема метрической геометрии, обосновывающая возможность сжатия данных без потери расстояний.

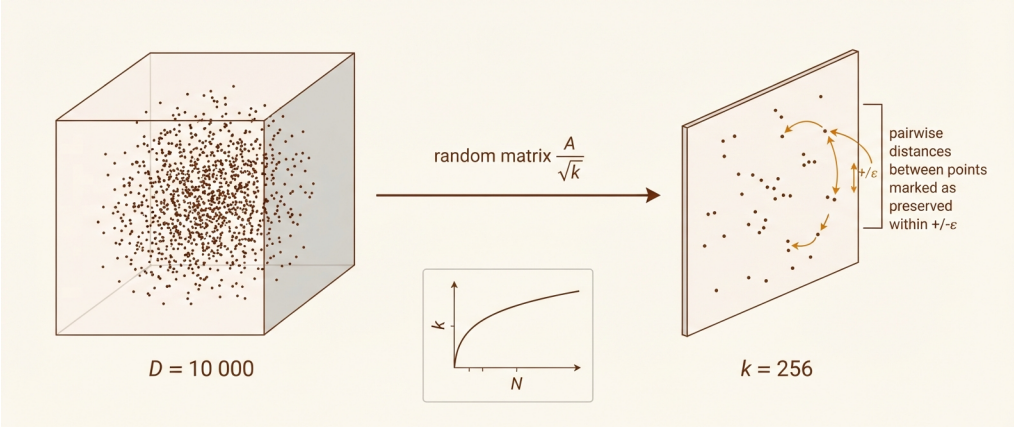


Рис. 3: Сжатие данных без потери расстояний

Формулировка теоремы

Теорема (Johnson & Lindenstrauss, 1984): Пусть $\varepsilon \in (0,1)$ — допустимый уровень относительного искажения евклидовых расстояний, а $X \subset \mathbb{R}^D$ — произвольное фиксированное множество из N точек. Тогда существует линейное отображение $f : \mathbb{R}^D \to \mathbb{R}^k$ такое, что для всех пар $u, v \in X$ выполняется:

$$(1-\varepsilon)\|u-v\|^2 \leq \|f(u)-f(v)\|^2 \leq (1+\varepsilon)\|u-v\|^2$$

при условии, что размерность целевого подпространства k удовлетворяет нижней границе:

$$k \geq \frac{C \ln N}{\varepsilon^2} = O\left(\frac{\log N}{\varepsilon^2}\right)$$

где универсальная константа C не зависит ни от D, ни от конфигурации множества X.

Концептуальный смысл теоремы

1. **Независимость от D:** Исходное пространство может иметь сколь угодно гигантскую размерность ($D = 10^6, 10^{12}$ или сколь угодно больше). Целевая размерность k зависит **исключительно от количества объектов N и требуемой погрешности ε**.
2. **Логарифмический масштаб по объему данных:** При росте выборки в 1000 раз целевая размерность k увеличивается лишь аддитивно на константу: $\ln(1000N) = \ln N + \ln 1000 \approx \ln N + 6.9$.
3. **Отсутствие адаптации под данные:** Отображение f не требует обучения (в отличие от PCA, t-SNE, UMAP). Оно формируется случайным образом.

---

4. Вероятностный метод: Редукция к сохранению нормы единичного вектора

Конструктивное доказательство леммы строится не через поиск специального базиса, а через **вероятностный метод Эрдёша**: мы доказываем, что случайно сгенерированная матрица обладает требуемым свойством с вероятностью, близкой к 1.

Конструкция отображения

Зададим матрицу $A \in \mathbb{R}^{k \times D}$, каждый элемент которой выбирается независимо из стандартного нормального распределения:

$$A_{ij} \sim \mathcal{N}(0,1), \quad \forall i \in \{1,\dots,k\},\ j \in \{1,\dots,D\}$$

Определим линейное отображение $f : \mathbb{R}^D \to \mathbb{R}^k$:

$$f(x) = \frac{1}{\sqrt{k}} Ax$$

Множитель $\frac{1}{\sqrt{k}}$ нормирует длину образа, компенсируя суммирование квадратов по k координатам.

Редукция задачи к единичному вектору

В силу линейности матрицы A:

$$f(u) - f(v) = \frac{1}{\sqrt{k}} A(u - v)$$

Квадрат евклидовой нормы разности образов:

$$\|f(u) - f(v)\|^2 = \frac{1}{k}\|A(u - v)\|^2 = \|u - v\|^2 \cdot \left(\frac{1}{k}\left\|A\left(\frac{u - v}{\|u - v\|}\right)\right\|^2\right)$$

Обозначим единичный вектор разности через z:

$$z = \frac{u - v}{\|u - v\|} \in \mathbb{R}^D, \quad \|z\|_2 = 1$$

Тогда условие сохранения расстояния с погрешностью ε:

$$(1 - \varepsilon) \leq \frac{\|f(u) - f(v)\|^2}{\|u - v\|^2} \leq (1 + \varepsilon) \iff \left|\frac{1}{k}\|Az\|^2 - 1\right| \leq \varepsilon$$

Таким образом, задача свелась к доказательству одномерного факта концентрации меры: для любого фиксированного единичного вектора $z \in \mathbb{S}^{D-1}$ случайная величина $\frac{1}{k}\|Az\|^2$ концентрируется около единицы с экспоненциально подавляемым хвостом:

$$\mathbb{P}\left(\left|\frac{1}{k}\|Az\|^2 - 1\right| \geq \varepsilon\right) \leq 2e^{-ck\varepsilon^2}$$

---

5. Доказательство JL: Шаг 1 — 1D Гауссова устойчивость

Рассмотрим вектор $y = Az \in \mathbb{R}^k$. Его i-я компонента y_i представляет собой скалярное произведение i-й строки матрицы A (обозначим её $a_i^\top$) и фиксированного вектора z:

$$y_i = \sum_{j=1}^{D} A_{ij} z_j = a_i^\top z$$

Вычислим математическое ожидание и дисперсию величины y_i:

1. **Математическое ожидание:**

$$\mathbb{E}[y_i] = \mathbb{E}\left[\sum_{j=1}^{D} A_{ij} z_j\right] = \sum_{j=1}^{D} z_j \mathbb{E}[A_{ij}] = \sum_{j=1}^{D} z_j \cdot 0 = 0$$

2. **Дисперсия:** Так как элементы A_{ij} взаимно независимы для всех j:

$$\mathsf{Var}(y_i) = \mathsf{Var}\left(\sum_{j=1}^{D} A_{ij} z_j\right) = \sum_{j=1}^{D} z_j^2 \mathsf{Var}(A_{ij}) = \sum_{j=1}^{D} z_j^2 \cdot 1 = \|z\|_2^2$$

Поскольку z — единичный вектор ($\|z\|_2 = 1$):

$$\mathsf{Var}(y_i) = 1$$

В силу свойства устойчивости нормального распределения (линейная комбинация независимых гауссиан строго гауссова):

$$y_i \sim \mathcal{N}(0,1), \quad \forall i \in \{1, \dots, k\}$$

Поскольку строки $a_1, \dots, a_k$ матрицы A генерируются независимо, величины $y_1, y_2, \dots, y_k$ являются **взаимно независимыми стандартными нормальными величинами**.

> **Геометрический смысл:** Стандартное многомерное гауссовское распределение сферически симметрично (изотропно). Его проекция на любое единичное одномерное направление z дает в точности стандартное нормальное распределение $\mathcal{N}(0,1)$. Исходная размерность D полностью исчезает из уравнений на этом шаге.

---

6. Доказательство JL: Шаг 2 — Концентрация распределения хи-квадрат

Квадрат нормы спроецированного вектора равен сумме независимых величин:

$$\|f(z)\|^2 = \frac{1}{k}\|Az\|^2 = \frac{1}{k}\sum_{i=1}^{k} y_i^2 = \frac{1}{k}S_k$$

где величина $S_k = \sum_{i=1}^{k} y_i^2$ подчиняется распределению **хи-квадрат с k степенями свободы**: $S_k \sim \chi^2(k)$.

Ее среднее равно $\mathbb{E}[S_k] = k$, следовательно, $\mathbb{E}\left[\frac{1}{k}S_k\right] = 1$. Оценим вероятность отклонения от среднего с помощью **метода Чернова**.

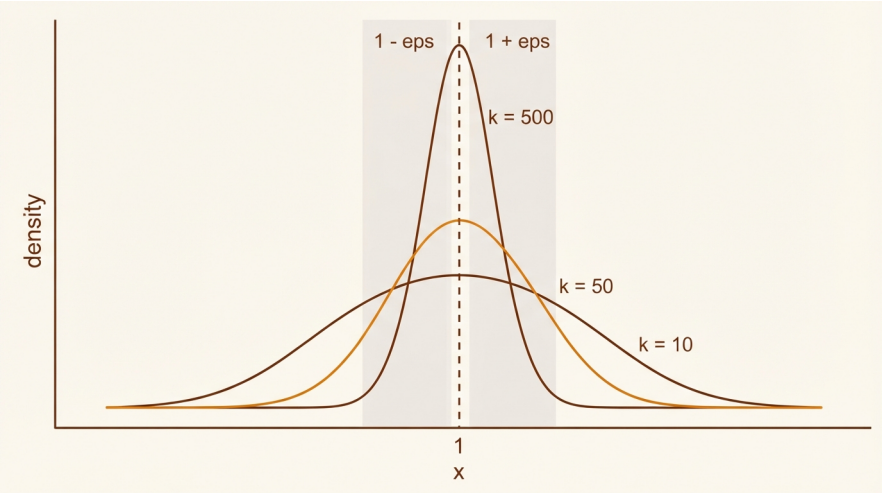


Рис. 4: нормированное на k хи-квадрат распределение с k степенями свободы

Оценка верхнего хвоста

Для любого вещественного параметра $t > 0$ применим неравенство Маркова к экспоненте:

$$\mathbb{P}\left(\frac{1}{k}S_k \geq 1+\varepsilon\right) = \mathbb{P}\left(S_k \geq k(1+\varepsilon)\right) = \mathbb{P}\left(e^{tS_k} \geq e^{tk(1+\varepsilon)}\right) \leq \frac{\mathbb{E}[e^{tS_k}]}{e^{tk(1+\varepsilon)}}$$

Вычислим производящую функцию моментов (MGF) для одной величины $y_i^2 \sim \chi^2(1)$:

$$\mathbb{E}[e^{ty_i^2}] = \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-y^2/2} e^{ty^2} dy = \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}(1-2t)} dy$$

Интеграл сходится при $1 - 2t > 0 \iff t < 1/2$. Сделав замену переменной $u = y\sqrt{1-2t}$:

$$\mathbb{E}[e^{ty_i^2}] = (1-2t)^{-1/2}$$

В силу независимости координат:

$$\mathbb{E}[e^{tS_k}] = \prod_{i=1}^{k} \mathbb{E}[e^{ty_i^2}] = (1-2t)^{-k/2}$$

Подставим полученную MGF в экспоненциальную оценку Чернова:

$$\mathbb{P}\left(\frac{1}{k}S_k \geq 1+\varepsilon\right) \leq \inf_{0<t<1/2} e^{-tk(1+\varepsilon)}(1-2t)^{-k/2} = \inf_{0<t<1/2} \left[(1-2t)^{-1} e^{-2t(1+\varepsilon)}\right]^{k/2}$$

Минимизируем функцию $g(t) = -(1+\varepsilon)t - \frac{1}{2}\ln(1-2t)$. Найдем ее производную по t:

$$g'(t) = -(1+\varepsilon) + \frac{1}{1-2t} = 0 \implies 1-2t = \frac{1}{1+\varepsilon} \implies t^* = \frac{\varepsilon}{2(1+\varepsilon)}$$

Условие $t^* < 1/2$ выполняется для любого $\varepsilon > 0$. Подставим t^* обратно:

$$1 - 2t^* = \frac{1}{1+\varepsilon}, \quad e^{-2t^*(1+\varepsilon)} = e^{-\varepsilon}$$

Следовательно:

$$\mathbb{P}\left(\frac{1}{k}S_k \geq 1+\varepsilon\right) \leq \left[(1+\varepsilon)e^{-\varepsilon}\right]^{k/2} = \exp\left(-\frac{k}{2}(\varepsilon - \ln(1+\varepsilon))\right)$$

Разложим функцию $h(\varepsilon) = \varepsilon - \ln(1+\varepsilon)$ в ряд Тейлора:

$$h(\varepsilon) = \frac{\varepsilon^2}{2} - \frac{\varepsilon^3}{3} + \ldots$$

Для всех $\varepsilon \in (0,1)$ справедливо строгое неравенство $\varepsilon - \ln(1+\varepsilon) \geq \frac{\varepsilon^2}{4}$. Таким образом:

$$\mathbb{P}\left(\frac{1}{k}S_k \geq 1+\varepsilon\right) \leq e^{-\frac{k\varepsilon^2}{8}}$$

Оценка нижнего хвоста

Аналогично, применяя неравенство Чернова для $t < 0$:

$$\mathbb{P}\left(\frac{1}{k}S_k \leq 1-\varepsilon\right) \leq \inf_{t>0} e^{tk(1-\varepsilon)}\mathbb{E}[e^{-tS_k}] \leq \left[(1-\varepsilon)e^{\varepsilon}\right]^{k/2} = \exp\left(-\frac{k}{2}(-\varepsilon - \ln(1-\varepsilon))\right)$$

Так как $-\varepsilon - \ln(1-\varepsilon) \geq \frac{\varepsilon^2}{2} \geq \frac{\varepsilon^2}{4}$, получаем:

$$\mathbb{P}\left(\frac{1}{k}S_k \leq 1-\varepsilon\right) \leq e^{-\frac{k\varepsilon^2}{8}}$$

Итоговая концентрация для одного вектора

По правилу объединения событий (Union Bound):

$$\mathbb{P}\left(\left|\frac{1}{k}\|Az\|^2 - 1\right| \geq \varepsilon\right) \leq \mathbb{P}\left(\frac{1}{k}S_k \geq 1+\varepsilon\right) + \mathbb{P}\left(\frac{1}{k}S_k \leq 1-\varepsilon\right) \leq 2e^{-\frac{k\varepsilon^2}{8}}$$

---

7. Доказательство JL: Шаг 3 — Union Bound по парам точек

Перейдем от одного вектора z к исходному множеству точек $X \subset \mathbb{R}^D$, $|X| = N$.

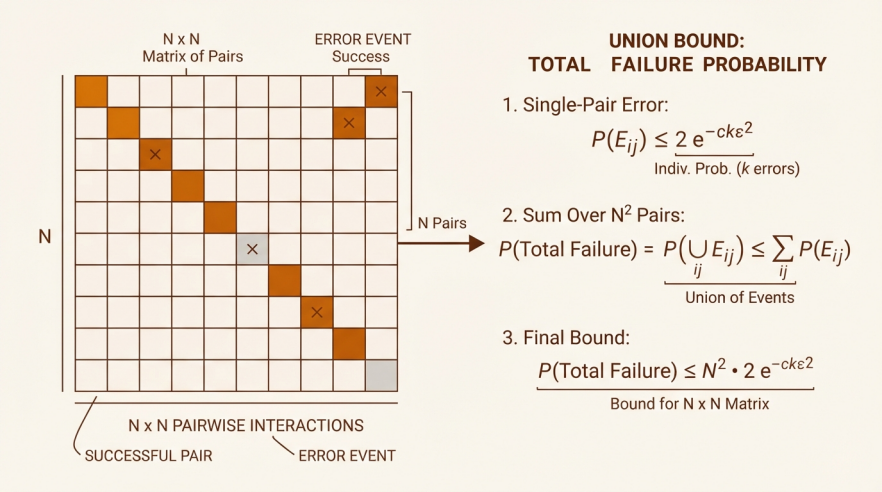


Рис. 5: Иллюстрация 7 к слайду

1. **Количество пар:** В множестве из N элементов общее число неупорядоченных пар равно:

$$\binom{N}{2} = \frac{N(N-1)}{2} < \frac{N^2}{2}$$

2. **Вероятность сбоя хотя бы на одной паре:** Обозначим за событие сбоя

$$E_{u,v} = \left\{\left|\frac{\|f(u)-f(v)\|^2}{\|u-v\|^2} - 1\right| \geq \varepsilon\right\}$$

По неравенству Буля:

$$\mathbb{P}(\text{сбой}) = \mathbb{P}\left(\bigcup_{u \neq v \in X} E_{u,v}\right) \leq \sum_{u \neq v \in X} \mathbb{P}(E_{u,v}) < \frac{N^2}{2} \cdot \left(2e^{-\frac{k\varepsilon^2}{8}}\right) = N^2 e^{-\frac{k\varepsilon^2}{8}}$$

3. **Ограничение вероятности ошибки малой величиной δ:** Потребуем, чтобы суммарная вероятность неудачи не превосходила заданного уровня $\delta \in (0, 1)$ (например, $\delta = 0.01$):

$$N^2 e^{-\frac{k\varepsilon^2}{8}} \leq \delta$$

Логарифмируя обе части:

$$2 \ln N - \frac{k\varepsilon^2}{8} \leq \ln \delta \iff \frac{k\varepsilon^2}{8} \geq 2 \ln N + \ln\left(\frac{1}{\delta}\right)$$

$$k \geq \frac{16 \ln N + 8 \ln(1/\delta)}{\varepsilon^2}$$

Если положить $\delta = \frac{1}{N}$, то $k \geq \frac{24 \ln N}{\varepsilon^2} = O\left(\frac{\ln N}{\varepsilon^2}\right)$.

Вывод доказательства: Мы доказали теорему существования методом Монте-Карло: случайная матрица из нормальных чисел $\mathcal{N}(0, 1)$ гарантированно удовлетворяет условию изометрии с вероятностью $\geq 1 - \delta$.

---

8. Практические варианты проекций: от плотного Гаусса к FJLT

Хотя гауссовские матрицы дают оптимальные математические гарантии, их прямое инженерное использование в production-системах не всегда эффективно.

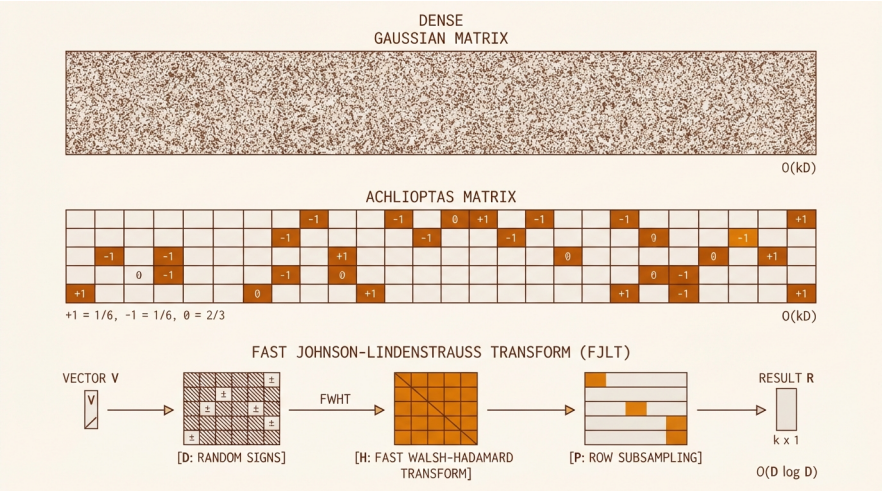


Рис. 6: Иллюстрация 8 к слайду

Ограничение плотной матрицы Гаусса

Вычисление проекции $y = Ax$ требует умножения матрицы $k \times D$ на плотный вектор размера D, что составляет $O(k \cdot D)$ вещественных операций умножения с накоплением (MAC). Для эмбеддинга $D = 4096$ и целевой размерности $k = 512$ это требует свыше 2×10^6 FLOP на каждый вектор, создавая задержку в миллисекунды при пакетной обработке.

1. Разреженные проекции Ачлиоптаса (Achlioptas, 2003)

Димитрис Ачлиоптас доказал, что непрерывное гауссовское распределение можно заменить дискретным распределением, сохраняющим второй и четвертый моменты:

$$A_{ij} = \sqrt{3} \times \begin{cases} +1, & \text{с вероятностью } 1/6 \\ 0, & \text{с вероятностью } 2/3 \\ -1, & \text{с вероятностью } 1/6 \end{cases}$$

* **Преимущества:** * Матрица на 66.7% состоит из нулей. * Умножение вектора на такую матрицу ускоряется в 3 раза. * Вместо инструкций умножения с плавающей точкой выполняются целочисленные сложения и вычитания (сложение координат вектора с соответствующими знаками), что снижает энергопотребление и энергоемкость кэшей процессора.

2. Fast Johnson-Lindenstrauss Transform (FJLT)

Айлон и Чазелл (Ailon & Chazelle, 2006) предложили факторизацию проекционной матрицы:

$$A = P \cdot H \cdot D$$

Где: * $D \in \mathbb{R}^{D \times D}$ — случайная диагональная матрица, где диагональные элементы $D_{ii} \in \{-1, +1\}$ равновероятны (матрица рандомизации знаков/фаз). * $H \in \mathbb{R}^{D \times D}$ — нормированная матрица Адамара размера $D \times D$ ($H_{ij} = \pm 1/\sqrt{D}$), вычисляемая через алгоритм **Fast Walsh-Hadamard Transform (FWHT)** за $O(D \log D)$ действий. * $P \in \mathbb{R}^{k \times D}$ — разреженная случайная матрица выборки координат.

Вычислительная сложность: Падает с $O(kD)$ до $O(D \log D + k \log^2 N)$. Каскад $H \cdot D$ равномерно распределяет энергию вектора по всем базисным направлениям (разрушает разреженность и пиковые компоненты), после чего достаточно применить тривиальное разреженное прореживание P.

---

9. Применение 1: Масштабируемый векторный поиск (ANN) в RAG-системах

Векторные базы данных лежат в основе Retrieval-Augmented Generation (RAG). Однако масштабирование векторного поиска до миллиардов документов наталкивается на физические лимиты оборудования.

Проблема масштабирования по памяти и пропускной способности

Пусть коллекция содержит $N = 10^7$ (10 миллионов) пассажей. При использовании стандартного эмбеддера `text-embedding-3-small` от OpenAI размерность вектора составляет $D = 1536$ в формате FP32 (4 байта на число):

$$\text{Объем сырых данных} = 10^7 \times 1536 \times 4 \text{ байта} \approx 61.44 \text{ ГБ}$$

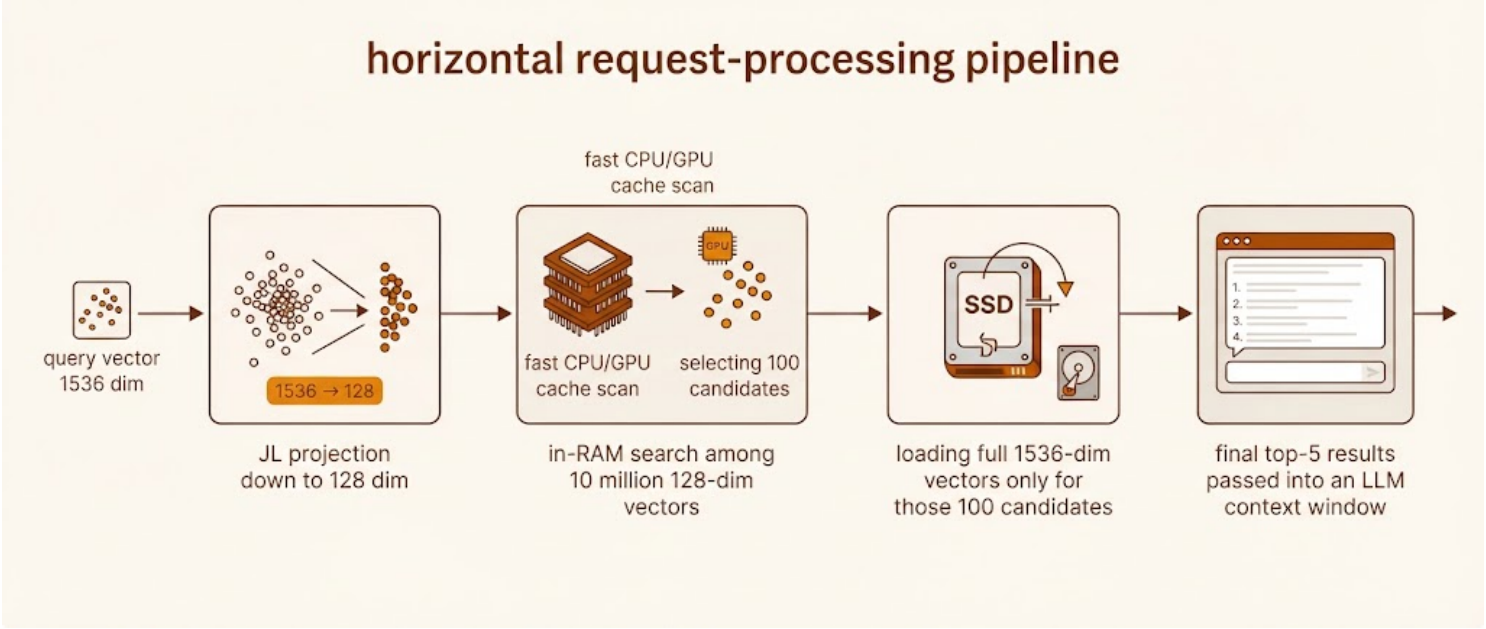


Рис. 7: Иллюстрация 9 к слайду

Для хранения только индексов требуется оперативная память целого сервера. Линейный поиск ближайших соседей (k-NN) требует выполнения 10^7 скалярных произведений размерности 1536 на каждый запрос пользователя. Даже на специализированных GPU это приводит к неприемлемым задержкам и утилизации пропускной способности шины памяти.

Двухстадийная архитектура поиска (Approximate Nearest Neighbors)

Случайные проекции позволяют построить эффективный каскадный фильтр:

```
[Пользовательский запрос q] ──> [JL-проекция в k=128]
                                          |
                                          ▼
                          [Стадия 1: Грубый поиск в RAM]
                          Быстрое сканирование базы сжатых векторов
                          Отбор топ-M кандидатов (M = 100)
                                          |
                                          ▼
                          [Стадия 2: Точное переранжирование]
                    Чтение 100 исходных векторов (D = 1536) с диска/SSD
                          Вычисление точного косинусного сходства
                                          |
                                          ▼
                                [Итоговый топ-K для LLM]
```

1. **Стадия 1 (Coarse filtering):** Векторы сжимаются из $D = 1536$ в $k = 128$ измерений. Объем базы падает с 61.44 ГБ до 5.12 ГБ (а при переводе в FP16 — до 2.56 ГБ), что целиком помещается в L3-кэш или быстрый RAM. Поиск топ-M кандидатов ($M \approx 100$) происходит на два порядка быстрее.
2. **Стадия 2 (Exact Reranking):** Полные векторы для отобранных 100 кандидатов поднимаются из холодного хранилища, и между ними вычисляется точное скалярное произведение в исходном

пространстве $D = 1536$.

Разрыв между теорией и практикой: Внутренняя размерность

По теоретической оценке JL-леммы:

$$k \geq \frac{16 \ln(10^7)}{0.1^2} \approx \frac{16 \times 16.11}{0.01} \approx 25\,700$$

Кажется, что k должно быть больше исходного $D = 1536$! Почему же на практике отлично работает $k = 128$?

Ответ: Теоретическая граница JL защищает **худший случай** (worst-case), когда данные распределены произвольно. Реальные семантические эмбеддинги естественного языка лежат на компактных гладких подмногообразиях низкой размерности (Manifold Hypothesis). **Внутренняя размерность (intrinsic dimensionality)** таких распределений обычно лежит в пределах от 20 до 50. Поэтому проекция в $k = 128$ сохраняет топологию взаимного соседства практически без потерь (Recall@K $> 98\%$).

---

10. SimHash и угловой Locality-Sensitive Hashing (LSH)

Locality-Sensitive Hashing (LSH) — семейство алгоритмов, в которых хэш-функции намеренно конструируются так, чтобы вероятность коллизии монотонно зависела от метрического расстояния между объектами:

$$\mathbb{P}(h(u) = h(v)) = f(\mathsf{sim}(u, v))$$

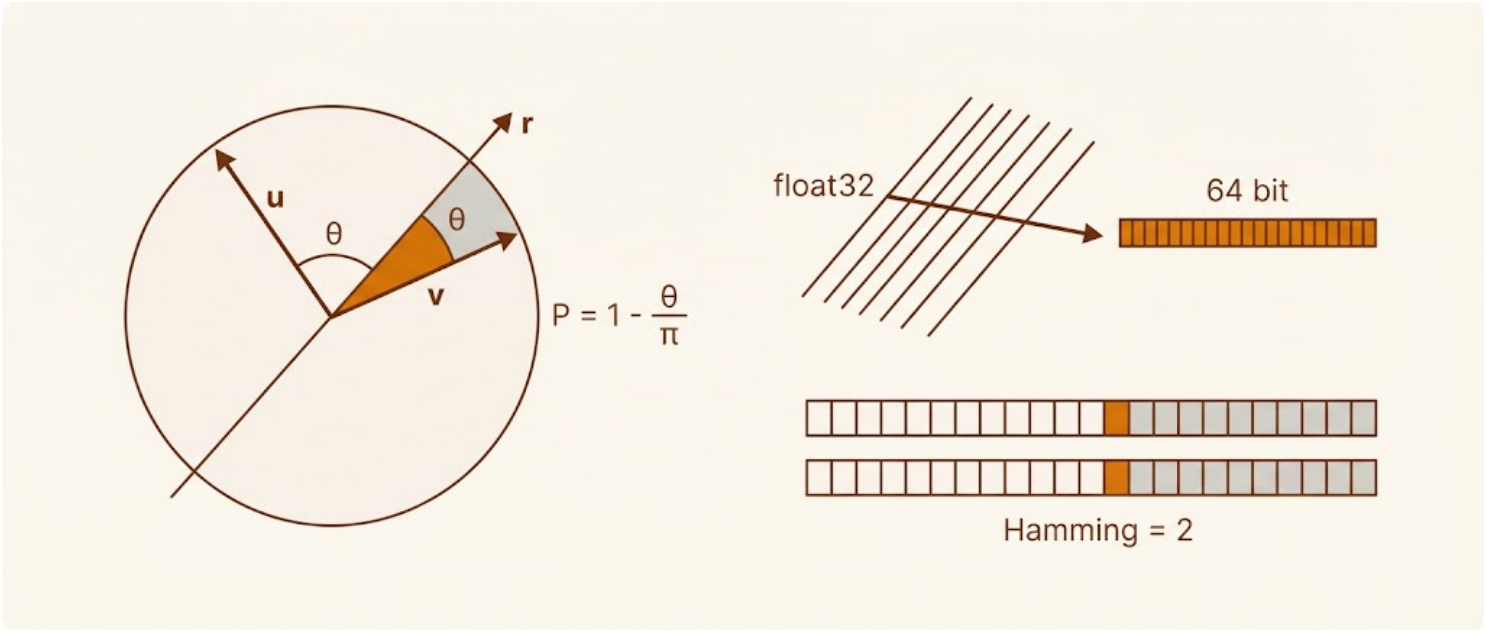


Рис. 8: Иллюстрация 10 к слайду

Метод случайных гиперплоскостей (Charikar, 2002)

Пусть $r \sim \mathcal{N}(0, I_D)$ — вектор нормали к гиперплоскости, проходящей через начало координат. Определим бинарную хэш-функцию:

$$h_r(x) = \text{sign}(\langle r, x \rangle) \in \{-1, +1\}$$

Геометрически гиперплоскость делит евклидово пространство на два полупространства.

Теорема Гёманса–Вильямсона / Чарикара

> **Теорема:** Пусть $\theta(u, v) = \arccos\left(\frac{u^\top v}{\|u\|\|v\|}\right)$ — угол между векторами u и v. Тогда вероятность того, что случайная гиперплоскость разделит эти векторы, строго пропорциональна углу между ними:
>
> $$\mathbb{P}(h_r(u) \neq h_r(v)) = \frac{\theta(u, v)}{\pi}$$
>
> Соответственно, вероятность коллизии:
>
> $$\mathbb{P}(h_r(u) = h_r(v)) = 1 - \frac{\theta(u, v)}{\pi}$$

Геометрический вывод:

1. Векторы u и v натянуты на двумерную плоскость $\text{span}(u, v)$.
2. В силу сферической изотропности нормального распределения ортогональная проекция случайного вектора r на эту плоскость распределена равномерно по углам окружности $[0, 2\pi)$.
3. Гиперплоскость разделяет u и v тогда и только тогда, когда вектор нормали r попадает в сегмент между перпендикулярами к этим векторам.
4. Суммарный раствор этих двух симметричных секторов равен 2θ.
5. Вероятность попадания равна отношению меры угла секторов к полной длине окружности: $\frac{2\theta}{2\pi} = \frac{\theta}{\pi}$.

Формирование сигнатуры SimHash и аппаратное ускорение

Выберем b независимых векторов нормалей $r_1, \ldots, r_b$. Сконкатенируем результаты:

$$\text{SimHash}(x) = [\text{sign}(r_1^\top x), \text{sign}(r_2^\top x), \ldots, \text{sign}(r_b^\top x)] \in \{0, 1\}^b$$

Косинусное сходство векторов в $\mathbb{R}^D$ транслируется в **расстояние Хэмминга** на b-битных словах:

$$\mathbb{E}[d_H(\text{SimHash}(u), \text{SimHash}(v))] = b \cdot \frac{\theta(u, v)}{\pi}$$

Аппаратный выигрыш: Расстояние Хэмминга между двумя 64-битными хэшами вычисляется за **один процессорный такт** на уровне ассемблерных инструкций:

```
uint64_t dist = __builtin_popcountll(hash1 ^ hash2);
// XOR выявляет несовпадения, POPCNT считает биты
```

Это на 3–4 порядка быстрее вычисления косинусного расстояния с плавающей точкой в $\mathbb{R}^{1536}$.

---

11. Random Projection Trees (RP-Trees)

Классические структуры пространственного индексирования (например, k-d деревья) рекурсивно разбивают пространство плоскостями, параллельными исходным координатным осям.

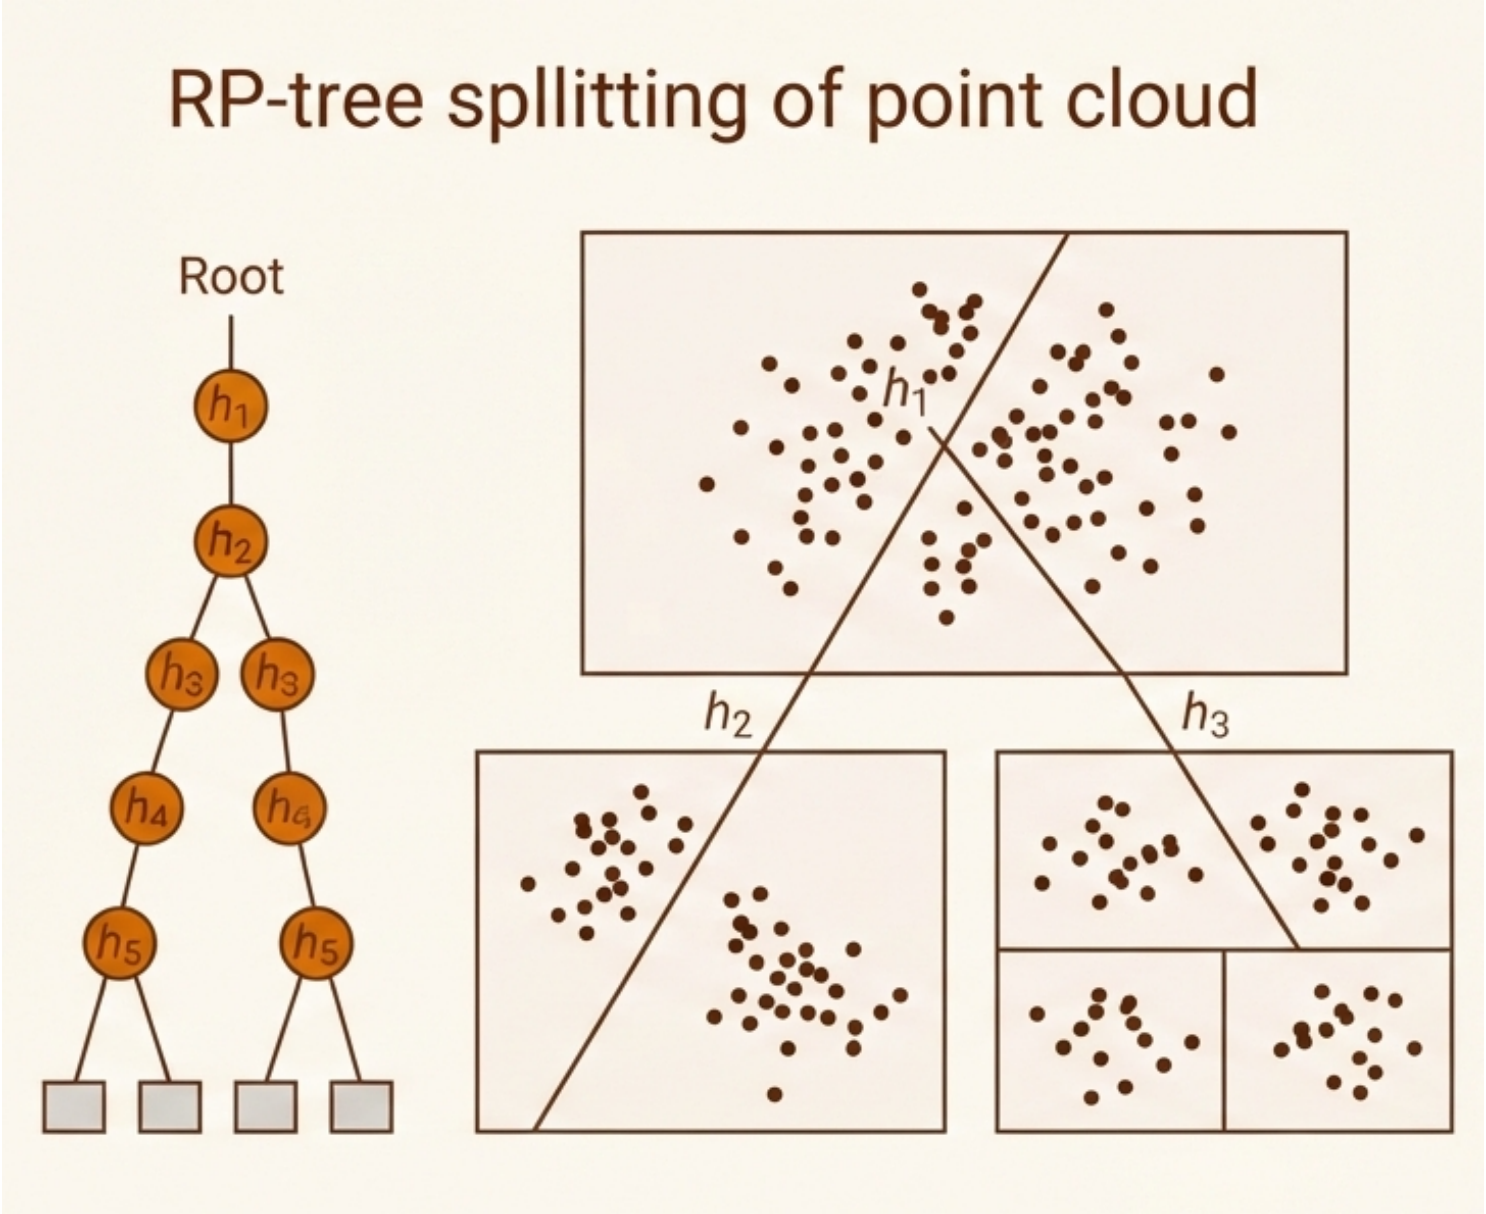


Рис. 9: Иллюстрация 11 к слайду

Недостаток k-d деревьев в высокой размерности

В $\mathbb{R}^D$ при $D > 20$ число ячеек растет как 2^D. Большинство листьев дерева оказываются пустыми, а траектория поиска вынуждена посещать почти все ветви дерева, вырождаясь в алгоритм прямого перебора $O(N)$. Кроме того, координатные оси почти никогда не совпадают с направлениями максимальной дисперсии данных.

Принцип работы Random Projection Tree (Dasgupta & Freund, 2008)

В каждом узле дерева:

1. Генерируется случайное единичное направление $r \sim \mathcal{N}(0, I_D)$.
2. Все объекты в данном узле проецируются на это направление: $p_i = \langle r, x_i \rangle \in \mathbb{R}$.
3. Вычисляется медиана проекций: $m = \text{median}(\{p_i\})$.
4. Данные делятся гиперплоскостью:

$$\text{Left} = \{x \mid \langle r, x \rangle \leq m\}, \quad \text{Right} = \{x \mid \langle r, x \rangle > m\}$$

Теоретическое свойство: Скорость уменьшения диаметра ячеек в RP-Tree зависит не от размерности объемлющего пространства D, а от **внутренней размерности подмногообразия данных** $d_{\text{intrinsic}}$. Дерево автоматически адаптируется к геометрии данных без необходимости вычисления дорогостоящего PCA на каждом разбиении.

---

12. Применение 2: Экстремальное квантование больших языковых моделей (LLM)

Инференс современных языковых моделей упирается в пропускную способность памяти (Memory Bandwidth Bound).

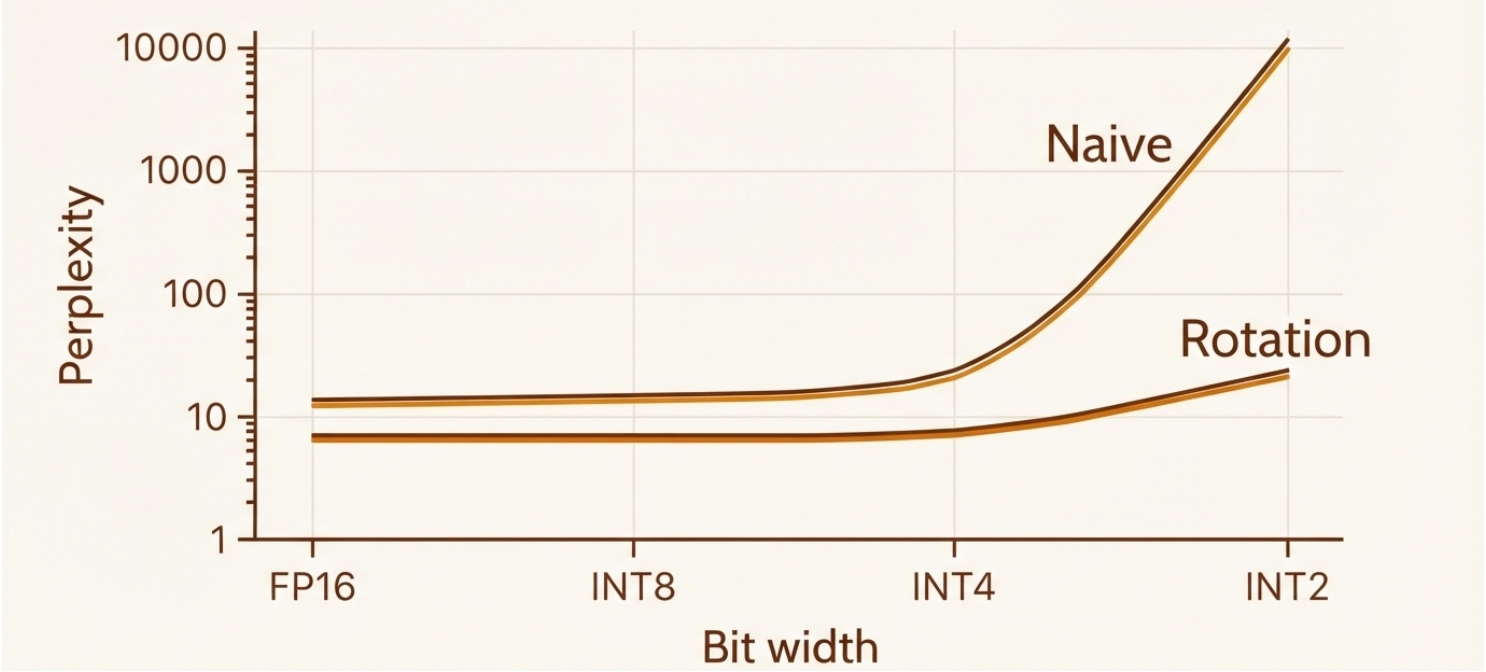


Рис. 10: График зависимости Perplexity от разрядности

Проблема объема видеопамяти (VRAM)

Модель LLaMA-3-70B содержит около 70×10^9 параметров: * В базовом формате FP16 (2 байта на вес) только для хранения весов требуется:

$$70 \times 10^9 \times 2 \text{ байта} \approx 140 \text{ ГБ VRAM}$$

Это требует минимум двух карт NVIDIA A100/H100 (по 80 ГБ каждая), что делает локальное использование модели чрезвычайно дорогостоящим. * При 4-битном квантовании (INT4) размер модели сокращается до $\approx$ 36–38 ГБ (модель помещается на одну потребительскую карту RTX 4090 24GB в паре

с системным RAM или на один чип Apple Silicon M-серии). * При 2-битном квантовании (INT2) модель занимает менее 20 ГБ, запускаясь на стандартных ноутбуках.

Парадигмы квантования

1. **Weight-Only (W4A16, GPTQ, AWQ):** Квантуются только матрицы весов. Активации токенов остаются в FP16. Перед выполнением операции умножения веса на лету распаковываются из INT4 в FP16. Это экономит память, но тензорные ядра по-прежнему выполняют инструкции FP16. Ускорение вычислений ограничено.
2. **Weight-Activation (W4A4, SmoothQuant, QuaRot):** И веса, и матрицы активаций квантуются до INT4. Умножение матриц выполняется напрямую аппаратно на целочисленных тензорных ядрах (DP4A / INT4 Tensor Core GEMM). Это дает **ускорение вычислений в 2–4 раза** по сравнению с FP16 при четырехкратном сжатии памяти.

Стена квантования (Quantization Cliff)

При попытке сжать активации до уровня INT4 в моделях масштаба > 6.7B параметров перплексия (мера ошибки языковой модели) скачкообразно стремится к бесконечности: модель полностью деградирует и генерирует бессвязный набор символов.

---

13. Анатомия выбросов (Outlier Features) в трансформерах

Причина срыва квантования была открыта в работе Т. Деттмерса (Dettmers et al., 2022, `LLM.int8()`).

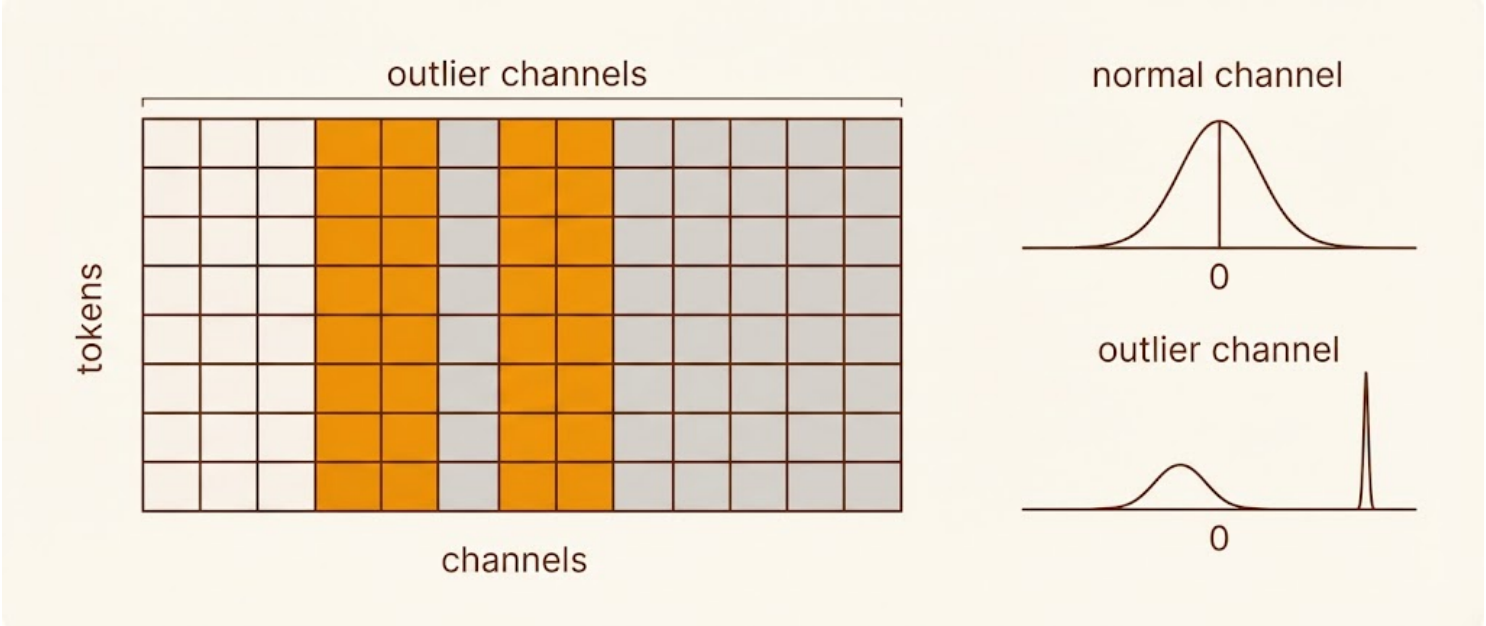


Рис. 11: Иллюстрация 13 к слайду

Феномен выбросов

При преодолении порога в 6.7 миллиардов параметров в трансформерах происходит фазовый переход:

- В $0.01\% - 0.1\%$ **скрытых каналов** (например, в 2–4 координатах из 4096) значения активаций внезапно достигают гигантских величин: от ± 50 до ± 150.
- В остальных 99.9% **каналов** величины активаций стабильно лежат в интервале $[-1.5, +1.5]$.
- Разница по амплитуде достигает 100 раз, а по энергии (квадрату амплитуды) — до $10\,000$ раз!

Свойства каналов-выбросов

1. **Жесткая координатная привязка:** Выбросы не распределены хаотично по токенам. Они привязаны к определенным индексам скрытого состояния (например, строго в 137-м и 2049-м каналах для всех токенов последовательности).
2. **Критическая функциональная роль:** Искусственное обнуление этих каналов полностью уничтожает связность генерации.
3. **Механизм возникновения:** Архитектура Multi-Head Attention содержит функцию Softmax:

$$\text{Softmax}(S)_{ij} = \frac{e^{S_{ij}}}{\sum_k e^{S_{ik}}}$$

Чтобы отбросить нерелевантный контекст, сети необходимо сформировать огромные отрицательные логиты перед Softmax. Для этого промежуточные слои обучаются использовать выделенные скрытые каналы как постоянные масштабные регуляторы (так называемые **attention sinks**).

---

14. Почему выбросы разрушают равномерное квантование

Рассмотрим симметричное квантование строки активаций $X \in \mathbb{R}^{1\times d}$ в 4-битные знаковые целые числа: диапазон $[-7, 7]$.

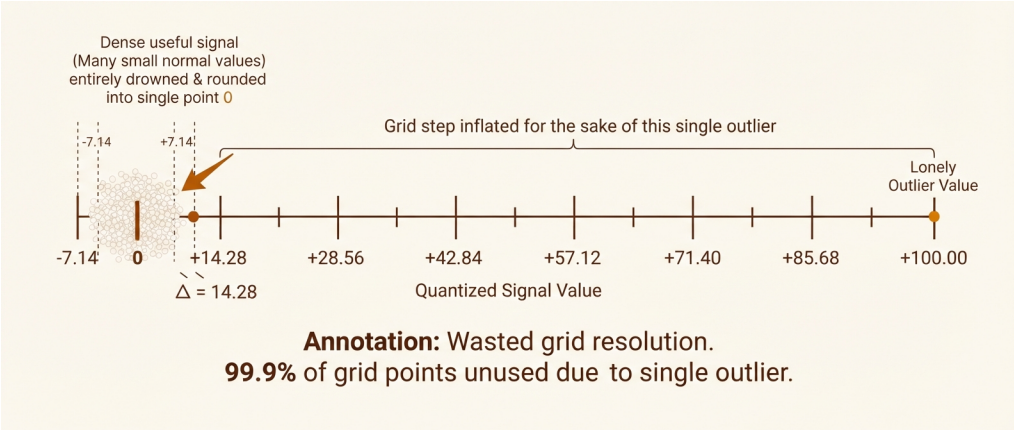


Рис. 12: Иллюстрация 14 к слайду

Схема квантования

Шаг сетки (scale factor) Δ настраивается на абсолютный максимум вектора:

$$\Delta = \frac{X_{\text{max}}}{2^{b-1} - 1} = \frac{\max_j |X_j|}{7}$$

Операция квантования и последующей деквантования:

$$X_{\text{quant}} = \text{clip}\left(\left\lfloor \frac{X}{\Delta} \right\rceil, -7, 7\right), \quad \hat{X} = X_{\text{quant}} \cdot \Delta$$

Механика катастрофы

Пусть в строке присутствует один выброс с $X_{\text{max}} = 100$:

$$\Delta = \frac{100}{7} \approx 14.28$$

Однако полезные 99.9% активаций лежат в диапазоне $[-1.5, +1.5]$. Проквантуем типичное информативное значение $x = 1.4$:

$$X_{\text{quant}} = \left\lfloor \frac{1.4}{14.28} \right\rceil = \lfloor 0.098 \rceil = 0$$

$$\hat{x} = 0 \cdot 14.28 = 0$$

> **Итог:** Из-за адаптации масштаба к одной аномальной координате **все остальные 4095 чисел округляются в ноль**. Информационная емкость скрытого слоя стирается.

Анализ дисперсии шума квантования

Шум квантования равномерной сетки моделируется как случайная величина, распределенная на отрезке $[-\Delta/2, \Delta/2]$. Его дисперсия:

$$\sigma^2 = \frac{\Delta^2}{12} = \frac{X_{\text{max}}^2}{12 \cdot 7^2} = \frac{X_{\text{max}}^2}{588}$$

Среднеквадратичная ошибка (MSE) слоя квадратично зависит от величины максимального выброса X_{max}:

$$\text{Рост } X_{\text{max}} \text{ в } 50 \text{ раз} \implies \text{Рост ошибки MSE в } 50^2 = \textbf{2500} \text{ раз!}$$

---

15. Incoherence Processing: Ортогональная инвариантность линейного слоя

Ключевая идея преодоления проблемы выбросов (методы **QuIP**, **QuaRot**, **SpinQuant**, 2023–2024 гг.) заключается в преобразовании некогерентности (Incoherence Processing) через поворот пространства.

Алгебраическая инвариантность

Рассмотрим стандартный матричный слой нейросети:

$$Y = XW$$

где $X \in \mathbb{R}^{n \times d}$ — матрица активаций, $W \in \mathbb{R}^{d \times m}$ — матрица весов слоя. Пусть $R \in \mathbb{R}^{d \times d}$ — произвольная ортогональная матрица, для которой выполняется $RR^\top = I_d$. Вставим это тождество между X и W:

$$Y = XI_dW = X(RR^\top)W = (XR)(R^\top W) = \tilde{X}\tilde{W}$$

где:

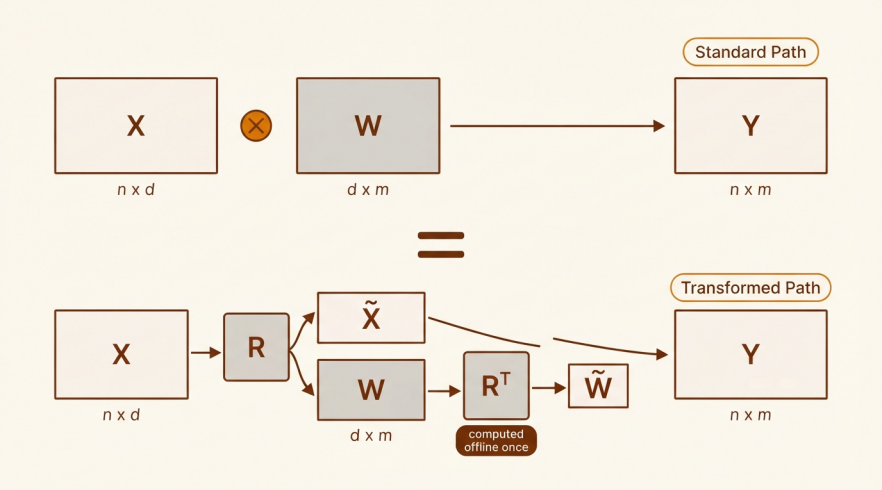


Рис. 13: Иллюстрация 15 к слайду

- $\tilde{X} = XR$ — повернутые активации,
- $\tilde{W} = R^\top W$ — повернутые веса.

Почему это меняет процесс квантования?

1. **Тождественная эквивалентность:** До процедуры квантования результат матричного умножения $\tilde{X}\tilde{W}$ математически строго равен XW. Погрешность преобразования равна нулю.
2. **Оффлайн-обработка весов:** Повернутые веса $\tilde{W} = R^\top W$ вычисляются заранее один раз на этапе подготовки модели, квантуются в INT4 и сохраняются на диск. В процессе инференса никакого оверхеда на поворот весов нет!
3. **Разрушение координатной структуры:** Выброс — это свойство стандартного канонического базиса, когда вектор коллинеарен базисному орту e_j. Ортогональное вращение ориентирует векторы так, чтобы они располагались под одинаковыми углами ко всем координатным осям.

---

16. Математика подавления выбросов: Концентрация на сфере

Покажем аналитически, как ортогональное вращение размывает локализованный всплеск амплитуды.

Математическая модель

Пусть вектор активаций $x \in \mathbb{R}^{1\times d}$ содержит экстремальный выброс амплитуды M в фиксированном канале j^*:

$$x = (0, \dots, 0, M, 0, \dots, 0), \quad \|x\|_2 = M$$

Пусть R — случайная ортогональная матрица, распределенная по мере Хаара на группе $O(d)$. Рассмотрим повернутый вектор $\tilde{x} = xR$: Его k-я компонента:

$$\tilde{x}_k = \sum_{j=1}^{d} x_j R_{jk} = M \cdot R_{j^*k}$$

где R_{j^*k} — элемент строки случайной ортогональной матрицы.

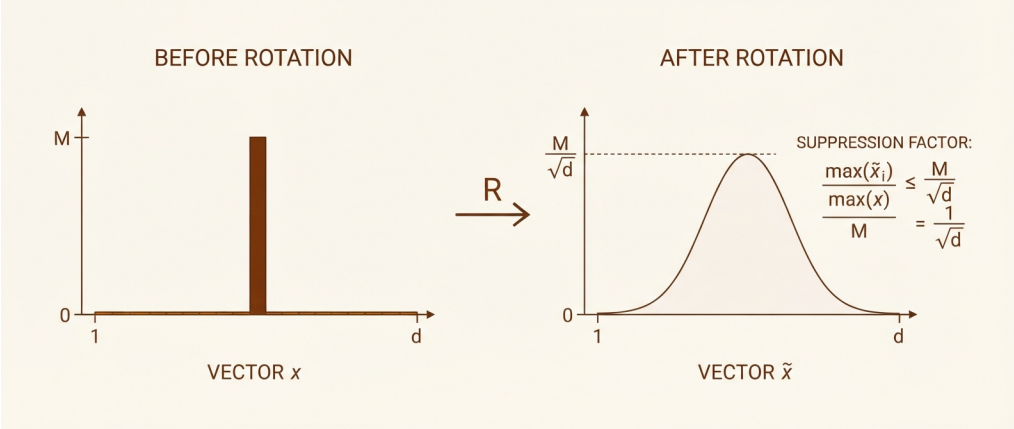


Рис. 14: Иллюстрация 16 к слайду

Концентрация меры на гиперсфере

Строка ортогональной матрицы Хаара представляет собой случайный единичный вектор на сфере $\mathbb{S}^{d-1}$. Как известно из геометрии высокой размерности, проекция равномерно распределенного на сфере вектора на любую фиксированную координатную ось асимптотически распределена как гауссиана с дисперсией $1/d$:

$$R_{j^*k} \approx \mathcal{N}\left(0, \frac{1}{d}\right)$$

Отсюда координаты повернутого вектора ведут себя как независимые случайные величины:

$$\tilde{x}_k \sim \mathcal{N}\left(0, \frac{M^2}{d}\right)$$

Энергия выброса M^2, запертая ранее в одном канале, равномерно распределилась по всем d измерениям!

Оценка супремума амплитуды (экстремальные значения гауссиан)

Найдем математическое ожидание максимума абсолютных значений компонент $\tilde{x}$. Для d случайных величин $Z_k \sim \mathcal{N}(0, \sigma^2)$ справедлива асимптотическая оценка:

$$\mathbb{E}\left[\max_{k=1..d} |Z_k|\right] \leq \sigma\sqrt{2\ln(2d)}$$

Подставляя $\sigma = \frac{M}{\sqrt{d}}$:

$$\mathbb{E}\left[\max_{k=1..d} |\tilde{x}_k|\right] \leq \frac{M}{\sqrt{d}}\sqrt{2\ln(2d)} = M\sqrt{\frac{2\ln(2d)}{d}}$$

Численный пример для трансформера ($d = 4096$):

$$\text{Коэффициент подавления пика} = \sqrt{\frac{2\ln(8192)}{4096}} = \sqrt{\frac{2 \times 9.01}{4096}} = \sqrt{\frac{18.02}{4096}} \approx \frac{1}{15.08}$$

* **Максимальная амплитуда выброса падает более чем в 15 раз!** (Если $M = 100$, то в повернутом пространстве $\max |\tilde{x}_k| \approx 6.6$). * Поскольку дисперсия ошибки квантования пропорциональна квадрату максимума, шум квантования падает в:

$$15.08^2 \approx \textbf{227} \text{ раз!}$$

* **Итог:** После вращения вектор активаций становится однородным (псевдослучайным), и 4-битная равномерная сетка квантования кодирует все его координаты без зануления полезного сигнала.

---

17. Вычислительная эффективность: Преобразование Уолша–Адамара

Использование плотной случайной матрицы Хаара $R \in \mathbb{R}^{d \times d}$ неприменимо на практике: умножение активаций XR на каждом слое требует $O(d^2)$ операций, что нивелирует ускорение от перевода тензорных ядер в INT4.

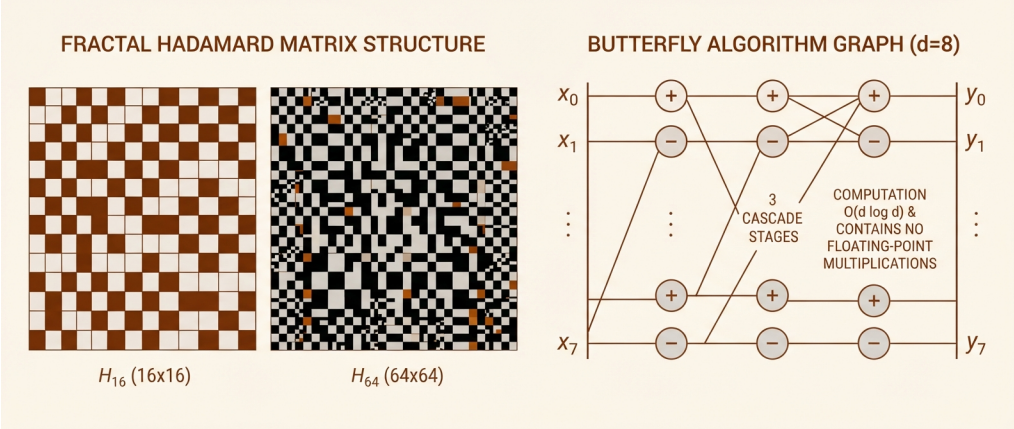


Рис. 15: Иллюстрация 17 к слайду

Решение: Рандомизированное преобразование Уолша–Адамара (RHT)

Вместо плотной случайной матрицы берется структурированная псевдослучайная ортогональная матрица:

$$R = \frac{1}{\sqrt{d}} H_d \cdot D$$

где: * $D = \text{diag}(\pm 1, \dots, \pm 1)$ — случайная диагональная знаковая матрица, * H_d — матрица Адамара размера $d \times d$ ($d = 2^m$), строящаяся рекурсивно через кронекерово произведение:

$$H_1 = (1), \quad H_2 = \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}, \quad H_{2^m} = H_2 \otimes H_{2^{m-1}}$$

Свойства матрицы Адамара:

1. **Строгая ортогональность:**

$$RR^\top = \left(\frac{1}{\sqrt{d}} H_d D\right)\left(\frac{1}{\sqrt{d}} D H_d^\top\right) = \frac{1}{d} H_d D^2 H_d = \frac{1}{d} H_d I_d H_d = \frac{1}{d}(d I_d) = I_d$$

2. **Быстрое преобразование (Fast Walsh-Hadamard Transform, FWHT):** Благодаря структуре «бабочки» умножение вектора на матрицу H_d не требует умножений с плавающей точкой вообще! Оно состоит исключительно из **сложений и вычитаний** и выполняется за:

$$O(d \log_2 d) \text{ операций}$$

Вычислительный выигрыш

Сравним операции для размерности скрытого слоя LLaMA $d = 4096$: * Плотная матрица: $d^2 = 4096^2 = 16\,777\,216$ операций с плавающей точкой. * Fast Walsh-Hadamard Transform: $d \log_2 d = 4096 \times 12 = 49\,152$ операции сложения/вычитания. * **Ускорение преобразования:**

$$\frac{16\,777\,216}{49\,152} \approx \textbf{341} \text{ раз!}$$

Аппаратная реализация

На современных GPU алгоритм FWHT реализуется внутри разделяемой памяти (Shared Memory / SRAM) потокового мультипроцессора (SM). Преобразование вектора токена выполняется менее чем за одну микросекунду и объединяется с операцией LayerNorm/RMSNorm (kernel fusion). Дополнительные накладные расходы на вращение активаций в рантайме составляют **менее 1.5%** общего времени инференса модели, обеспечивая чистый прирост скорости за счет целочисленных INT4 GEMM.