# Теория случайных матриц в ML: Закон Марченко–Пастура, переход BBP и спектры слоев нейросетей

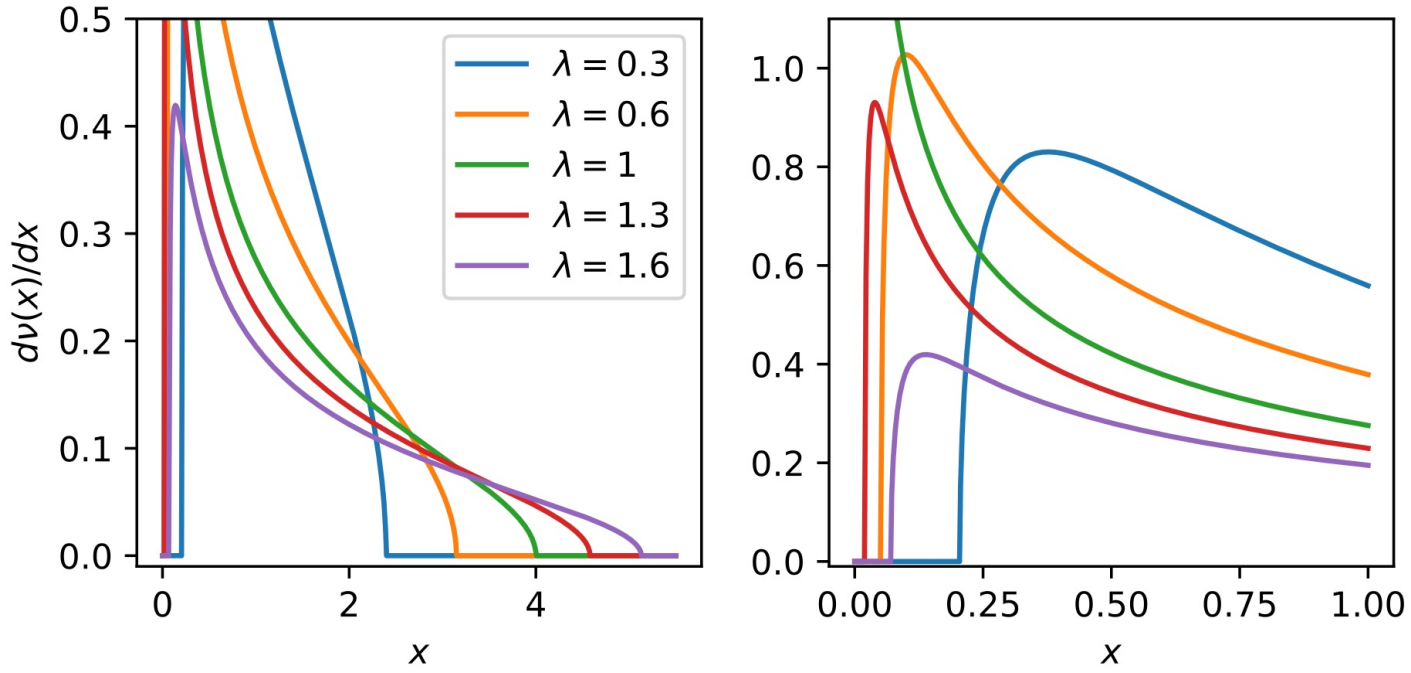



Рис. 1: Распределение Марченко–Пастура

## Введение

Современное глубокое обучение (Deep Learning) оперирует сверхпараметризованными моделями: число весов в современных нейросетях на порядки превосходит число обучающих примеров, а размерность промежуточных векторных представлений (эмбеддингов) достигает десятков тысяч. В этих условиях классическая многомерная статистика и интуиция, основанная на предположении о фиксированной размерности данных, терпят крах.

Теория случайных матриц (Random Matrix Theory, RMT), первоначально созданная физиками-теоретиками (Юджином Вигнером, Фрименом Дайсоном) в 1950–1960-х годах для описания статистических свойств уровней энергии тяжелых атомных ядер (таких как уран), сегодня стала фундаментом для понимания высокоразмерного машинного обучения. Как и в физике ядра, где точный гамильтониан системы сотен взаимодействующих нуклонов неизвестен, матрицы весов и матрицы ковариаций признаков в нейросетях ведут себя не как случайный набор разрозненных чисел, а подчиняются строгим спектральным универсальным законам.

Настоящий конспект посвящен изучению спектральных законов: от чистого случайного шума (закон Марченко–Пастура) и условий детектирования полезного сигнала (фазовый переход Байка–Бен Аруса–Пеше) до анализа структуры реальных весов обученных глубоких сетей (теория тяжелых хвостов Мартина–Махони).

## Содержание

- **Кризис размерности:** почему выборочная ковариация ломается в режиме $p \sim n$
- **Универсальный предел шума:** закон Марченко–Пастура и связь со спектральной плотностью
- **Фазовый переход BBP (Baik–Ben Arous–Péché):** фундаментальный предел детектирования сигнала в PCA
- **Спектральная диагностика весов нейросетей:** теория тяжелых хвостов Мартина–Махони (HTSR) без валидационных данных

#### Математический базис: спектральные свойства матриц

Перед погружением в высокоразмерную теорию зафиксируем ключевые понятия линейной алгебры:

1. **Спектр симметричной матрицы:** Для вещественной симметричной матрицы ковариации $\Sigma \in \mathbb{R}^{p \times p}$ спектральная теорема гарантирует существование ортонормированного базиса из собственных векторов $v_i$ и вещественных собственных значений $\lambda_1 \geq \lambda_2 \geq ... \geq \lambda_p$:

$$\Sigma v_i = \lambda_i v_i, \quad \Sigma = V \Lambda V^T = \sum_{i=1}^{p} \lambda_i v_i v_i^T$$

   Собственные числа характеризуют дисперсию данных вдоль направлений главных осей $v_i$.
2. **Сингулярные числа прямоугольной матрицы:** Матрицы данных $X \in \mathbb{R}^{p \times n}$ и матрицы весов межслойных соединений $W \in \mathbb{R}^{N \times M}$ прямоугольны. Сингулярное разложение (SVD) имеет вид $W = USV^T$, где $s_i \geq 0$ — сингулярные числа. Собственные значения симметричной матрицы Грама/ковариации $WW^T$ или $W^TW$ равны квадратам сингулярных чисел: $\lambda_i = s_i^2$.

Цель курса — связать микроскопические случайные флуктуации отдельных элементов матриц с макроскопическими свойствами всей системы.

---

## Кризис классической статистики: High-Dimensional Regime

В классической статистике XIX–XX веков неявно принималась аксиома фиксированной размерности пространства признаков:

- **Классический асимптотический режим:** Размерность пространства параметров $p$ фиксирована, а объем выборки стремится к бесконечности ($n \to \infty$). В этом пределе Закон больших чисел гарантирует поточечную и спектральную состоятельность выборочной ковариационной матрицы $\hat{\Sigma}_n$:

$$\hat{\Sigma}_n = \frac{1}{n} \sum_{i=1}^{n} x_i x_i^T \xrightarrow{P} \Sigma, \quad \|\hat{\Sigma}_n - \Sigma\|_2 \to 0$$

где $\|\cdot\|_2$ — спектральная (операторная) норма. Все собственные значения и собственные векторы выборочной матрицы сходятся к своим истинным популяционным значениям.

- **Современный высокоразмерный режим (Колмогоровский режим):**

$$p \to \infty, \quad n \to \infty, \quad \frac{p}{n} \to \gamma \in (0, \infty)$$

Число независимых элементов, подлежащих оценке в симметричной ковариационной матрице, составляет $p(p+1)/2 \sim \mathcal{O}(p^2)$. При этом весь доступный объем информации содержится в матрице данных размера $p \times n$. Если $p \sim n$, число неизвестных параметров имеет тот же порядок или даже превосходит общее число наблюдаемых скалярных измерений.

- **Феномен распада оценки:** Пусть истинные данные представляют собой абсолютно нескоррелированный многомерный стандартный белый шум: $\Sigma = I_p$. Каждое отдельное внедиагональное выборочное скалярное произведение мало: $\frac{1}{n} x_j^T x_k \sim \mathcal{O}(1/\sqrt{n})$. Однако совокупный эффект всех $\mathcal{O}(p^2)$ внедиагональных элементов кардинально деформирует геометрию матрицы:

$$\|\hat{\Sigma}_n - I_p\|_2 \not\to 0$$

Выборочная ковариация **никогда не сходится к единичной матрице по операторной норме**.

- **Последствия для ML-пайплайнов:** Спектр $\hat{\Sigma}_n$ размывается в непрерывный массив псевдокорреляций (шумовой bulk). Традиционные методы многомерного анализа данных (PCA, линейный дискриминант Фишера LDA, фильтрация Калмана, обращение ковариационных матриц в OLS-регрессии) в высокоразмерном режиме систематически сбоят, принимая случайные геометрические проекции шума за детерминированные закономерности.

---

## Модель выборочной ковариации (матрицы Уишарта)

Для строгого математического исследования шума высокой размерности вводится канонический ансамбль случайных матриц.

- **Постановка задачи:** Пусть матрица измерений $X \in \mathbb{R}^{p \times n}$ состоит из независимых одинаково распределенных (i.i.d.) случайных величин $X_{ij}$:

$$\mathbb{E}[X_{ij}] = 0, \quad \mathsf{Var}(X_{ij}) = \sigma^2, \quad \mathbb{E}[X_{ij}^4] < \infty$$

В принятой в машинном обучении нотации: $p$ строк соответствуют признакам (features), $n$ столбцов — отдельным наблюдениям/сэмплам (samples).

- **Матрица Уишарта (выборочная ковариация):**

$$\hat{\Sigma} = \frac{1}{n} X X^T \in \mathbb{R}^{p \times p}$$

Это неотрицательно определенная симметричная матрица. Ее ранг ограничен величиной $\min(p, n)$.

- **Эмпирическое спектральное распределение (ESD):** Поскольку собственные числа $\lambda_1 \geq \lambda_2 \geq ... \geq \lambda_p \geq 0$ матрицы $\hat{\Sigma}$ случайны, мы рассматриваем нормированную считающую меру (вероятностную меру, концентрирующуюся на спектре):

$$\mu_{\hat{\Sigma}}(\lambda) = \frac{1}{p} \sum_{i=1}^{p} \delta(\lambda - \lambda_i(\hat{\Sigma}))$$

  где $\delta(\cdot)$ — дельта-мера Дирака. Интеграл от тестовой функции по этой мере представляет собой нормированный след: $\int f(\lambda) d\mu_{\hat{\Sigma}}(\lambda) = \frac{1}{p} \mathrm{Tr}(f(\hat{\Sigma}))$.

- **Центральный вопрос RMT:** Хотя каждое отдельное собственное число $\lambda_i$ сильно флуктуирует от реализации к реализации, будет ли вся мера $\mu_{\hat{\Sigma}}$ в целом стремиться к детерминированному пределу при $p, n \to \infty, p/n \to \gamma$? Ответ дает закон Марченко–Пастура.

---

## Закон Марченко–Пастура (1967)

В 1967 году советские математики Владимир Александрович Марченко и Леонид Андреевич Пастур доказали фундаментальную теорему, описывающую термодинамический предел спектра выборочных ковариационных матриц.

- **Теорема Марченко–Пастура:** Если $p, n \to \infty$ так, что $p/n \to \gamma \in (0, \infty)$, то эмпирическая спектральная мера $\mu_{\hat{\Sigma}}$ почти наверное слабо сходится к детерминированной вероятностной мере $\mu_{MP}$, плотность которой имеет вид:

$$\rho_{MP}(\lambda) = \frac{1}{2\pi\sigma^2\gamma\lambda} \sqrt{(\lambda_+ - \lambda)(\lambda - \lambda_-)}\, \mathbf{1}_{[\lambda_-, \lambda_+]}(\lambda) + \max\left(0, 1 - \frac{1}{\gamma}\right) \delta_0(\lambda)$$

- **Края спектрального носителя (границы балка):**

$$\lambda_\pm = \sigma^2(1 \pm \sqrt{\gamma})^2$$

- **Структурный анализ плотности:**

  1. **Универсальность:** Закон универсален: он зависит исключительно от дисперсии элементов $\sigma^2$ и отношения размерностей $\gamma = p/n$, но не зависит от конкретного закона распределения элементов $X_{ij}$ (будь то гауссовское, распределение Радемахера $\pm 1$ или равномерное), если выполнены базовые моментные условия.
  2. **Режим $\gamma \leq 1$ ($p \leq n$):** Выборочная матрица имеет полный ранг почти наверное. Нижняя граница $\lambda_- > 0$, спектр отделен от нуля, сингулярного атома $\delta_0$ нет.

3. **Режим $\gamma > 1$ ($p > n$):** Число признаков превышает объем выборки. Линейная алгебра диктует, что $\text{rank}(\hat{\Sigma}) \leq n$. Матрица имеет ровно $p - n$ строго нулевых собственных чисел. Это отражается во втором слагаемом формулы: в точке $\lambda = 0$ возникает дельта-пик с массой $(p - n)/p = 1 - 1/\gamma$. Оставшиеся $n$ ненулевых собственных чисел распределены в непрерывном интервале $[\lambda_-, \lambda_+]$, где $\lambda_- = \sigma^2(1 - \sqrt{\gamma})^2 > 0$.

---

## Закон Марченко–Пастура: эффект «ложного сигнала»

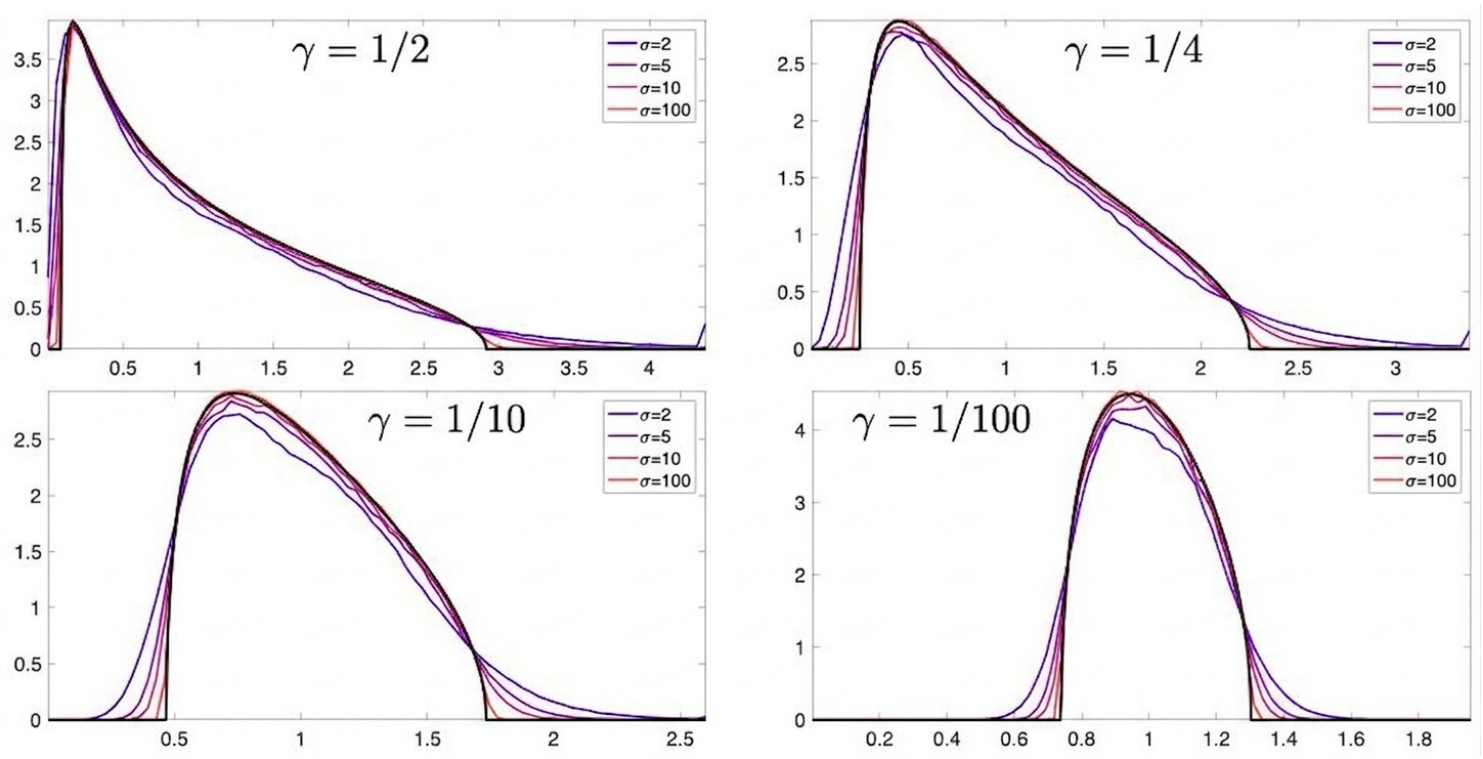



Рис. 2: Спектры случайных матриц большой размерности

Закон Марченко–Пастура показывает фундаментальную причину искажений при анализе многомерных данных:

- **Иллюзия дисперсии:** Пусть входные данные состоят из чистого независимого белого шума без каких-либо корреляций ($\Sigma_{\text{true}} = I_p$, $\sigma^2 = 1$). Рассмотрим случай, когда объем выборки точно равен числу признаков ($p = n \implies \gamma = 1$):

$$\lambda_- = (1 - 1)^2 = 0, \quad \lambda_+ = (1 + 1)^2 = 4$$

  Вместо одного точечного значения $\lambda = 1$ спектр размазывается по всему отрезку $[0, 4]$.

- **Крах классического PCA на шуме:** Метод главных компонент (PCA) ищет направления с максимальной дисперсией. На чистом белом шуме классический PCA определит максимальное выборочное собственное значение, стремящееся к $\lambda_+ = 4$. Алгоритм «утверждает», что вдоль первой главной компоненты сосредоточено в

4 раза больше вариации, чем истинная дисперсия признаков. Исследователь видит ложную структурированность там, где нет ничего, кроме шума.

- **Проблема обращения ковариации и регуляризация:** В регрессионном анализе (OLS) веса вычисляются через оператор $\hat{\Sigma}^{-1}$:

$$\hat{\beta} = (XX^T)^{-1}XY \implies \mathrm{Var}(\hat{\beta}) \propto \mathrm{Tr}(\hat{\Sigma}^{-1}) = \sum_{i=1}^{p} \frac{1}{\lambda_i}$$

Поскольку $\lambda_- \to 0$ при $\gamma \to 1$, спектральная плотность вблизи нуля ведет себя как $\rho_{MP}(\lambda) \sim \frac{1}{\pi\sqrt{\lambda}}$. Матрица становится катастрофически плохо обусловленной (число обусловленности $\kappa = \lambda_+/\lambda_- \to \infty$). Интеграл $\int \lambda^{-1}\rho_{MP}(\lambda)d\lambda$ расходится, дисперсия параметров регрессии взрывается. Это строго обосновывает математическую необходимость гребневой регрессии (Тихоновской регуляризации / Ridge): добавление $\alpha I$ сдвигает спектр от нуля вправо на величину $\alpha$.

---

## Модель ковариации с шипами (Spiked Covariance Model)

В реальных задачах машинного обучения данные не являются чистым шумом: в них содержится полезный низкоранговый сигнал (паттерны, скрытые факторы, классы), погруженный в высокоразмерный шум измерений.

- **Модель Джонстоуна (Iain Johnstone, 2001):** Истинная популяционная ковариационная матрица моделируется как аддитивное возмущение единичной шумовой матрицы несколькими «шипами» (spikes):

$$\Sigma = I_p + \sum_{k=1}^{r} \theta_k v_k v_k^T$$

  - $I_p$ — высокоразмерный изотропный шум ($\sigma^2 = 1$);
  - $r$ — эффективный внутренний ранг полезного сигнала ($r \ll p$, фиксировано при $p, n \to \infty$);
  - $\theta_1 \geq \theta_2 \geq ... \geq \theta_r > 0$ — истинная амплитуда (мощность) сигналов над уровнем шума;
  - $v_k \in \mathbb{R}^p$ — ортонормированные скрытые направления полезного сигнала.

- **Наблюдаемая выборка:** Наблюдаемые векторы генерируются как $y_i = \Sigma^{1/2}x_i$, где $x_i \sim \mathcal{N}(0, I_p)$. Соответственно, матрица данных $Y = \Sigma^{1/2}X \in \mathbb{R}^{p\times n}$.

- **Центральный вопрос высокоразмерного анализа:** В классической статистике любой сколь угодно малый сигнал $\theta > 0$ при $n \to \infty$ рано или поздно будет задетектирован. Сохраняется ли это свойство в режиме $p/n \to \gamma > 0$?

---

## Фазовый переход BBP (Baik–Ben Arous–Péché, 2005)

В 2005 году математики Джинхо Байк, Жерар Бен Арус и Сандрин Пеше совершили прорыв в теории случайных матриц, открыв явление резкого фазового перехода для изолированных собственных значений.

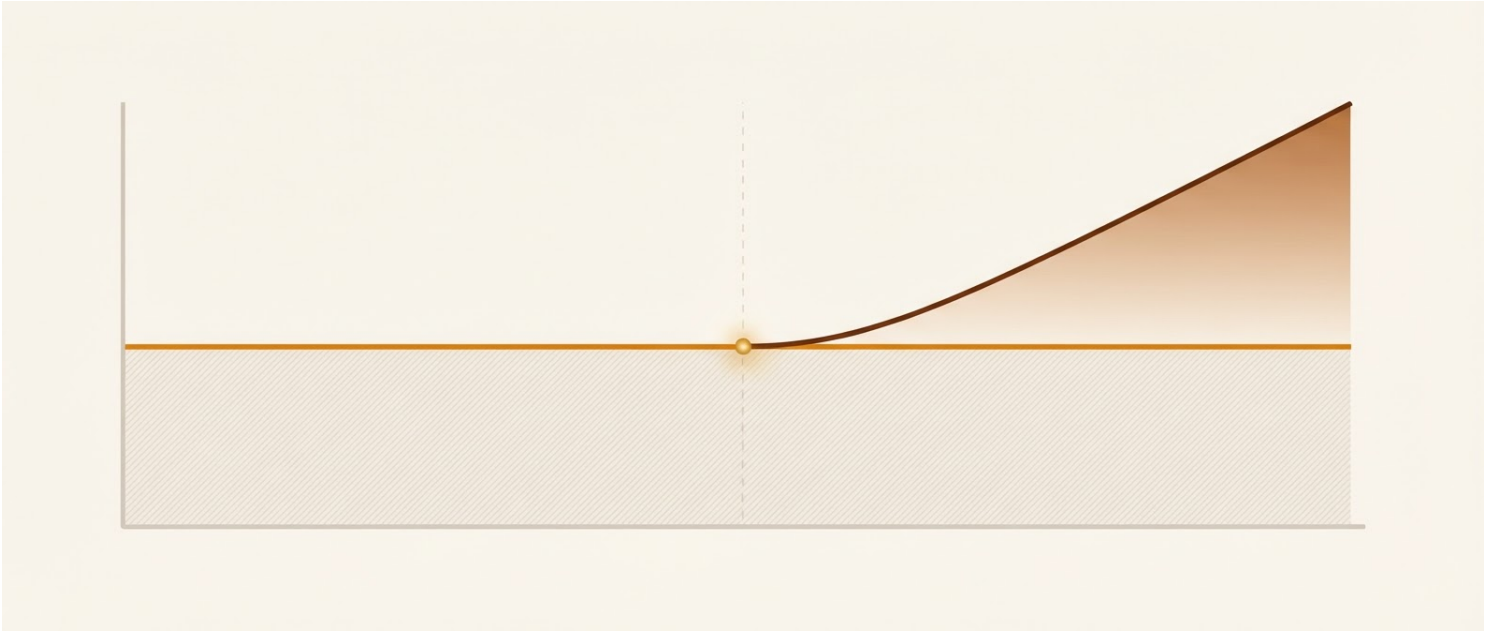


Рис. 3: Зависимость предельного выборочного собственного значения от истинной силы сигнала

- **Теорема BBP:** Пусть $p, n \to \infty$ так, что $p/n \to \gamma > 0$. Тогда старшее собственное значение выборочной ковариационной матрицы $\widehat{\lambda}_1 = \lambda_1(\frac{1}{n} Y Y^T)$ сходится почти наверное:

$$\hat{\lambda}_1 \xrightarrow{a.s.} \begin{cases} (1+\sqrt{\gamma})^2 = \lambda_+, & \text{если } \theta \le \sqrt{\gamma} \quad \textbf{(докритический режим)} \\ (1+\theta)\left(1+\frac{\gamma}{\theta}\right), & \text{если } \theta > \sqrt{\gamma} \quad \textbf{(надкритический режим)} \end{cases}$$

- **Критический порог детектирования:**

$$\theta_c = \sqrt{\gamma} = \sqrt{\frac{p}{n}}$$

- **Физический и аналитический смысл перехода:**
  1. **Докритический режим ($\theta \le \theta_c$):** Сигнал оказывается слишком слабым для заданного уровня зашумленности и отношения размерностей. Соответствующее выборочное собственное значение полностью затягивается внутрь шумового континуума Марченко–Пастура и асимптотически прилипает к его правой границе $\lambda_+$. Сигнал спектрально неотличим от случайных флуктуаций шума.
  2. **Надкритический режим ($\theta > \theta_c$):** Сигнал преодолевает критический барьер. Выборочное собственное число «выскакивает» из шумового балка, образуя изолированный спектральный пик (outlier) строго справа от $\lambda_+$.

3. **Смещение амплитуды (BBP Shrinkage):** Заметьте, что даже выше порога выборочное собственное значение $\hat{\lambda}_1 = 1 + \theta + \gamma + \frac{\gamma}{\theta}$ всегда строго больше истинного значения популяционного собственного числа $\lambda_{\text{true}} = 1 + \theta$. Высокоразмерный шум систематически «выталкивает» сигнальное собственное число вверх.

---

## Коллапс проекций и «слепота» PCA

Спектральный переход BBP описывает поведение собственных чисел. Однако для алгоритмов машинного обучения критически важна геометрия собственных векторов: восстанавливает ли выборочный вектор $\hat{v}_1$ истинное скрытое направление признака $v_1$?

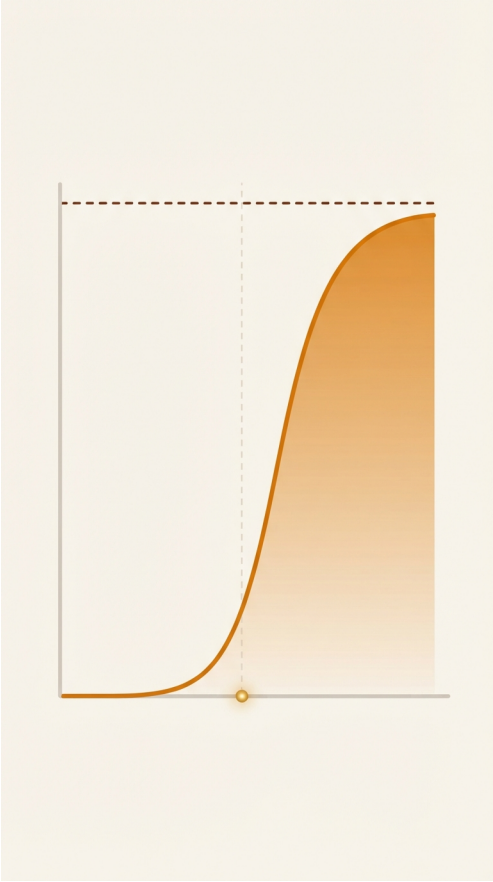


Рис. 4: График перекрытия векторов

- **Теорема о проекциях (Debashis Paul, 2007; Benaych-Georges & Nadakuditi, 2011):** Квадрат косинуса угла (коэффициент перекрытия, overlap) между истинным направлением сигнала $v_1$ и оцененным первой главной компонентой $\hat{v}_1$ в пределе высокой размерности равен:

$$|\langle \hat{v}_1, v_1 \rangle|^2 \xrightarrow{a.s.} \begin{cases} 0, & \theta \leq \sqrt{\gamma} \\ \frac{1 - \frac{\gamma}{\theta^2}}{1 + \frac{\gamma}{\theta}}, & \theta > \sqrt{\gamma} \end{cases}$$

- **Фундаментальные следствия:**

1. **Информационная слепота (Total Subspace Collapse):** В докритической области ($\theta \leq \sqrt{p/n}$) скалярное произведение стремится к нулю. Это означает, что выборочный вектор $\widehat{v}_1$ асимптотически ортогонален истинному сигналу $v_1$. Направление, найденное PCA, является случайным вектором в пространстве высокой размерности. Алгоритм не просто совершает численную ошибку — в данных принципиально отсутствует линейная информация для реконструкции направления при таком объеме выборки.
2. **Асимптотическое искажение направления:** Даже если сигнал превосходит порог ($\theta > \sqrt{\gamma}$), перекрытие строго меньше единицы ($|\langle \widehat{v}_1, v_1 \rangle|^2 < 1$). Чтобы выборочный собственный вектор с высокой точностью совпал с истинным ($|\langle \widehat{v}_1, v_1 \rangle| \approx 1$), амплитуда должна значительно превышать порог:

$$\frac{\gamma}{\theta^2} \ll 1 \iff n \gg \frac{p}{\theta^2}$$

3. **Предел детектируемости:** Порог BBP задает фундаментальную информационно-теоретическую границу: никакой линейный алгоритм без жестких априорных структурных ограничений (например, разреженности / sparsity) не способен извлечь полезный компонент из шума ниже границы $\theta_c$.

---

## Сколько компонент PCA — сигнал, а не шум?

Практикующие инженеры часто задаются вопросом: сколько компонент PCA необходимо оставлять при снижении размерности? Традиционные эвристики здесь не работают.

- **Несостоятельность классических методов:**
  - **Критерий Кайзера ($\lambda_i > 1$):** Рекомендует отбирать компоненты с дисперсией больше среднего. Однако по закону Марченко–Пастура для чистого белого шума при $\gamma = 1$ спектр простирается до 4. Ровно половина спектра чистого белого шума лежит выше единицы. Критерий Кайзера гарантированно включит в модель огромный объем шума.
  - **Правило «локтя» (Scree test):** Поиск визуального излома на графике собственных значений субъективен и не имеет строгой статистической силы в режиме $p \sim n$.
- **Алгоритм фильтрации шума на базе RMT и BBP:**
  1. **Оценка параметров шумового фона:** Используя устойчивые статистики нижних квантилей спектра (например, медиану распределения), находят оценку дисперсии шума $\widehat{\sigma}^2$ и эффективное отношение размерностей $\widehat{\gamma} = p/n$.
  2. **Вычисление теоретического шумового края:** Определяется правая граница балка Марченко–Пастура: $\lambda_+ = \widehat{\sigma}^2(1 + \sqrt{\widehat{\gamma}})^2$.
  3. **Проверка статистической гипотезы через флуктуации Трейси–Видома:** В конечных выборках максимальное собственное число шума флуктуирует около $\lambda_+$ в масштабе порядка $\mathcal{O}(n^{-2/3})$ согласно универсальному распределению Трейси–Видома ($TW_1$). Чтобы гарантированно отделить сигнал от шумового

выброса, вводится защитный интервал $\delta_n$:

$$r^* = \max\left\{k : \lambda_k(\hat{\Sigma}) > \lambda_+ + \delta_n\right\}, \quad \delta_n = \hat{\sigma}^2(1+\sqrt{\hat{\gamma}})^{4/3}\hat{\gamma}^{-1/6}n^{-2/3}s_{1-\alpha}$$

где $s_{1-\alpha}$ — соответствующий квантиль закона Трейси–Видома (например, для уровня доверия 99% $s_{0.99} \approx 2.02$).

4. **Устранение BBP-смещения (Inversion Shrinkage):** Найденные сигнальные значения $\hat{\lambda}_k$ систематически завышены из-за шума. Для получения несмещенной оценки истинной дисперсии $\theta_k$ обращают формулу надкритического режима BBP. Пусть $\tilde{\lambda}_k = \hat{\lambda}_k/\hat{\sigma}^2$:

$$\hat{\theta}_k = \frac{\tilde{\lambda}_k + 1 - \hat{\gamma} + \sqrt{(\tilde{\lambda}_k + 1 - \hat{\gamma})^2 - 4\tilde{\lambda}_k}}{2} - 1$$

Данная аналитическая калибровка возвращает физически точную мощность исходного скрытого сигнала.

---

## От ковариаций к весам нейросетей: спектральный срез

Перенесем математический аппарат теории случайных матриц на анализ весов глубоких нейронных сетей.

- **Матрицы весов как операторы:** Рассмотрим полносвязный слой или 2D-срез тензора сверточного слоя глубокой сети с матрицей весов $W \in \mathbb{R}^{N\times M}$. По аналогии с матрицей выборочной ковариации определим матрицу корреляций признаков слоя:

$$S = \frac{1}{N}W^TW \in \mathbb{R}^{M\times M}, \quad \gamma = M/N$$

Собственные числа матрицы $S$ равны квадратам сингулярных чисел матрицы $W$, нормированным на размерность: $\lambda_i = s_i^2(W)/N$.

- **Случайная инициализация (Xavier / He):** Перед началом обучения веса генерируются как независимые гауссовские величины с нулевым средним и фиксированной дисперсией: $W_{ij} \sim \mathcal{N}(0, \sigma^2)$. В этот момент условия теоремы Марченко–Пастура выполняются идеально: эмпирический спектр матрицы $S$ в точности совпадает с плотностью $\rho_{MP}(\lambda)$. Никакой скоординированной информации в слое нет.

- **Парадокс процесса обучения:** В процессе оптимизации с помощью стохастического градиентного спуска (SGD) веса матрицы $W$ обновляются, формируя сложные кросс-корреляции между нейронами. Классическая интуиция предполагала, что обучение формирует модель с шипами (Spiked Covariance Model): основной спектр останется шумовым балком Марченко–Пастура, из которого выдвинется небольшое число изолированных собственных чисел, кодирующих детерминированные высокоуровневые признаки. Однако экспериментальные

исследования Чарльза Мартина и Майкла Махони (2018–2021) показали, что в реальных обученных сетях возникает принципиально иной спектральный ландшафт: спектр полностью перестраивается, образуя тяжелые степенные хвосты.

---

## Подход Мартина–Махони: Heavy-Tailed Self-Regularization

Чарльз Мартин и Майкл Махони (UC Berkeley) провели масштабный эмпирический и теоретический анализ десятков тысяч весовых матриц в популярных SOTA-архитектурах (VGG, ResNet, DenseNet, BERT, GPT) и сформулировали теорию **тяжелохвостной саморегуляризации (Heavy-Tailed Self-Regularization, HTSR)**.

- **Самоорганизованная критичность (SOC) в нейросетях:** Процесс оптимизации в глубоком обучении объединяет три компоненты:
  1. Невыпуклый, многомерный ландшафт функции потерь со множеством локальных минимумов и седловых точек;
  2. Стохастический шум выборки мини-батчей в алгоритме SGD;
  3. Нелинейные сжимающие функции активации (ReLU, GELU).

  Взаимодействие этих факторов переводит динамическую систему нейросети в режим **самоорганизованной критичности** (явление, аналогичное образованию песчаных куч Бака–Танга–Визенфельда или масштабно-инвариантным процессам в турбулентности и землетрясениях).
- **Степенное распределение собственных чисел (Power Law):** Вместо компактного полукругового или марченко-пастуровского балка с жесткой границей $\lambda_+$ спектральная плотность матриц $S$ приобретает форму степенного закона (хвоста Парето):
  $$\rho(\lambda) \propto \lambda^{-\alpha}, \quad \lambda \in [\lambda_{min}, \lambda_{max}]$$
  где $\alpha$ — фундаментальный показатель формы степенного хвоста.
- **Масштабная инвариантность представлений (Scale-Free):** В обученной матрице отсутствуют выделенные масштабы признаков. Нейросеть организует информацию иерархически: от редких глобальных макро-признаков (огромные собственные числа в хвосте) до плотного континуума слабо выраженных контекстных микро-признаков (тело распределения).

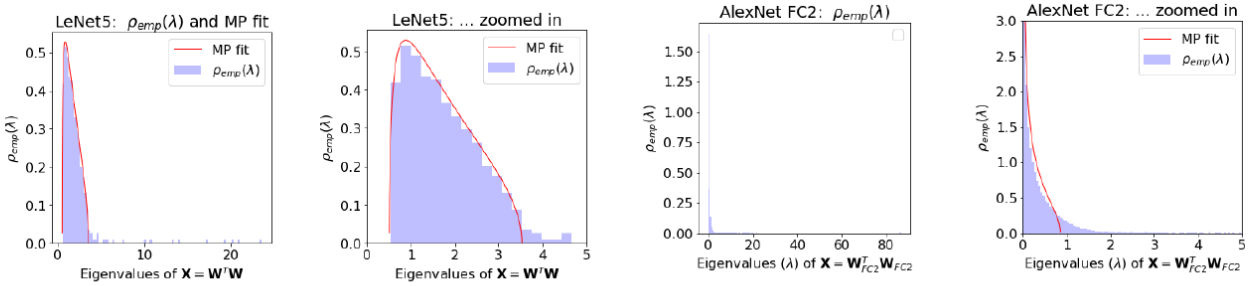
---

## Подход Мартина–Махони: Heavy-Tailed Self-Regularization

Графики спектральной плотности в двойном логарифмическом масштабе ($\log \rho(\lambda)$ от $\log \lambda$) наглядно подтверждают действие теории HTSR. Прямая линия на log-log шкале является главным визуальным маркером степенного закона:

$$\log \rho(\lambda) = -\alpha \log \lambda + \text{const}$$

В отличие от случайных матриц, спектр которых резко обрывается в точке $\lambda_+$, спектр обученного слоя демонстрирует протяженный непрерывный хвост, охватывающий




(a) LeNet5, full (b) LeNet5, zoomed-in (c) AlexNet, full (d) AlexNet, zoomed-in

Figure 1: Full and zoomed-in ESD for LeNet5 (Layer FC1) and AlexNet (Layer FC2). Overlaid (in red) are fits of the MP distribution (which fit the bulk very well for LeNet5 but *not* well for AlexNet).

Рис. 5: Спектр матриц слоев

несколько порядков величины по оси $\lambda$. При этом наклон прямой определяет показатель $\alpha$.

---

## Пять спектральных фаз слоев нейросетей

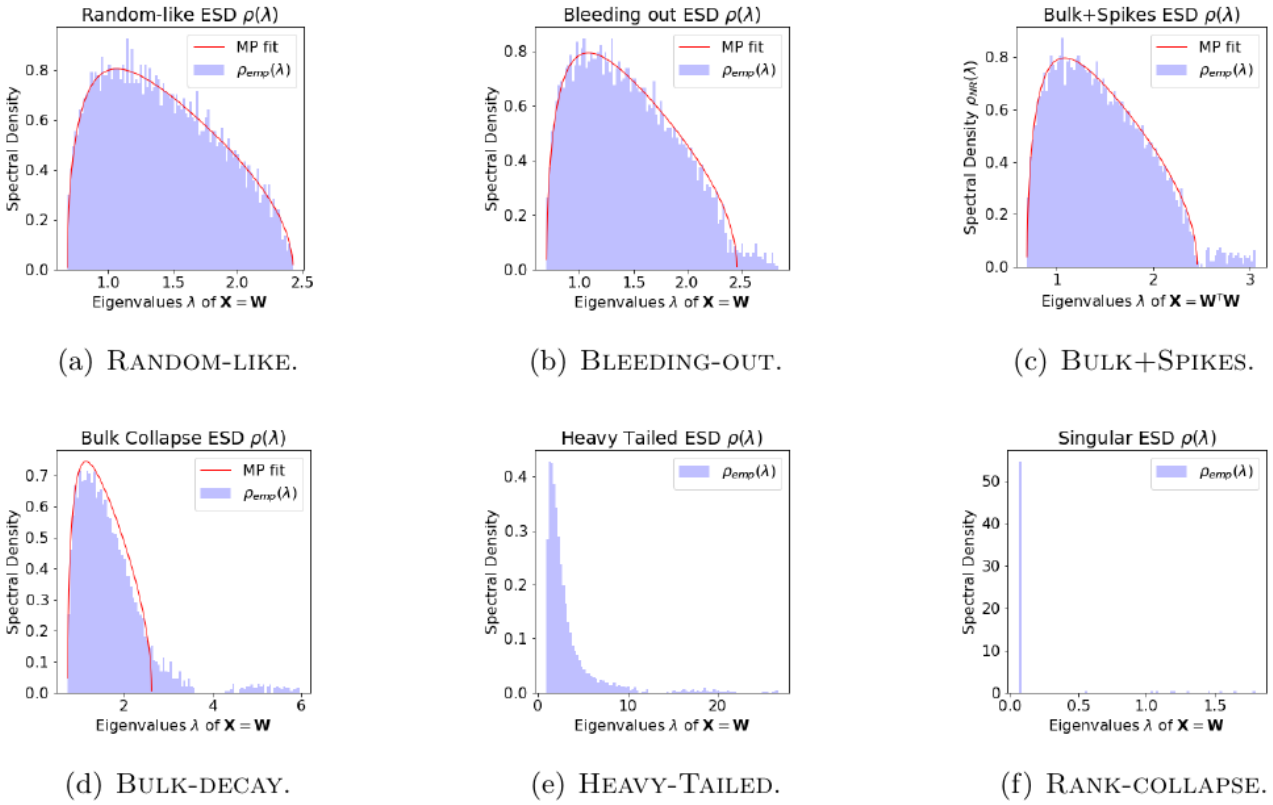
Мартин и Махони выделили пять последовательных спектральных фаз, через которые проходят матрицы весов в процессе эволюции от инициализации до завершения тренировки:

1. **Фаза 1: Random-like (MP):** Спектр практически неотличим от балка Марченко–Пастура. Собственные числа зажаты в интервале $[\lambda_-, \lambda_+]$. Это указывает на то, что слой не обучался (например, при заморозке весов, исчезновении градиентов или некорректно подобранном Learning Rate).
2. **Фаза 2: Bleeding out (Просачивание):** Небольшая часть собственных чисел начинает слегка выступать за теоретическую границу $\lambda_+$, но выраженный степенной хвост еще не сформирован. Типично для самых ранних эпох тренировки или слоев с жесткой L2-регуляризацией.
3. **Фаза 3: Bulk + Decay (Балк с затуханием):** В спектре одновременно сосуществуют две структуры: низкоэнергетический шум Марченко–Пастура (остаточный шумовой балк около нуля) и выраженный степенной хвост информативных собственных чисел справа от него. Характерно для промежуточных слоев и умеренно обученных сетей.
4. **Фаза 4: Heavy-Tailed (Чистый тяжелый хвост):** Шумовой балк полностью исчезает или вытесняется к минимальным значениям. Весь спектральный массив подчиняется единому степенному закону $\rho(\lambda) \sim \lambda^{-\alpha}$ с оптимальным показателем $\alpha \in (2, 4)$. Это режим идеальной саморегуляризации и максимальной обобщающей способности.
5. **Фаза 5: Collapsed / Rank-deficient (Схлопывание ранга):** Катастрофическая деградация представления. Один или два гигантских собственных значения аккумулируют в себе почти весь след матрицы ($\mathrm{Tr}(S)$), а остальные собственные зна-

чения прижимаются к нулю. Это индикатор жесткого переобучения (overfitting) и коллапса признакового пространства в сверхнизкоранговое подпространство.

---

## Пять спектральных фаз матриц весов




(a) RANDOM-LIKE. (b) BLEEDING-OUT. (c) BULK+SPIKES.

(d) BULK-DECAY. (e) HEAVY-TAILED. (f) RANK-COLLAPSE.

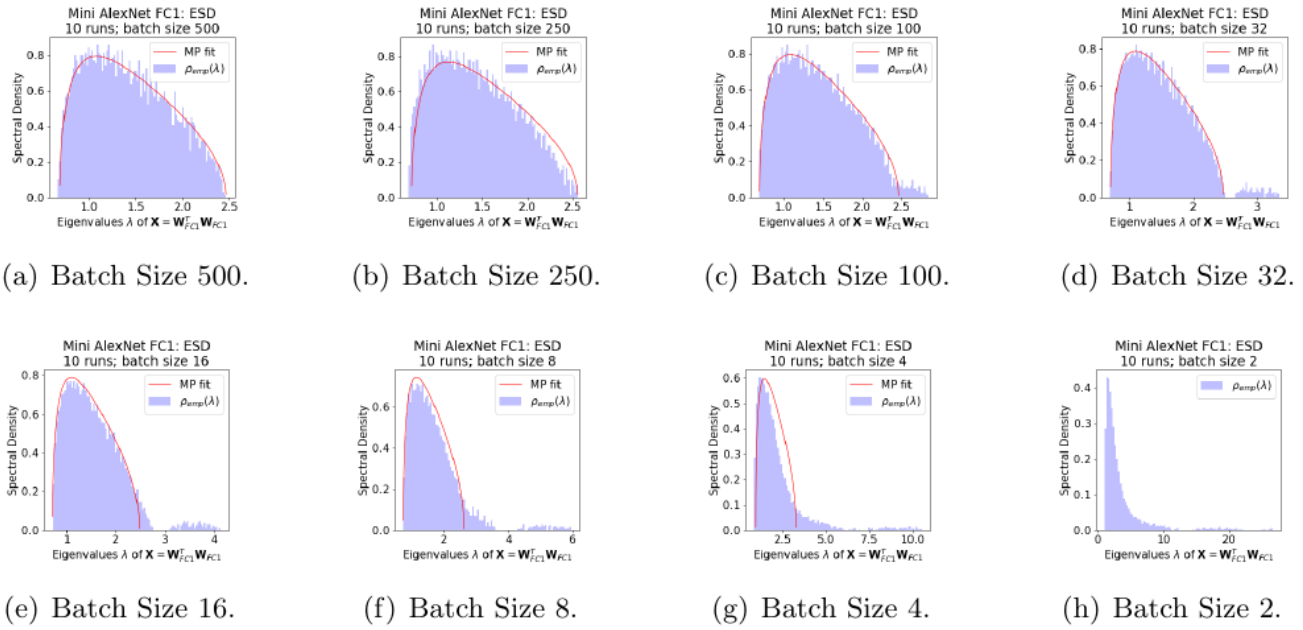
Figure 2: Taxonomy of trained models. Starting off with an initial random or RANDOM-LIKE model (2(a)), training can lead to a BULK+SPIKES model (2(c)), with data-dependent spikes on top of a random-like bulk. Depending on the network size and architecture, properties of training data, etc., additional training can lead to a HEAVY-TAILED model (2(e)), a high-quality model with long-range correlations. An intermediate BLEEDING-OUT model (2(b)), where spikes start to pull out from the bulk, and an intermediate BULK-DECAY model (2(d)), where correlations start to degrade the separation between the bulk and spikes, leading to a decay of the bulk, are also possible. In extreme cases, a severely over-regularized model (2(f)) is possible.

Рис. 6: Пять спектральных фаз матриц весов

Графическая иллюстрация пяти спектральных состояний демонстрирует плавную эволюцию системы: от гауссова беспорядка (Phase 1) через структурирование информации (Phases 2–3) к состоянию масштабно-инвариантной критичности (Phase 4), с риском деградации в переобученное вырожденное состояние (Phase 5).

---

## Влияние размера батча (Batch Size) на форму спектра




(a) Batch Size 500. (b) Batch Size 250. (c) Batch Size 100. (d) Batch Size 32.

(e) Batch Size 16. (f) Batch Size 8. (g) Batch Size 4. (h) Batch Size 2.

Figure 5: Varying Batch Size. ESD for Layer FC1 of MiniAlexNet, with MP fit (in red), for an ensemble of 10 runs, for Batch Size ranging from 500 down to 2. Smaller batch size leads to more implicitly self-regularized models. We exhibit all 5 of the main phases of training by varying only the batch size.

Рис. 7: Зависимость спектра от размера батча

Размер мини-батча (Batch Size, $B$) в алгоритме SGD играет роль эффективной «температуры» стохастической системы:

- **Математическая природа градиентного шума:** При стохастическом спуске оценка градиента по мини-батчу флуктуирует вокруг истинного градиента всей обучающей выборки:

$$g_B(w) = \nabla \mathcal{L}(w) + \xi_B, \quad \text{Cov}(\xi_B) \approx \frac{1}{B}\Sigma_{\text{grad}}$$

  Дисперсия этого стохастического шума обратно пропорциональна размеру батча $B$.

- **Стохастический градиент против полного градиента:**
  - **Малый размер батча (Small Batch Size):** Интенсивный шум $\xi_B$ действует как неявный динамический регуляризатор. Он помогает траектории оптимизации непрерывно «выбиваться» из мелких и острых локальных минимумов ландшафта потерь, направляя систему в широкие, плоские минимумы. На спектральном уровне это транслируется в идеальное формирование тяжелого хвоста (Phase 4) с оптимальным наклоном $\alpha \approx 2.5 - 3.5$.
  - **Большой размер батча (Large Batch Size):** При росте $B$ шум затухает, приближая алгоритм к классическому градиентному спуску (Full Batch GD). Вектор

весов стремится сойтись в ближайший (зачастую очень острый) локальный минимум. Спектр при этом смещается либо в сторону слабо обученного состояния (Bulk + Decay с высоким $\alpha > 4$), либо стремительно коллапсирует в фазу 5.

- **Инженерный компромисс:** Современные аппаратные ускорители (GPU, TPU) требуют больших размеров батча для максимальной параллелизации матричных умножений на тензорных ядрах. Однако чистое масштабирование батча без адаптации Learning Rate разрушает саморегуляризацию HTSR и ухудшает тестовую точность модели.

---

## Степенной показатель $\alpha$ как мера обобщения

Для количественной оценки степени саморегуляризации слоя используется точная математическая процедура подгонки хвоста распределения.

- **Метод оценивания (Алгоритм Клаузе–Шальзи–Ньюмана, Clauset–Cosma–Newman):** Оценка параметров проводится численным методом максимального правдоподобия (MLE / Hill estimator) в комбинации с минимизацией расстояния Колмогорова–Смирнова для автоматического определения нижнего порога степенного хвоста $\lambda_{min}$:

$$\hat{\alpha} = 1 + N_\lambda \left[ \sum_{i=1}^{N_\lambda} \ln \frac{\lambda_i}{\lambda_{min}} \right]^{-1}, \quad \text{для всех } \lambda_i \geq \lambda_{min}$$

- **Связь показателя $\alpha$ с обобщающей способностью:**
  - $\alpha > 4$ **(Слабая регуляризация / Недообучение):** Хвост спектра затухает слишком круто (субэкспоненциально). В терминах вероятностей у такого распределения сходятся все первые моменты (среднее, дисперсия, эксцесс). Слой работает неэффективно, формируя преимущественно шум и локальные корреляции. Модель обладает плохой выразительностью.
  - $2 < \alpha \leq 4$ **(«Зона Златовласки» / The Goldilocks Zone):** Универсальный класс систем с тяжелыми хвостами. *При* $2 < \alpha \leq 3$*:* распределение обладает конечным математическим ожиданием $\mathbb{E}[\lambda] < \infty$, но строго бесконечной теоретической дисперсией $\mathrm{Var}(\lambda) = \infty$ (в пределе бесконечной размерности). *Интерпретация:* Конечная средняя энергия обеспечивает глобальную стабильность слоя, а расходящаяся дисперсия дает бесконечный динамический диапазон для масштабно-инвариантного кодирования признаков. Нейросеть сжимает информацию и демонстрирует выдающееся качество обобщения (test generalization).
  - $\alpha \leq 2$ **(Сверхтяжелые хвосты / Переобучение):** В бесконечном пределе у распределения расходится даже первый момент (математическое ожидание энергии $\mathbb{E}[\lambda] \to \infty$). На практике это означает крайнюю степень концентрации: ничтожная горстка сингулярных векторов полностью подавляет все остальные степени свободы матрицы весов. Информационная емкость слоя

схлопывается, сеть катастрофически теряет способность к обобщению на новых данных.

---

## Диагностика без валидационной выборки (WeightWatcher)

Традиционные методы оценки нейросетей требуют прогона модели на гигантских размеченных тестовых или валидационных датасетах. Спектральная теория Мартина–Махони позволяет оценивать качество модели абсолютно **без данных (data-free)** — анализируя исключительно геометрию весовых матриц.

- **Глобальная спектральная метрика сети (Alpha-Hat):** Для комплексной оценки всей глубокой сети из $L$ слоев рассчитывается средневзвешенный степенной показатель:

$$\hat{\alpha} = \frac{1}{L}\sum_{l=1}^{L}\alpha_l, \quad \text{или} \quad \hat{\alpha}_{\text{weighted}} = \frac{1}{L}\sum_{l=1}^{L}\alpha_l \log \lambda_{\max,l}$$

  где $\lambda_{\max,l} = \|W_l\|_2^2$ — спектральная норма матрицы слоя (квадрат максимального сингулярного числа), учитывающая относительный масштаб вклада слоя в общий сквозной сигнал сети.

- **Практические сценарии применения в MLOps:**

  1. **Ранняя остановка без валидации (Data-Free Early Stopping):** В процессе тренировки значение $\hat{\alpha}$ непрерывно снижается от высоких значений ($> 5$) в направлении «зоны Златовласки». Выход метрики на плато в диапазоне $[2, 3.5]$ сигнализирует об оптимальном моменте остановки обучения до наступления спектрального коллапса.
  2. **Послойная диагностика (Layer-by-Layer Debugging):** Вычисление индивидуальных $\alpha_l$ позволяет мгновенно локализовать «больные» слои архитектуры:
     - Если $\alpha_l > 5$ — слой заблокирован, градиенты не текут (необходимо уменьшить Weight Decay или сменить схему инициализации);
     - Если $\alpha_l < 1.8$ — слой переобучен, емкость избыточна (необходимо увеличить Dropout или сжать слой через прунинг/LoRA).
  3. **Аудит открытых и закрытых весов (LLM Auditing):** Экспресс-тестирование предобученных открытых моделей (Llama, Mistral, Qwen) без необходимости запуска дорогостоящего многодневного инференса на терабайтных бенчмарках.

---

## Диагностика без валидационной выборки (WeightWatcher)

На практике описанный спектральный аудит полностью автоматизирован в открытой Python-библиотеке `weightwatcher` (разработанной Ч. Мартином).

- **Пример использования:** Библиотека интегрируется с фреймворками PyTorch, TensorFlow и HuggingFace всего в несколько строк кода:

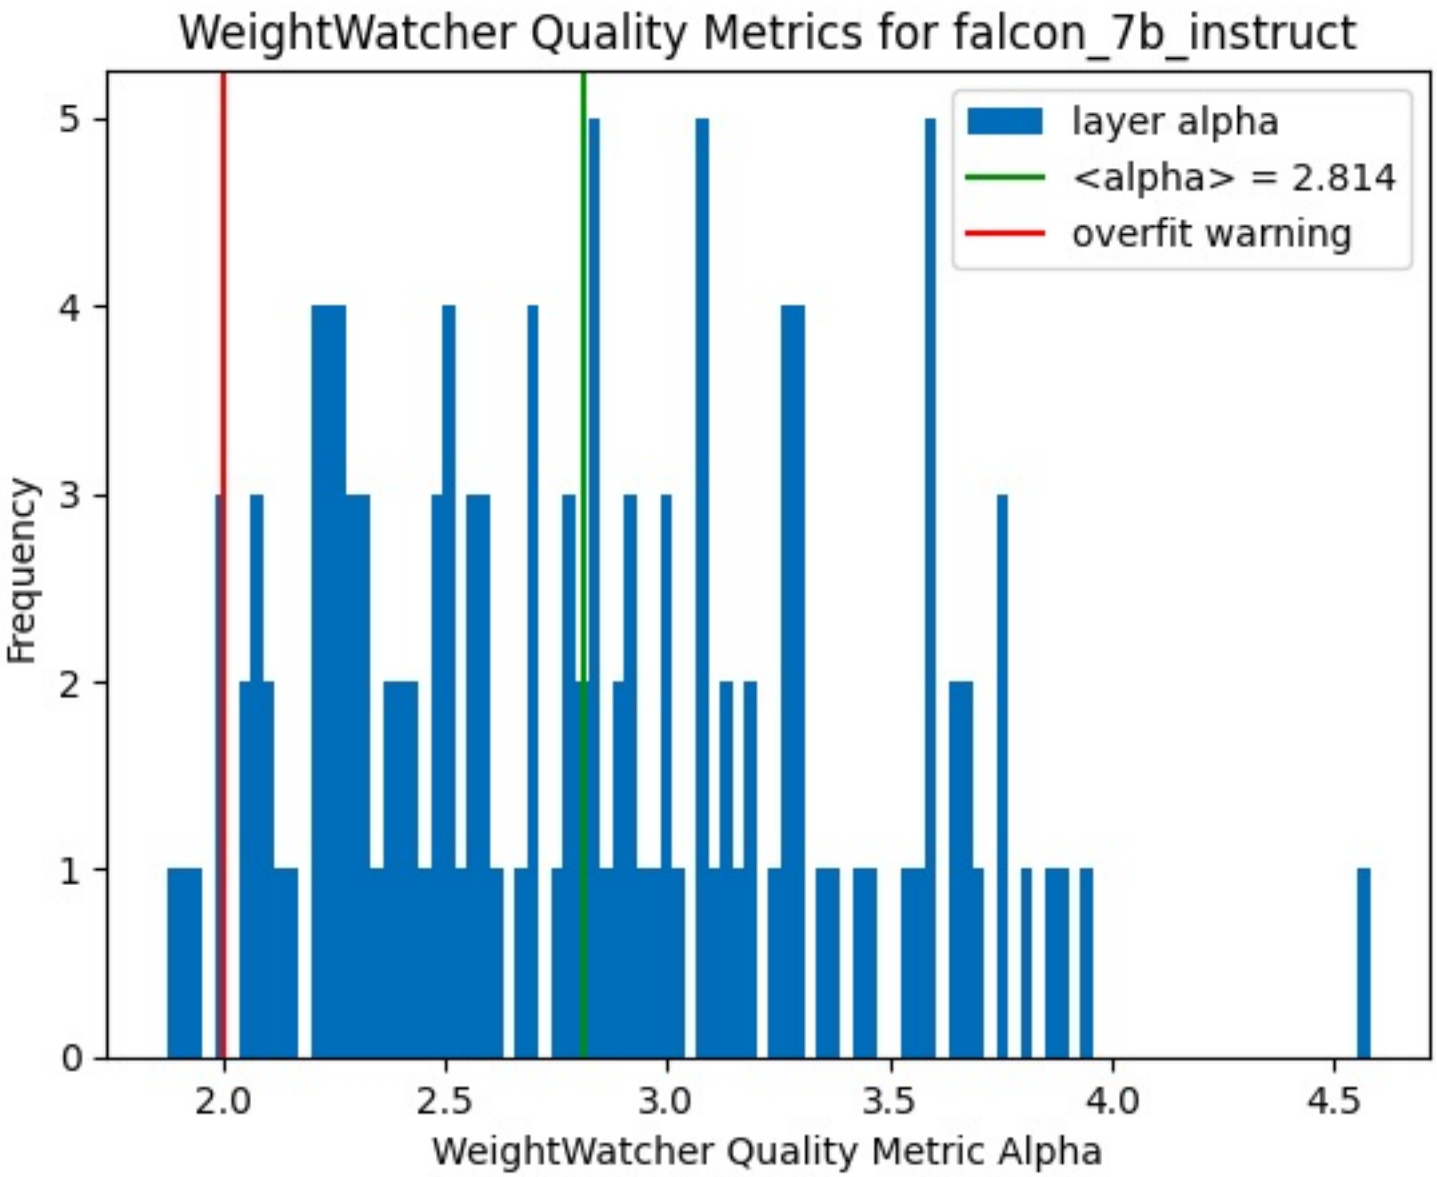



Рис. 8: WeightWatcher

```python
import torch
from torchvision.models import resnet50
import weightwatcher as ww

# Загрузка любой модели
model = resnet50(pretrained=True)

# Инициализация анализатора
watcher = ww.WeightWatcher(model=model)

# Спектральный анализ всех слоев без использования данных
details = watcher.analyze()
summary = watcher.get_summary()

print(f"Global Alpha-Hat: {summary['alpha']}")
```

- Библиотека извлекает тензоры весов, разворачивает свертки в двумерные матрицы, выполняет сингулярное разложение (SVD), оценивает $\lambda_{min}$, находит показатели $\alpha_l$, выявляет фазы матриц и формирует детальный аналитический отчет о стабильности и обобщающей способности каждого слоя.

---

## Резюме: от теории матриц к практике ML

Теория случайных матриц переводит глубокое обучение из области эмпирических эвристик в плоскость строгой математической физики. Три фундаментальных столпа RMT определяют жизненный цикл высокоразмерных моделей:

1. **Универсальный предел шума (Закон Марченко–Пастура):**
   - В режиме высокой размерности ($p \sim n$) эмпирическая ковариационная матрица белого шума никогда не сходится к единичной. Шум формирует жесткий детерминированный массив (bulk) с границей $\lambda_+ = \sigma^2(1 + \sqrt{\gamma})^2$.
   - Наличие малых собственных чисел вблизи $\lambda_-$ вызывает численную сингулярность при обращении матриц, что строго обосновывает использование регуляризации Тихонова (Ridge) для предотвращения взрыва дисперсии.
2. **Фундаментальный предел детектирования (Фазовый переход BBP):**
   - Линейные проекционные методы (PCA) способны зафиксировать наличие полезного низкорангового сигнала в шуме тогда и только тогда, когда истинная амплитуда сигнала превышает критический порог: $\theta > \sqrt{p/n}$.
   - Ниже порога BBP наступает полная информационная слепота: выборочный собственный вектор становится ортогонален истинному направлению данных ($|\langle \hat{v}_1, v_1 \rangle| \to 0$).
   - Выше порога выборочные значения систематически переоценивают сигнал, что требует обязательной калибровки (BBP shrinkage correction).
3. **Спектральная физика глубоких сетей (Теория HTSR):**
   - Стохастический градиентный спуск трансформирует случайный шум инициализации в масштабно-инвариантные спектры с тяжелыми хвостами: $\rho(\lambda) \sim \lambda^{-\alpha}$.

- Степень наклона хвоста $\alpha$ служит объективной, не зависящей от тестовых данных мерой качества модели: оптимальное обобщение достигается строго в «зоне Златовласки» $\alpha \in (2, 4)$, балансирующей между недообучением ($\alpha > 4$) и низкоранговым переобучением ($\alpha \leq 2$).