Теория случайных матриц в ML: Закон Марченко–Пастура, переход BBP и спектры слоев нейросетей

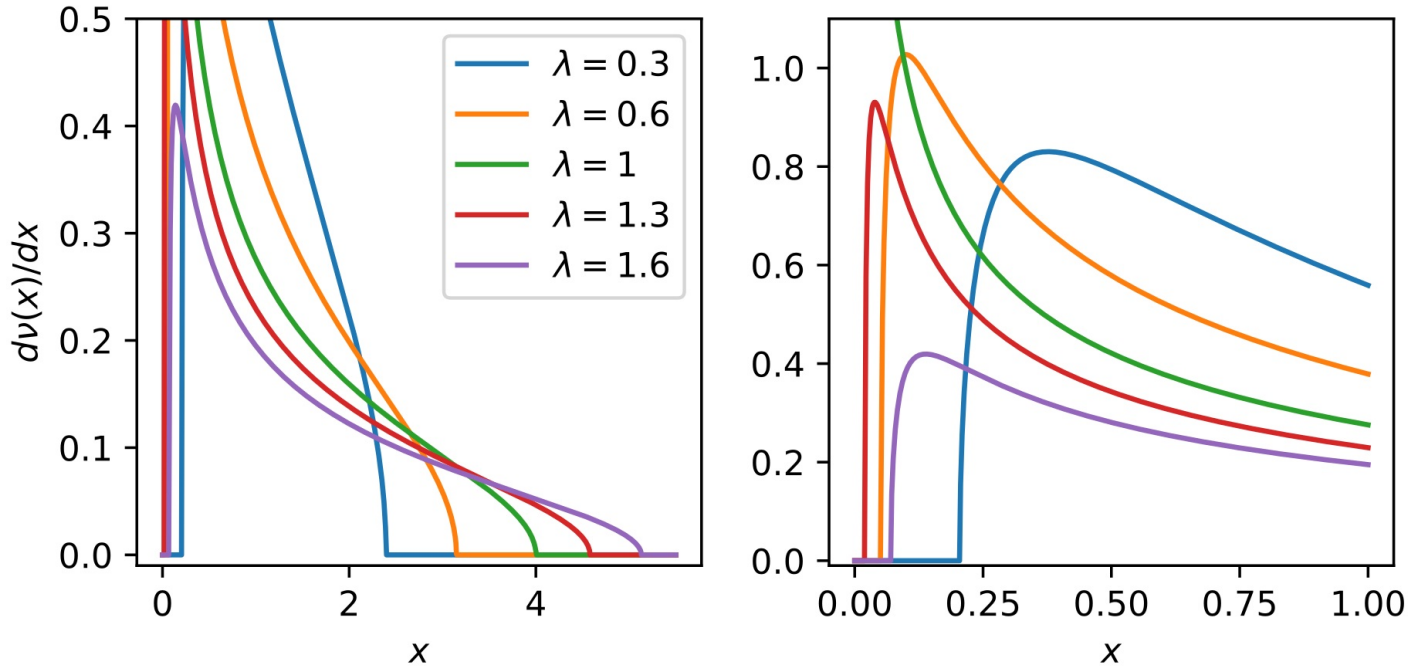


Рис. 1: Распределение Марченко–Пастура

Содержание

- **Кризис размерности:** почему выборочная ковариация ломается в режиме $p \sim n$
- **Универсальный предел шума:** закон Марченко–Пастура и метод преобразования Стилтьеса
- **Фазовый переход BBP (Baik–Ben Arous–Péché):** фундаментальный порог детектирования сигнала в PCA
- Спектральная диагностика весов нейросетей без валидационной выборки (теория Мартина–Махони / HTSR)

Кризис классической статистики: High-Dimensional Regime

- **Классический режим (p фиксировано, $n \to \infty$):**
  - Закон больших чисел гарантирует состоятельность эмпирической ковариации:

$$\hat{\Sigma}_n = \frac{1}{n}\sum_{i=1}^{n} x_i x_i^T \xrightarrow{P} \Sigma$$

  - Ошибки оценивания спектра стремятся к нулю: $\|\hat{\Sigma}_n - \Sigma\|_2 \to 0$.

- **Современный режим высокой размерности ($p, n \to \infty$, $p/n \to \gamma \in (0, \infty)$):**
  - Число оцениваемых параметров матрицы ($\sim p^2/2$) сопоставимо с объемом данных $n \times p$ или превосходит его.
  - Даже если истинные данные — некоррелированный белый шум ($\Sigma = I_p$), выборочная ковариация **никогда не сходится к единичной**:

$$\|\hat{\Sigma}_n - I_p\|_2 \not\to 0$$

  - Спектр $\hat{\Sigma}_n$ не концентрируется в точке $\lambda = 1$, а расплывается в непрерывный массив псевдокорреляций (шумовой «балк»).

В задачах большой размерности (изображения, тексты, звук) мы почти всегда находимся справа ($p \sim n$ или даже $p \gg n$). Это значит, что алгоритмы, полагающиеся на классическую интуицию выборочной ковариации (PCA, LDA, фильтр Калмана, регрессия Риджа), фундаментально смещены шумом высокой размерности.

Модель выборочной ковариации (матрицы Уишарта)

- Пусть матрица данных $X \in \mathbb{R}^{p \times n}$ состоит из независимых одинаково распределенных (i.i.d.) случайных величин:

$$\mathbb{E}[X_{ij}] = 0, \quad \mathrm{Var}(X_{ij}) = \sigma^2, \quad \mathbb{E}[X_{ij}^4] < \infty$$

- Выборочная ковариационная матрица (выборочная матрица Уишарта):

$$\hat{\Sigma} = \frac{1}{n} X X^T \in \mathbb{R}^{p \times p}$$

- Эмпирическое спектральное распределение (ESD — Empirical Spectral Distribution):

$$\mu_{\hat{\Sigma}}(x) = \frac{1}{p} \sum_{i=1}^{p} \delta_{\lambda_i(\hat{\Sigma})}(x)$$

  где $\lambda_1(\hat{\Sigma}) \geq \lambda_2(\hat{\Sigma}) \geq ... \geq \lambda_p(\hat{\Sigma}) \geq 0$ — собственные числа матрицы $\hat{\Sigma}$.
- **Фундаментальный вопрос:** к какой предельной детерминированной мере сходится $\mu_{\hat{\Sigma}}$ при $p, n \to \infty$, $p/n \to \gamma$?

Закон Марченко–Пастура (1967)

- **Теорема (В. А. Марченко, Л. А. Пастур):** Если $p, n \to \infty$ так, что отношение размерности к числу наблюдений $p/n \to \gamma \in (0, \infty)$, то мера $\mu_{\hat{\Sigma}}$ почти наверное слабо сходится (термодинамический предел) к вероятностной мере μ_{MP} с обобщенной плотностью:

$$\rho_{MP}(\lambda) = \frac{1}{2\pi\sigma^2\gamma\lambda} \sqrt{(\lambda_+ - \lambda)(\lambda - \lambda_-)}\, \mathbf{1}_{[\lambda_-, \lambda_+]}(\lambda) + \max\left(0, 1 - \frac{1}{\gamma}\right) \delta_0(\lambda)$$

- **Границы непрерывного спектра (спектральный массив / bulk):**

$$\lambda_{\pm} = \sigma^2(1 \pm \sqrt{\gamma})^2$$

- **Ключевые выводы о предельном спектре:**
  - Непрерывная часть спектра строго сосредоточена на детерминированном отрезке $[\lambda_-, \lambda_+]$.
  - При $\gamma \leq 1$ ($p \leq n$) матрица почти наверное полноранговая, атома в нуле нет.
  - При $\gamma > 1$ ($p > n$) матрица имеет дефект ранга (ровно $p - n$ нулевых собственных чисел), порождающий дискретный атом в нуле с весом $1 - 1/\gamma$.

Закон Марченко–Пастура: эффект «ложного сигнала»

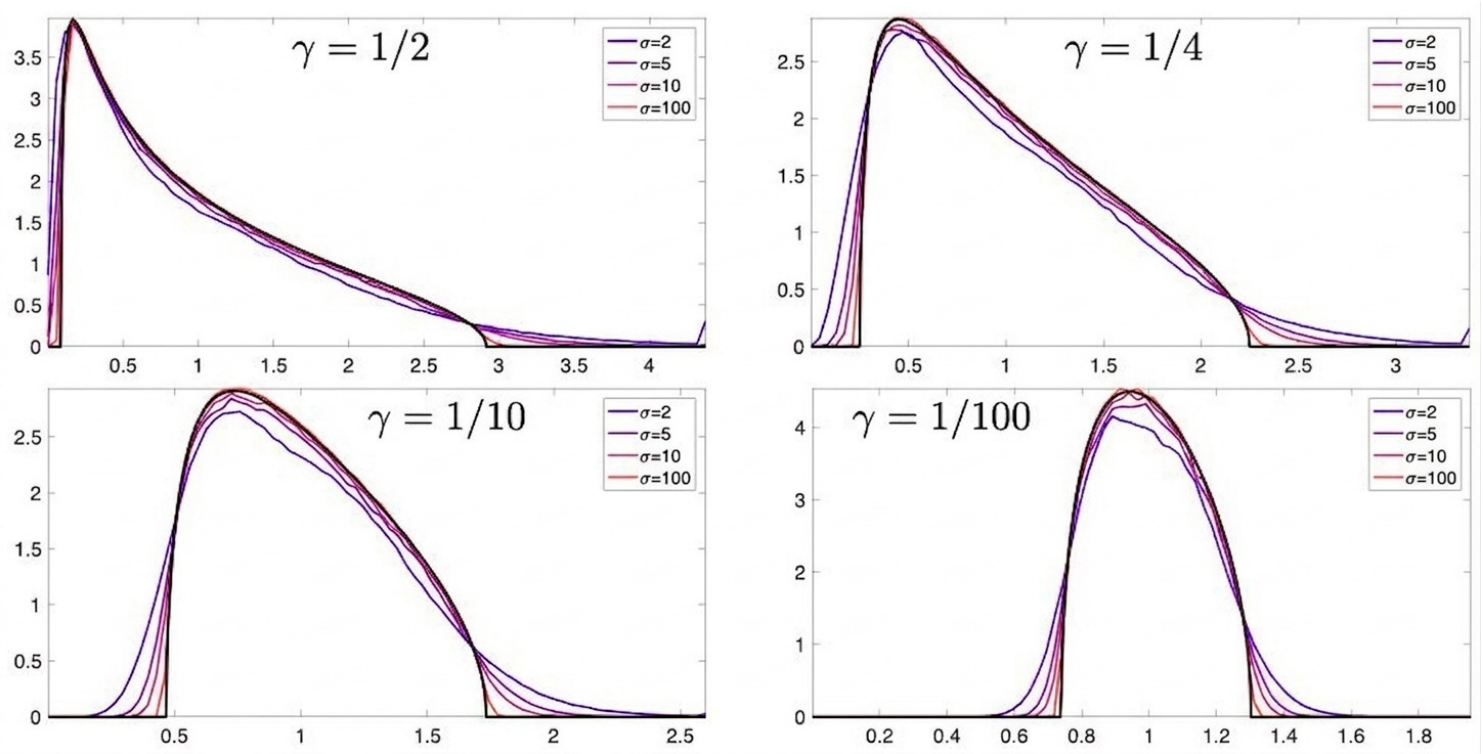


Рис. 2: Спектры случайных матриц большой размерности

- **Иллюзия структуры:** Даже для абсолютно некоррелированного белого шума ($\Sigma_{\text{ист}} = I$, $\sigma^2 = 1$) при равном числе признаков и измерений ($p = n \implies \gamma = 1$):

$$\lambda_- = (1-1)^2 = 0, \quad \lambda_+ = (1+1)^2 = 4$$

- **Следствие для PCA:** Максимальное эмпирическое собственное число стремится к 4, а не к 1. Алгоритм метода главных компонент «обнаружит» кажущуюся дисперсию вдоль первой компоненты в 4 раза выше истинной, создавая ложное ощущение структуры данных там, где есть только чистый шум.

Математический аппарат: резольвента и преобразование Стилтьеса

- Прямой расчет совместного распределения корней характеристического полинома $\det(\hat{\Sigma} - \lambda I) = 0$ аналитически сложен и неуниверсален.
- **Резольвента матрицы** (оператор, обратный спектральному; аналог функции Грина):

$$G(z) = (\hat{\Sigma} - zI_p)^{-1}, \quad z \in \mathbb{C}^+ = \{z \in \mathbb{C} : \operatorname{Im} z > 0\}$$

Так как $\hat{\Sigma}$ симметрична (спектр вещественен), матрица $(\hat{\Sigma} - zI_p)$ обратима для любого не вещественного z.

- **Эмпирическое преобразование Стилтьеса спектральной меры μ:**

$$s_p(z) = \frac{1}{p}\operatorname{Tr}(\hat{\Sigma} - zI_p)^{-1} = \frac{1}{p}\sum_{i=1}^{p}\frac{1}{\lambda_i - z}$$

- **Предельное преобразование Стилтьеса** (детерминированная функция):

$$s(z) = \lim_{p\to\infty} s_p(z) = \int_{\mathbb{R}} \frac{1}{\lambda - z} d\mu_{MP}(\lambda)$$

- **Свойства преобразования:**
  - $s_p(z)$ аналитична в $\mathbb{C}^+$ и отображает верхнюю полуплоскость в себя ($\operatorname{Im} s_p(z) > 0$).
  - Асимптотика на бесконечности кодирует моменты: $s_p(z) = -\frac{1}{z} - \frac{m_1}{z^2} - \ldots$, где $m_k = \int \lambda^k d\mu$.
- **Формула обращения Стилтьеса–Перрона:**

$$\rho_p(\lambda) = \frac{1}{\pi}\lim_{\epsilon\to 0^+}\operatorname{Im} s_p(\lambda + i\epsilon)$$

Зная аналитическую функцию $s(z)$, можно однозначно восстановить плотность распределения.

Вывод уравнения Марченко–Пастура: резольвентный метод

- Введем парную (компаньонную) матрицу размера $n \times n$:

$$\tilde{\Sigma} = \frac{1}{n}X^T X, \quad \tilde{G}(z) = (\tilde{\Sigma} - zI_n)^{-1}, \quad \tilde{s}(z) = \frac{1}{n}\operatorname{Tr}\tilde{G}(z)$$

- Ненулевые собственные числа $\hat{\Sigma}$ и $\tilde{\Sigma}$ идентичны, разница лишь в $|p-n|$ нулевых собственных числах:

$$p \cdot s(z) - n \cdot \tilde{s}(z) = \frac{n-p}{z} \implies \tilde{s}(z) = \gamma s(z) + \frac{\gamma - 1}{z}$$

- Представим $\hat{\Sigma} = \hat{\Sigma}^{(-j)} + \frac{1}{n} x_j x_j^T$ как сумму независимой части и возмущения ранга 1 (столбец x_j). По формуле Шермана–Моррисона диагональный элемент парной резольвенты:

$$\tilde{G}_{jj}(z) = -\frac{1}{z\left(1 + \frac{1}{n} x_j^T G^{(-j)}(z) x_j\right)}, \quad \text{где } G^{(-j)}(z) = (\hat{\Sigma}^{(-j)} - zI_p)^{-1}$$

- Столбец x_j не зависит от $G^{(-j)}$, поэтому по лемме о следе квадратичная форма концентрируется вокруг своего следа:

$$\frac{1}{n} x_j^T G^{(-j)}(z) x_j \approx \frac{\sigma^2}{n} \operatorname{Tr} G^{(-j)}(z)$$

- Исключение одного наблюдения: Удаление одного столбца x_j меняет ранг матрицы всего на 1, поэтому $\operatorname{Tr} G^{(-j)}(z) = \operatorname{Tr} G(z) + O(1)$.
- Термодинамический предел ($p, n \to \infty$, $p/n \to \gamma$): Случайные флуктуации исчезают (самоусреднение), и квадратичная форма сходится к детерминированной константе:

$$\frac{1}{n} x_j^T G^{(-j)}(z) x_j \xrightarrow{\text{п.н.}} \sigma^2 \frac{p}{n} s_p(z) \longrightarrow \sigma^2 \gamma s(z)$$

- Усредняя по $j = 1, \dots, n$, в термодинамическом пределе получаем фундаментальное соотношение:

$$\tilde{s}(z) = -\frac{1}{z(1 + \sigma^2 \gamma s(z))}$$

От алгебраического уравнения — к плотности Марченко-Пастура

- Подставим соотношение $\tilde{s}(z) = \gamma s(z) + \frac{\gamma - 1}{z}$ в полученное уравнение:

$$\gamma s(z) + \frac{\gamma - 1}{z} = -\frac{1}{z(1 + \sigma^2 \gamma s(z))}$$

- Положим для простоты $\sigma^2 = 1$ и домножим на знаменатель:

$$(\gamma z s(z) + \gamma - 1)\,(1 + \gamma s(z)) = -1$$

  Раскрывая скобки и деля на γ, получаем **квадратное уравнение Пастура**:

$$\gamma z s^2(z) + (z + \gamma - 1) s(z) + 1 = 0$$

- Корни уравнения определяются знаком дискриминанта $D(z) = (z - \lambda_+)(z - \lambda_-)$, где $\lambda_\pm = (1 \pm \sqrt{\gamma})^2$:

$$s(z) = \frac{-(z + \gamma - 1) + \sqrt{(z - \lambda_+)(z - \lambda_-)}}{2\gamma z} \quad \text{(выбираем ветвь с } \operatorname{Im} s(z) > 0)$$

- **Восстановление плотности** по формуле Перрона $\rho(\lambda) = \frac{1}{\pi} \lim_{\epsilon \to 0^+} \operatorname{Im} s(\lambda + i\epsilon)$:
  - Мнимая часть возникает только тогда, когда выражение под корнем строго отрицательно, т. е. при $\lambda \in [\lambda_-, \lambda_+]$:

$$\rho_{MP}(\lambda) = \frac{\sqrt{(\lambda_+ - \lambda)(\lambda - \lambda_-)}}{2\pi\gamma\lambda}$$

(Для общего случая $\sigma^2 \neq 1$ масштабирование дает множитель σ^2 в знаменателе и в границах $\lambda_\pm$). При $\gamma > 1$ полюс функции $s(z)$ в нуле $z \to 0$ дает вычет, отвечающий атому $(1 - 1/\gamma)\delta_0(\lambda)$.

Модель ковариации с шипами (Spiked Covariance Model)

- В реальных данных есть сигнал! Как формализовать наличие информативных компонент?
- **Модель Джонстоуна (Johnstone, 2001):** Истинная ковариация — это сумма шума и низкорангового сигнала ранга $r \ll p$:

$$\Sigma = I_p + \sum_{k=1}^{r} \theta_k v_k v_k^T, \quad \theta_1 \geq \theta_2 \geq \ldots \geq \theta_r > 0$$

  - θ_k — истинная мощность (амплитуда) k-го сигнала;
  - v_k — истинное направление (ортонормированные сигнальные векторы);
  - I_p — фон белого шума ($\sigma^2 = 1$).
- **Наблюдаемые данные:** $Y = \Sigma^{1/2} X$, где $X \in \mathbb{R}^{p \times n}$ — шум с элементами $\mathcal{N}(0, 1)$.
- **Задача PCA:** обнаружить наличие сигнала и оценить его вектор v_k по собственным векторам выборочной матрицы $\hat{\Sigma} = \frac{1}{n} Y Y^T$.
- **Вопрос:** всегда ли PCA способен различить сигнал произвольной силы $\theta > 0$?

Фазовый переход BBP (Baik–Ben Arous–Péché, 2005)

- **Теорема BBP:** В пределе $p, n \to \infty, p/n \to \gamma > 0$ выборочное собственное значение $\hat{\lambda}_1 = \lambda_1(\hat{\Sigma})$ демонстрирует резкий **фазовый переход**:

$$\hat{\lambda}_1 \xrightarrow{a.s.} \begin{cases} (1 + \sqrt{\gamma})^2 = \lambda_+, & \text{если } \theta \leq \sqrt{\gamma} \quad \textbf{(докритический режим)} \\ (1 + \theta)\left(1 + \frac{\gamma}{\theta}\right), & \text{если } \theta > \sqrt{\gamma} \quad \textbf{(сверхкритический режим)} \end{cases}$$

- **Критический порог детектирования:**

$$\theta_c = \sqrt{\gamma} = \sqrt{\frac{p}{n}}$$

- **Физический смысл фазового перехода:**
  - Если сигнал слабее порога ($\theta \leq \sqrt{\gamma}$), выборочное значение $\hat{\lambda}_1$ намертво застревает на верхней границе шумового балка λ_+.
  - Сигнал не просто искажен — он **математически неотделим от шума** спектральными методами!

Математический механизм BBP: секулярное уравнение

- Откуда берется число $\theta_c = \sqrt{\gamma}$?
- Запишем $\hat{\Sigma} = \frac{1}{n}\Sigma^{1/2}XX^T\Sigma^{1/2}$ для одношиповой модели ($\Sigma = I + \theta vv^T$):
  - Ненулевые собственные числа $\hat{\Sigma}$ вне балка являются корнями уравнения:

$$\det(\hat{\Sigma} - zI_p) = 0 \iff \det\left(I_p + \theta vv^T - z\left(\frac{1}{n}XX^T\right)^{-1}\right) = 0$$

- Применяя формулу детерминанта возмущения ранга 1 ($\det(I + uw^T) = 1 + w^Tu$):

$$1 + \theta \cdot v^T\left(\frac{1}{n}XX^T - zI\right)^{-1}v = 0$$

- В пределе высокой размерности квадратичная форма концентрируется к следу резольвенты шума:

$$v^T\left(\frac{1}{n}XX^T - zI\right)^{-1}v \xrightarrow{P} s_{MP}(z)$$

- **Секулярное уравнение вне балка:**

$$1 + \theta \cdot s_{MP}(z) = 0 \iff s_{MP}(z) = -\frac{1}{\theta}$$

- Так как $s_{MP}(z)$ монотонна на (λ_+, ∞), ее максимальное по модулю значение достигается на краю балка:

$$|s_{MP}(\lambda_+)| = \frac{1}{\sqrt{\gamma}}$$

- Вещественный корень вне балка существует тогда и только тогда, когда:

$$\frac{1}{\theta} < \frac{1}{\sqrt{\gamma}} \iff \theta > \sqrt{\gamma}$$

Эффект «слепоты» PCA и коллапс проекций

- Что происходит с направлением собственного вектора $\widehat{v}_1$ (первой главной компонентой)?
- **Теорема о проекции собственного вектора (Paul, 2007; Benaych-Georges & Nadakuditi, 2011):** Косинус угла (скалярное произведение) между истинным сигнальным направлением v_1 и найденной главной компонентой $\widehat{v}_1$:

$$|\langle \widehat{v}_1, v_1 \rangle|^2 \xrightarrow{a.s.} \begin{cases} 0, & \theta \le \sqrt{\gamma} \\ \frac{1-\frac{\gamma}{\theta^2}}{1+\frac{\gamma}{\theta}}, & \theta > \sqrt{\gamma} \end{cases}$$

- **Следствия:**
  1. **Информационная слепота:** если $\theta \le \sqrt{\gamma}$, выборочный вектор $\widehat{v}_1$ асимптотически ортогонален истинному сигналу! Линейный PCA находит случайное направление.
  2. **Неустранимое смещение:** даже если $\theta > \sqrt{\gamma}$, скалярное произведение строго меньше 1. Чтобы получить оценку высокого качества ($|\langle \widehat{v}_1, v_1 \rangle|^2 \approx 1$), необходимо:

$$\theta \gg \sqrt{\gamma} \iff n \gg \frac{p}{\theta^2}$$

Сколько компонент PCA — сигнал, а не шум?

- **Классические эвристики:**
  - *Критерий Кайзера:* оставлять $\lambda_i > 1$ (среднее значение). **Ошибочен:** в шуме половина собственных чисел больше 1!
  - *Правило «локтя» (Scree plot):* визуально субъективно и ненадежно.
- **Математически строгий алгоритм на базе RMT и BBP:**
  1. Оцениваем эффективное отношение $\widehat{\gamma} = p/n$ и масштабирующий фактор дисперсии σ^2 (по нижним квантилям спектра).
  2. Рассчитываем край Марченко–Пастура: $\lambda_+ = \sigma^2(1 + \sqrt{\widehat{\gamma}})^2$.
  3. **Число реальных сигнальных компонент r^*:**

$$r^* = \arg\max_k \left\{ \lambda_k(\widehat{\Sigma}) > \lambda_+ + \delta_n \right\}$$

  (где $\delta_n \sim n^{-2/3}$ — поправка на флуктуации Трейси–Видома на краю).
  4. **Калибровка амплитуды сигнала:** истинная сила сигнала восстанавливается обратным преобразованием формулы BBP:

$$\widehat{\theta}_k = \frac{\widehat{\lambda}_k + 1 - \widehat{\gamma} + \sqrt{(\widehat{\lambda}_k + 1 - \widehat{\gamma})^2 - 4\widehat{\lambda}_k}}{2} - 1$$

От ковариаций к весам нейросетей: спектральный срез

- Рассмотрим матрицу весов полносвязного слоя (или развернутого сверточного) глубокой сети:
$$W \in \mathbb{R}^{N \times M}$$
- Сформируем матрицу выборочных корреляций признаков слоя:
$$X = \frac{1}{N} W^T W \in \mathbb{R}^{M \times M}$$
- **Что происходит при случайной инициализации (Xavier / He)?**
  - Веса независимы: $W_{ij} \sim \mathcal{N}(0, \sigma^2)$.
  - Спектр матрицы X идеально следует закону Марченко–Пастура с $\gamma = M/N$.
- **Что происходит во время обучения через SGD?**
  - Градиентный спуск индуцирует сильные корреляции между строками и столбцами весовых матриц.
  - Традиционная гипотеза: спектр превратится в “Bulk + Spikes” (BBP-модель: шумовой балк + несколько сигнальных компонент).
  - **Реальность (Martin & Mahoney, 2018–2021):** в обученных глубоких сетях спектр фундаментально иной!

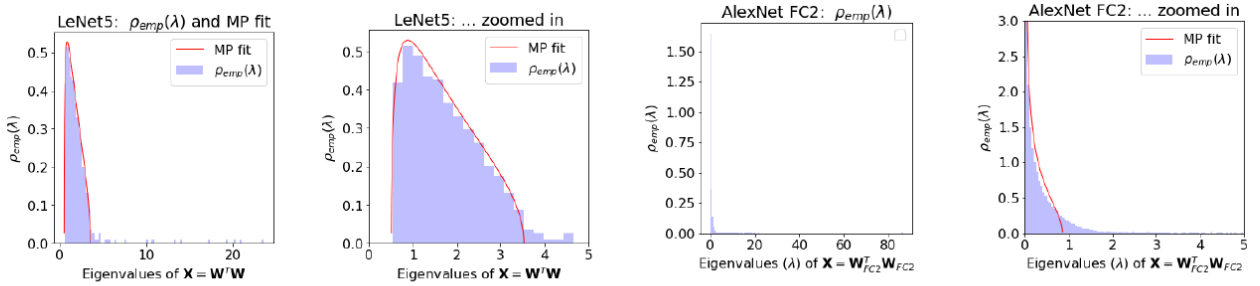
Подход Мартина–Махони: Heavy-Tailed Self-Regularization

- **Чарльз Мартин и Майкл Махони (UC Berkeley):** Серия фундаментальных работ (JMLR 2021) по непертурбативному анализу весов SOTA-нейросетей (VGG, ResNet, BERT, GPT).
- **Теория HTSR (Heavy-Tailed Self-Regularization):**
  - Взаимодействие шума мини-батчей SGD, сильной невыпуклости ландшафта и нелинейностей (ReLU) приводит к эффекту **самоорганизованной критичности** (SOC).
  - Модель спонтанно саморегуляризуется, сдвигая спектры матриц весов от гауссова балка Марченко–Пастура к **тяжелохвостым степенным распределениям (Power Law)**:
$$\rho(\lambda) \propto \lambda^{-\alpha}, \quad \lambda \in [\lambda_{min}, \lambda_{max}]$$
  - Спектр становится масштабно-инвариантным (scale-free), объединяя корреляции на всех масштабных уровнях представления признаков.

Подход Мартина–Махони: Heavy-Tailed Self-Regularization

Пять спектральных фаз матриц весов

- **1. Random-like (MP):** Спектр неотличим от шума Марченко–Пастура. Слой не обучился (веса «заморожены» или градиенты затухли).



(a) LeNet5, full (b) LeNet5, zoomed-in (c) AlexNet, full (d) AlexNet, zoomed-in

Figure 1: Full and zoomed-in ESD for LeNet5 (Layer FC1) and AlexNet (Layer FC2). Overlaid (in red) are fits of the MP distribution (which fit the bulk very well for LeNet5 but *not* well for AlexNet).

Рис. 3: Спектр матриц слоев

- **2. Bleeding out:** Собственные числа начинают вытекать за границу λ_+, формируя слабые корреляции.
- **3. Fat-Tailed / Heavy-Tailed:** Балк полностью растворился, весь спектр подчинен степенному закону.
- **4. Bulk + Decay:** Частично сохранен шумовой балк низких частот, из которого произрастает степенной хвост сигнала.
- **5. Collapsed / Rank-deficient:** Катастрофическое схлопывание ранга — пара собственных чисел забирает 99% следа матрицы. Признак сильного переобучения.

Эта классификация позволяет инженеру по машинному обучению за секунды оценить “здоровье” каждого слоя нейросети без прогона терабайтных валидационных сетов.

Пять спектральных фаз матриц весов

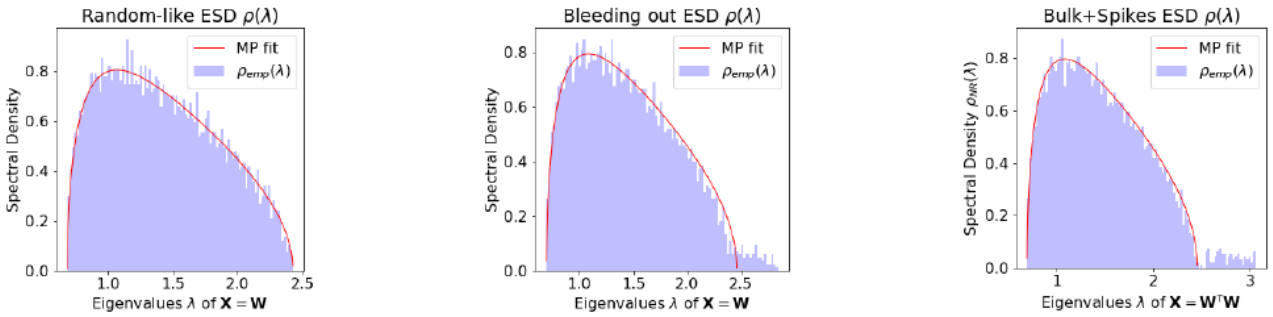
Что происходит во время обуения нейросети

Зависимость от Batch Size

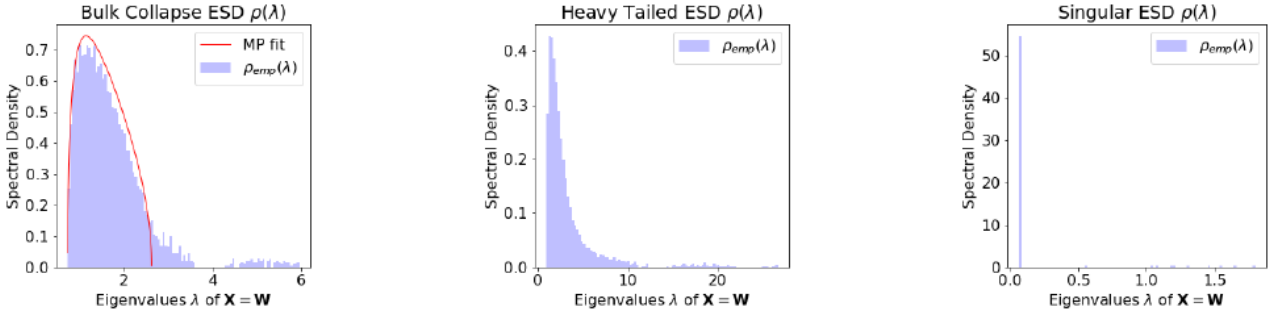
Степенной показатель α как мера обобщения

- Плотность хвоста аппроксимируется усеченным распределением Парето методом максимального правдоподобия (метод Клаузе–Шальзи–Ньюмана):

$$\rho(\lambda) \sim \lambda^{-\alpha}, \quad \lambda \geq \lambda_{min}$$



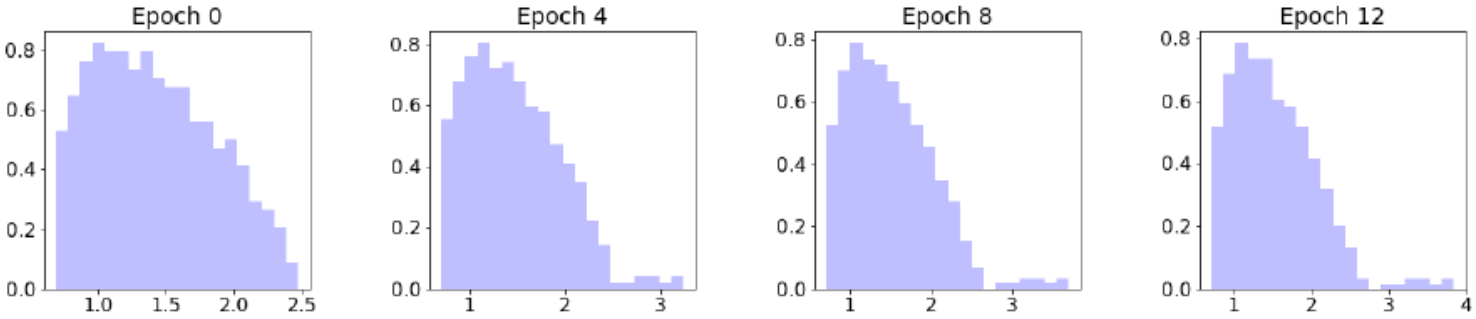
(a) RANDOM-LIKE. (b) BLEEDING-OUT. (c) BULK+SPIKES.



(d) BULK-DECAY. (e) HEAVY-TAILED. (f) RANK-COLLAPSE.

Figure 2: Taxonomy of trained models. Starting off with an initial random or RANDOM-LIKE model (2(a)), training can lead to a BULK+SPIKES model (2(c)), with data-dependent spikes on top of a random-like bulk. Depending on the network size and architecture, properties of training data, etc., additional training can lead to a HEAVY-TAILED model (2(e)), a high-quality model with long-range correlations. An intermediate BLEEDING-OUT model (2(b)), where spikes start to pull out from the bulk, and an intermediate BULK-DECAY model (2(d)), where correlations start to degrade the separation between the bulk and spikes, leading to a decay of the bulk, are also possible. In extreme cases, a severely over-regularized model (2(f)) is possible.

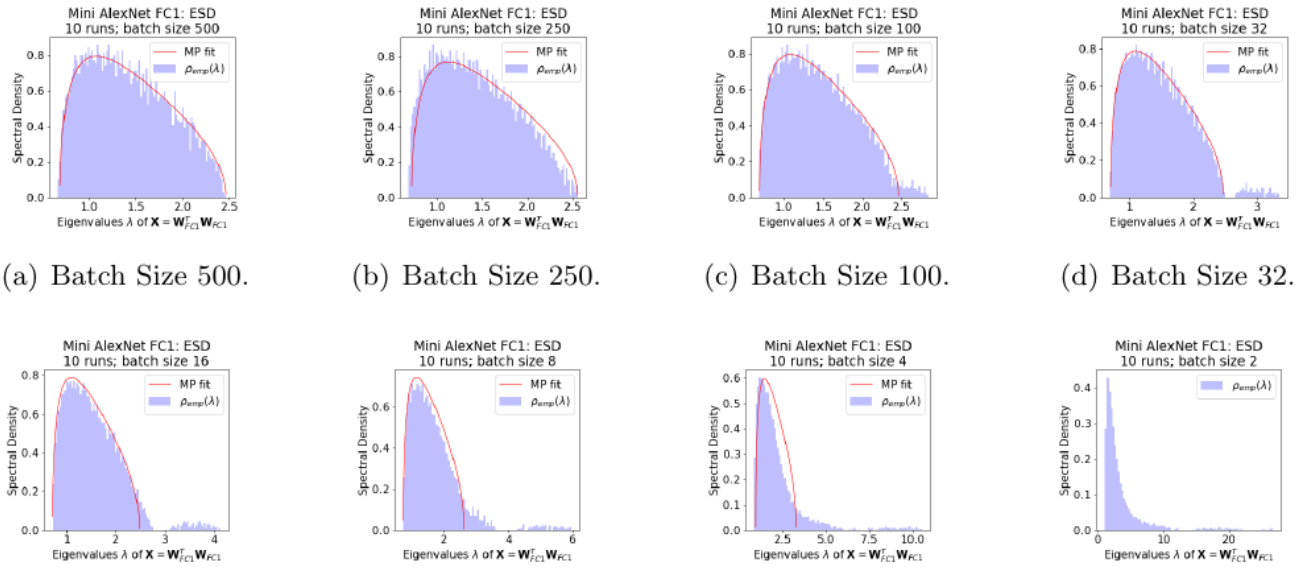
Рис. 4: Пять спектральных фаз матриц весов



(a) Epoch 0 (b) Epoch 4 (c) Epoch 8 (d) Epoch 12

Figure 3: Baseline ESD for Layer FC1 of MiniAlexNet, during training.

Рис. 5: Пять спектральных фаз матриц весов



(a) Batch Size 500. (b) Batch Size 250. (c) Batch Size 100. (d) Batch Size 32.

(e) Batch Size 16. (f) Batch Size 8. (g) Batch Size 4. (h) Batch Size 2.

Figure 5: Varying Batch Size. ESD for Layer FC1 of MiniAlexNet, with MP fit (in red), for an ensemble of 10 runs, for Batch Size ranging from 500 down to 2. Smaller batch size leads to more implicitly self-regularized models. We exhibit all 5 of the main phases of training by varying only the batch size.

Рис. 6: Пять спектральных фаз матриц весов

- **Диагностическая шкала показателя α:**
  - $\alpha > 4$ **(Слабая регуляризация / Недообучение):** Хвост слишком легкий (близок к субэкспоненциальному/гауссову). Модель не извлекла глубоких семантических зависимостей. Фазы 1-2.
  - $2 < \alpha \leq 4$ **(«Зона Златовласки» / Оптимальное обучение):** Универсальный класс систем с тяжелыми хвостами (распределения Леви–Хинчина). Идеальный баланс между сжатием признаков и выразительностью. Модель отлично обобщает. Фазы 2-4.
  - $\alpha \leq 2$ **(Переобучение / Запоминание шума):** Хвост аномально тяжелый (теоретическая дисперсия бесконечна). Веса слоя определяются узким набором запомненных обучающих примеров; спектральная норма $\|W\|_2$ доминирует над стабильностью. Фаза 5.

Диагностика без валидационной выборки (WeightWatcher)

- На практике Мартин и Махони используют взвешенный показатель качества модели Alpha-Hat:

$$\widehat{\alpha} = \frac{1}{L}\sum_{l=1}^{L}\alpha_l, \quad \text{или} \quad \widehat{\alpha}_{\text{weighted}} = \frac{1}{L}\sum_{l=1}^{L}\alpha_l \log \lambda_{\text{max},l}$$

  Здесь L - общее кол-во слоев нейросети, l - индекс слоя.

- **Практическая ценность для MLOps и Deep Learning:**
  - **Сравнение чекпоинтов:** мониторинг $\widehat{\alpha}$ в процессе тренировки позволяет останавливать обучение (Early Stopping) без валидационного сета.
  - **Детекция битых слоев:** для хорошо обученных слоев $2 < \alpha_l < 6$ (чем меньше, тем лучше натренирован). Но если у слоя l показатель $\alpha_l < 1.8$, этот слой переобучен. Решение: добавить Weight Decay или Dropout локально в этот слой.
  - **Оценка качества без доступа к закрытым данным:** аудит приватных и коммерческих LLM на устойчивость к генерализации.

Диагностика без валидационной выборки (WeightWatcher)

Резюме: от пределов RMT к машинному обучению

- **1. Предел высокой размерности ($p \sim n$):**
  - Случайный шум порождает детерминированный непрерывный спектр Марченко–Пастура с жестким краем $\lambda_+ = \sigma^2(1+\sqrt{\gamma})^2$.
  - Направления с малыми собственными числами — фиктивный артефакт, разрушающий линейную регрессию.
- **2. Фазовый переход BBP:**

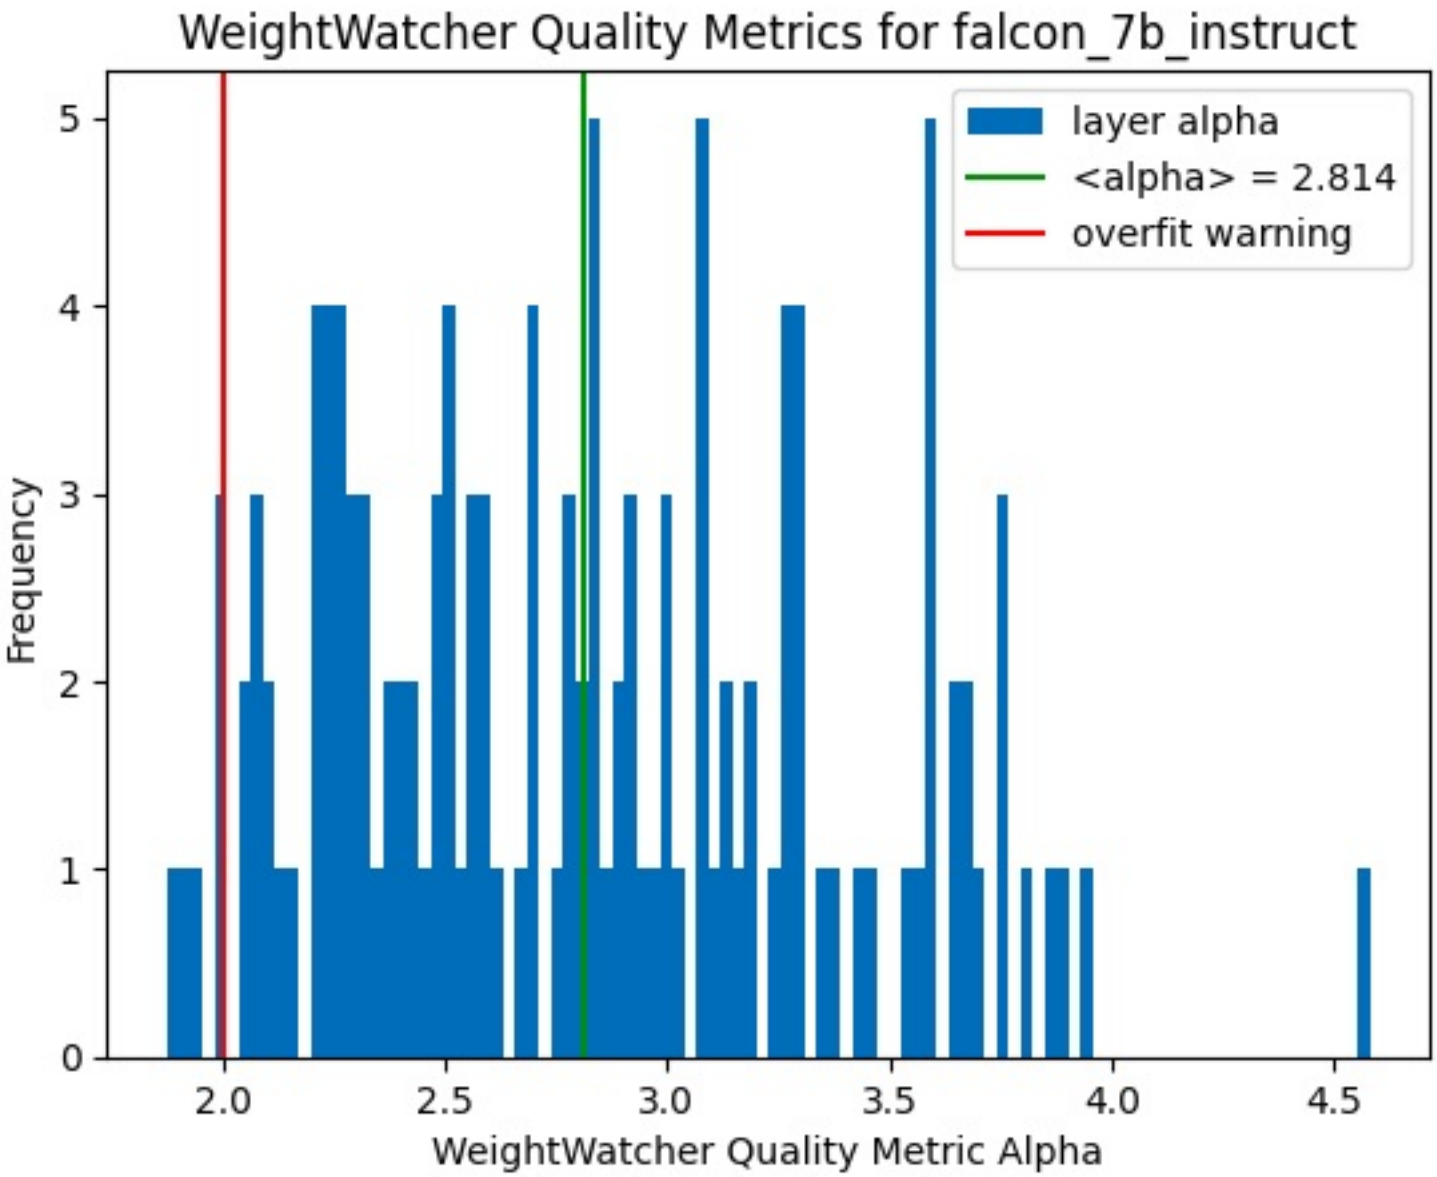


Рис. 7: WeightWatcher

  - Сигнал детектируем стандартным PCA тогда и только тогда, когда его амплитуда строго превышает $\theta_c = \sqrt{p/n}$.
  - Ниже порога θ_c выборочный вектор ортогонален истинному — имеет место информационная слепота.
- **3. Диагностика глубоких сетей (HTSR):**
  - Градиентный спуск превращает гауссов шум Марченко–Пастура в тяжелохвостые спектры со степенным спадом $\rho(\lambda) \sim \lambda^{-\alpha}$.
  - Показатель наклона хвоста $\alpha \in (2, 4)$ служит индикатором оптимального обобщения без обращения к валидационным данным.